

Мультимасштабная графовая нейросетевая модель регионального прогноза погоды

А.С. Табаков^{1,2}, А.В. Пененко¹, А.Б. Колкер³

¹Институт вычислительной математики и математической геофизики СО РАН, г. Новосибирск, Россия; ²Новосибирский государственный университет, г. Новосибирск, Россия; ³Новосибирский государственный технический университет, г. Новосибирск, Россия

artur.tabakov11@gmail.com

Работа проверяет, может ли графовая нейросеть давать региональный прогноз погоды высокого разрешения, если граничные условия для области задаёт не внешняя модель, а глобальная часть той же сети. Глобальная сетка с шагом $0,703^\circ$ и региональная вставка с шагом $0,25^\circ$ объединены в один граф из 133 279 узлов. Глобальная часть графа прогнозируется одновременно со вставкой и передаёт в неё информацию извне, поэтому граничные данные от другой модели не нужны. На независимой выборке ERA5 из 1607 сроков над областью $50\text{--}60^\circ$ с. ш., $83\text{--}98^\circ$ в. д. ошибка прогноза приземной температуры на сутки равна $1,37^\circ\text{C}$. У границы вставки она на 3–5 % выше, чем в 100–200 км от неё, и с ростом срока прогноза превышение не растёт. Ошибка в 1,21 раза больше, чем у глобальной модели GraphCast, у которой в 5,5 раза больше параметров. Модель с 6,7 млн параметров обучается на одном графическом ускорителе. Веса узлов и каналов в функции потерь снизили ошибку приземной температуры на 10 %. Передача сообщений с признаками рёбер в кодировщике и декодировщике убрала из прогноза отпечаток треугольников графа. Сгущение графа над областью до шага около 55 км снизило ошибку ветра на 5–8 %. Ошибка одношагового прогноза на проверочной выборке оказалась ненадёжным критерием отбора модели для многошагового прогноза.

Ключевые слова: численный прогноз погоды, графовая нейронная сеть, региональный прогноз, мультимасштабная сетка, авторегрессионный прогноз, функция потерь, машинное обучение

A multiscale graph neural network for regional weather forecasting

A.S. Tabakov^{1,2}, A.V. Penenko¹, A.B. Kolker³

¹Institute of Computational Mathematics and Mathematical Geophysics SB RAS, Novosibirsk, Russia; ²Novosibirsk State University, Novosibirsk, Russia; ³Novosibirsk State Technical University, Novosibirsk, Russia

artur.tabakov11@gmail.com

The work tests whether a graph neural network can give a high-resolution regional weather forecast when the boundary conditions for the area come from the global part of the same network rather than from an external model. A 0.703° global grid and a 0.25° regional insert form one graph of 133,279 nodes. The global part is forecast together with the insert and feeds it, so no boundary data from another model are needed. On 1607 independent ERA5 initial times over $50\text{--}60^\circ\text{ N}$, $83\text{--}98^\circ\text{ E}$ the 24-h 2-m temperature error is 1.37°C . Near the insert boundary it is 3–5 % higher than 100–200 km inside, and the excess does not grow with lead time. The error is 1.21 times that of GraphCast, which has 5.5 times more parameters. The model has 6.7 million parameters and trains on one GPU. Loss weights for nodes and channels cut the 2-m temperature error by 10 %. Message passing with edge features in the encoder and decoder removes the imprint of mesh triangles. Refining the graph over the area to about 55 km cuts the wind error by 5–8 %. The single-step validation error proves an unreliable criterion for selecting a multi-step forecast model.

Keywords: numerical weather prediction, graph neural network, regional forecasting, multiscale mesh, autoregressive forecast, loss function, machine learning

Введение

Численный прогноз погоды получают интегрированием уравнений гидротермодинамики атмосферы (уравнений Навье–Стокса на вращающейся Земле) на глобальных и более подробных региональных сетках. В России глобальный прогноз оперативно выпускают по полулагранжевой модели ПЛАВ [1]. Такие модели составляют основу оперативного прогноза, но один глобальный прогноз на средние сроки занимает часы работы суперкомпьютера. Это ограничивает частоту обновления прогноза и размер ансамбля.

В 2022–2023 годах нейросетевые модели, обученные на архиве реанализа, сравнялись по точности с оперативными моделями крупнейших прогностических центров на ограниченном наборе переменных, а считают во много раз быстрее. GraphCast [8] прогнозирует пять приземных полей и шесть переменных на 37 уровнях. На сроках до десяти суток она превзошла оперативную систему Европейского центра на 90 % из 1380 проверенных сочетаний переменных, уровня и срока. Сопоставимых результатов достигли Pangu-Weather [3] и FourCastNet [11]. В основе GraphCast лежит граф, узлы которого покрывают сферу с близким шагом (п. 3.1).

Перечисленные модели глобальные. Региональный прогноз решает другую задачу: он даёт более подробные поля над ограниченной территорией и нужен наряду с глобальным. Главная трудность нейросетевого регионального прогноза связана с граничными условиями: у краевых узлов вырезанной области нет корректного окружения. В классическом прогнозе поле в буферной зоне релаксирует к внешнему полю [4]. Для этого нужна отдельная процедура, которая вносит собственные погрешности.

Для нейросетевых региональных моделей предложено несколько способов обойти проблему границ. Архитектура Neural-LAM [10] получает граничный форсинг от глобальной

модели. В [9] разрешение плавно меняется на растянутой сетке. В [5] вложенные сетки обмениваются информацией между уровнями. Подходы с растянутой сеткой и с ограниченной областью сравнивали в [13].

Цель работы состоит в проверке того, можно ли получить региональный прогноз высокого разрешения без граничных условий от внешней модели, если объединить глобальную и региональную сетки в один граф. Схема проверена на области $50\text{--}60^\circ$ с. ш., $83\text{--}98^\circ$ в. д. Основные положения работы следующие.

1. Глобальная сетка с шагом $0,703^\circ$ и региональная вставка с шагом $0,25^\circ$ соединены жёстко в один граф без внешних границ, и отдельная процедура сшивания полей не нужна. Граничные условия для вставки задаёт глобальная часть того же графа, которая прогнозируется одновременно со вставкой. У границы вставки ошибка приземной температуры на 3–5 % выше, чем в 100–200 км от неё, и с ростом срока прогноза это превышение не растёт (п. 4.6). Сама идея мультимасштабного представления известна [5, 9]. Предложенный вариант отличается способом построения: узлы глобальной решётки внутри области заменены узлами вставки, и связность для всех узлов строится одинаково. Такая конструкция точнее интерполяции прогноза глобальной модели в те же узлы.
 2. Модель намеренно сделана лёгкой: у неё 6,7 млн параметров, у моделей [3, 8, 9] от десятков до сотен миллионов. Обучение и прогноз выполняются на одном ускорителе NVIDIA H100 с памятью 80 ГБ. Эпоха дообучения занимает около 2,8 ч, суточный прогноз вместе с чтением данных меньше 5 с. Такие ресурсы доступны вычислительной среде регионального управления гидрометслужбы.
 3. Исследована стратегия дообучения глобальной модели под региональную сетку. Ошибка одношагового прогноза на проверочной выборке оказалась ненадёжным критерием отбора, если модель строит многошаговый прогноз.
 4. При равномерном усреднении функции потерь обучающий сигнал распределяется не так, как требует задача: узлы целевой области получают 1,7 % сигнала, приземная температура 0,46 %. Явные веса по узлам и каналам снижают ошибку приземной температуры на 10,2 %, архитектура и объём обучения остаются прежними.
 5. Сравнение с GraphCast по масштабам показало, где модель теряет точность. Кодировщик и декодировщик на свёрточных слоях графа не учитывают положение узла сетки относительно вершин графа, и в прогнозе проступают границы треугольников. Передача сообщений с признаками рёбер, как в GraphCast, убирает этот отпечаток, а сгущение графа над областью закрывает отставание на масштабах 100–220 км (п. 4.8).
-

Данные, базовая модель и метрики качества

Исходные данные

Модель обучали и оценивали на реанализе ERA5 Европейского центра среднесрочных прогнозов погоды [6] за 2010–2020 гг. с шагом 6 ч. Это 16 072 последовательных срока.

Состояние атмосферы описывают 19 полей. Семь из них приземные: температура воздуха на высоте 2 м, зональная и меридиональная составляющие ветра на высоте 10 м, давление на уровне моря, приземное давление, суммарные осадки за 6 ч и общее содержание водяного пара в столбе атмосферы. Два поля статические: геопотенциал поверхности и маска суши и моря. Модель получает статические поля на вход, но не прогнозирует. На уровнях 850 и 500 гПа заданы по пять полей: температура, две составляющие ветра, геопотенциал и удельная влажность. Граф двумерный: значения на уровнях 850 и 500 гПа входят в вектор признаков того же узла, что и приземные поля.

Поля хранятся в размерном виде, геопотенциал ERA5 поделён на $g = 9,80665 \text{ м/с}^2$. Перед подачей в сеть каждый канал нормируется: из него вычитают среднее и делят на стандартное отклонение за 2010–2020 гг., включая проверочную и тестовую части. Влияние этих двух чисел на канал пренебрежимо мало.

На вход модель получает два последовательных срока (12 ч). Прогноз строится авторегрессионно с шагом 6 ч, оценки приводятся для горизонтов +6, +12, +18 и +24 ч.

Целевая область (регион) ограничена координатами 50–60° с. ш., 83–98° в. д. Область покрывает решётка с шагом 0,25° размером $61 \times 41 = 2501$ узел. Внутри региона выделена зона 55,5–56,5° с. ш., 92–94° в. д. (45 узлов), удалённая от границы вставки не меньше чем на 250 км. Метрики считаются относительно полей ERA5 с шагом 0,25° в этих узлах, без интерполяции с более грубой сетки.

Итоговая модель использует 33 канала. К 19 полям в ней добавлены температура, обе составляющие ветра, геопотенциал и удельная влажность на уровнях 250 и 1000 гПа и четыре канала временного форсинга, синусы и косинусы часа суток и дня года. При развёртке форсинг и статические поля берутся из данных и в число прогностических каналов не входят.

Хронологическое разбиение выборки

Выборку разбили по времени, без перемешивания: обучающая часть предшествует проверочной, а та тестовой. Окно примера включает 2 входных среза и 4 прогностических шага, и из 16 072 сроков получается 16 067 примеров. Примеры разделили в долях 80, 10 и 10 %: 12 853 для обучения, 1607 для подбора гиперпараметров и отбора состояния модели, 1607 для тестов. Все публикуемые числа получены на тестовой выборке, которая охватывает полный годовой цикл. Сроки начала прогноза в обучающей выборке идут с 01.01.2010 06 UTC по 19.10.2018 06 UTC, в проверочной с 19.10.2018 12 UTC по 25.11.2019 00 UTC, в тестовой с 25.11.2019 06 UTC по 30.12.2020 18 UTC.

Базовая глобальная модель

Региональное дообучение начинается с глобальной модели. Глобальную модель обучили на тех же 19 полях на широтно-долготной сетке 512×256 узлов с шагом около $0,703^\circ$. Архитектура у неё та же, что у региональной (п. 3.2), но без слоёв с признаками рёбер в кодировщике и декодировщике. Меш объединяет уровни детализации 4 и 6. У глобальной модели 6,0 млн обучаемых параметров, в шесть раз меньше, чем у GraphCast [8].

Функция потерь равна среднеквадратической ошибке в стандартизованных переменных, осреднённой по узлам, каналам и горизонтам. Из-за особенности реализации широтные веса узлов при глобальном предобучении были почти равномерными, а при региональном дообучении (п. 3.4) применялись веса $\cos\phi$, где ϕ обозначает широту узла. Региональное дообучение стартовало с промежуточного состояния глобальной модели с наименьшей ошибкой на проверочной выборке (эпоха 30 из 36 пройденных). На собственной сетке базовая модель даёт агрегатную успешность около 65 % и ошибку приземной температуры $1,07^\circ\text{C}$ в среднем по горизонтам $+6\dots+24$ ч (200 сроков). Эти значения посчитаны по всему шару на сетке $0,703^\circ$ и на другой подвыборке сроков, и с региональными числами они несопоставимы.

Метрики качества

Для канала c и горизонта τ среднеквадратическая ошибка считается в физических единицах канала:

$$\text{RMSE}_c(\tau) = \left[\frac{1}{N|G|} \sum_{n=1}^N \sum_{g \in G} (\hat{x}_{c,g}^{(n)}(\tau) - x_{c,g}^{(n)}(\tau))^2 \right]^{1/2}, \quad (1)$$

где N — число сроков ($N = 1607$ для тестовой выборки); G — множество оцениваемых узлов (2501 для региона, 45 для внутренней зоны); $\hat{x}$ — прогноз, x — значение реанализа, принятое за истинное. Ошибка приводится в единицах переменной: $^\circ\text{C}$, м/с, гПа, гпм. Узлы входят в сумму с весами $\cos\phi$, нормированными на единичное среднее, как принято в протоколе верификации нейросетевых моделей прогноза [12]. Ячейка широтно-долготной сетки на 60° с. ш. вдвое уже экваториальной, и при равных весах высокие широты получили бы завышенный вклад.

Успешность считается относительно двух опорных прогнозов. Первый сохраняет поля последнего входного среза t_0 на всех горизонтах без изменений (прогноз сохранения, в англоязычной литературе persistence). Второй равен климатологии и описан ниже. Успешность относительно опорного прогноза вычисляется так:

$$S_c(\tau) = \left(1 - \frac{\text{RMSE}_c(\tau)}{\text{RMSE}_c^{\text{оп}}(\tau)} \right) \cdot 100\%, \quad (2)$$

где $RMSE^{оп}$ — ошибка (1) для опорного прогноза на том же окне и той же маске узлов.

Прогноз сохранения подходит для сравнения не по всем полям. По приземной температуре его ошибка на горизонтах +6...+24 ч равна 4,99; 6,88; 5,88 и 4,42 °C: к суткам поле возвращается к тому же часу местного времени. Успешность относительно него немонотонна (76,4; 80,2; 76,2 и 67,0 %) и зависит от опорного прогноза не меньше, чем от модели.

Климатология от часа суток не зависит. Климатологию построили по обучающей части выборки разложением по гармоникам (три годовые и суточный ход), тестовые сроки в подгонку не входили. Ошибка климатологии почти не меняется с горизонтом и равна 6,25 °C по приземной температуре, 5,42 °C по температуре на 850 гПа, 9,19 гПа по давлению на уровне моря, 2,05 и 1,74 м/с по составляющим ветра. На суточном сроке успешность итоговой модели относительно климатологии равна 78,1 % по приземной температуре, 84,8 % по T850, 89,5 % по давлению, 69,3 и 64,9 % по ветру.

Сводную оценку даёт агрегатный показатель относительно прогноза сохранения. Единицы у каналов разные, и агрегат считается в нормированных переменных:

$$\overline{RMSE} = \left[\frac{1}{N |G| C H} \sum_n \sum_{g \in G} \sum_{c=1}^C \sum_{\tau} \left(\frac{x_{c,g}^{(n)}(\tau) - x_{c,g}^{(n)}(\tau)}{\sigma_c} \right)^2 \right]^{1/2}, \quad \bar{S} = \left(1 - \frac{\overline{RMSE}}{\overline{RMSE}^{оп}} \right) \cdot 100 \%, \quad (3)$$

где σ_c — стандартное отклонение канала при нормировке; C — число прогностических каналов (17 для 19-канальной конфигурации, 27 для 33-канальной: исключены два статических поля и четыре канала форсинга); $H = 4$. В табл. 1 столбец $\bar{S}$ осредняет разные наборы каналов, и строки с 19 и 33 каналами по нему сравнивать нельзя. Сравнимы поканальные значения и строки внутри одного набора.

Кроме ошибки, приводится аномальная корреляция. Эта мера показывает, насколько прогноз воспроизводит отклонение от обычного состояния:

$$ACC_c(\tau) = \frac{\sum w_g (x_{c,g}^{(n)} - \bar{x}_{c,g})(x_{c,g} - \bar{x}_{c,g})}{\left[\sum w_g (x_{c,g}^{(n)} - \bar{x}_{c,g})^2 \sum w_g (x_{c,g} - \bar{x}_{c,g})^2 \right]^{1/2}}, \quad (4)$$

где $\bar{x}$ — климатология ERA5 за 1990–2019 гг. из архива WeatherBench 2 [12], w_g — тот же широтный вес. Суммирование идёт сразу по узлам и срокам, то есть ACC равна отношению сумм, а не среднему посрочных корреляций.

Точность оценок характеризуют доверительные интервалы блочного бутстрепа. Сроки идут через 6 ч и коррелированы внутри одного синоптического процесса, и при ресэмплинге берутся блоки подряд идущих сроков [7]. Интервалы строятся из посрочных вкладов в ошибку, и конфигурации сравниваются парно на общих сроках. Интервал учитывает изменчивость

по срокам верификации, но не по повторным обучениям. Изменчивость по обучением оценена в п. 5.1.

Мультимасштабная графовая модель и стратегия дообучения

Ограничения регулярной сетки на сфере

Значение переменной в узле через шесть часов определяется состоянием его окрестности, и чтобы модель выучила эту зависимость, окрестность должна везде охватывать примерно одно и то же расстояние в километрах. На регулярной сетке это не так: при шаге $0,703^\circ$ расстояние между узлами вдоль параллели равно около 78 км на экваторе, 50 км на 50° с. ш. и 14 км на 80° с. ш., а у полюсов сетка вырождается.

Узлы с близким шагом по всей сфере даёт икосаэдрическая триангуляция. Каждый треугольник икосаэдра рекурсивно делят на четыре, а новые вершины проецируют на сферу. У каждой вершины пять или шесть соседей. На самом подробном уровне графа длины рёбер лежат в пределах 110–132 км, поэтому окрестность вершины везде охватывает близкое расстояние.

Архитектура

Модель построена по схеме «кодировщик–процессор–декодировщик» [2, 8]. Узлы обмениваются информацией на графе, а входные и выходные поля остаются на регулярной сетке.

Кодировщик переносит значения из узлов сетки в вершины графа. Каждая вершина собирает признаки узлов, которые попали в её окрестность (радиус связи 0,6 в единицах длины ребра графа). Сначала признаки смешивают свёрточные слои графа с весами, которые зависят только от числа связей. Затем слой передачи сообщений с признаками рёбер, как в GraphCast [8], добавляет поправку, которая зависит от смещения узла относительно вершины. Размерность скрытого представления вершины равна 256.

Процессор выполняет $R = 12$ раундов обмена сообщениями по рёбрам графа. Каждый раунд реализован блоком Interaction Network [2] и состоит из двух шагов. Сначала для каждого ребра ($i \rightarrow j$) вычисляется сообщение

$$m_{ij}^{(r)} = \varphi_e(h_i^{(r-1)}, h_j^{(r-1)}, e_{ij}), \quad (5)$$

затем состояние вершины обновляется по среднему входящих сообщений:

$$h_j^{(r)} = \varphi_v(h_j^{(r-1)}, \frac{1}{|N(j)|} \sum_{i \in N(j)} m_{ij}^{(r)}), \quad (6)$$

где $h_j^{(r)}$ — скрытое представление вершины j после раунда r (размерность 256); e_{ij} — постоянные признаки ребра (длина и три компоненты единичного вектора направления в геоцентрических координатах); $N(j)$ — вершины, соединённые с j ; ϕ_e и ϕ_v — персептроны с активацией Swish и послойной нормировкой. Веса раундов не разделяются, как и в [8].

Декодировщик переносит скрытые представления вершин обратно в узлы регулярной сетки и выдаёт приращения полей. Каждый узел сетки получает сообщения от трёх вершин треугольника графа, в который он попадает. Сообщение строится по формуле (5), где признаки ребра задают смещение узла относительно вершины, так что вклад вершины зависит от положения узла внутри треугольника. Зачем это нужно, показано в п. 4.8.

Прогноз строится авторегрессионно с шагом 6 ч. Выход модели снова подаётся на её вход и даёт следующий срок:

$$\hat{x}(t_0 + 6(k+1)) = F(\hat{x}(t_0 + 6k), \hat{x}(t_0 + 6(k-1))), \quad k = 0, 1, \dots, K-1, \quad (7)$$

где F — обученное отображение; при $k = 0$ на вход идут два среза анализа. Конфигурации на 19 и 33 канала различаются только входным и выходным слоями, это около 9 тыс. параметров. Слои с признаками рёбер в кодировщике и декодировщике добавляют 0,6 млн, всего у итоговой модели 6,7 млн параметров.

Мультимасштабная расчётная сетка

В предложенной схеме глобальная и региональная сетки объединены в один граф, и внешней границы у модели нет. Из глобальной сетки 512×256 (шаг $0,703^\circ$) удалены узлы внутри области интереса. На их место поставлена регулярная решётка с шагом $0,25^\circ$ ($61 \times 41 = 2501$ узел) в границах $50\text{--}60^\circ$ с. ш., $83\text{--}98^\circ$ в. д. Итоговая расчётная сетка содержит 130 778 глобальных узлов и 2501 узел вставки, всего 133 279.

Рёбра между узлами и вершинами графа строятся поиском ближайших соседей по геоцентрическим координатам. Для узлов обоих разрешений процедура одна и та же, и переходную зону при построении связности никак не выделяют.

Соединение жёсткое: множества узлов не пересекаются, и значения собираются в один вектор состояния без весовой функции и сглаживания на стыке. Разрешения согласуются в ходе обмена сообщениями. Узлы по обе стороны стыка связаны рёбрами и обмениваются признаками на каждом из 12 раундов, так что переходный слой модель формирует сама при обучении.

Шаг графа 110–130 км, и детали мельче 200 км процессор не передаёт. Поэтому над вставкой с запасом 2° треугольники самого подробного уровня поделены на четыре, шаг там около 55 км. Добавляются 492 вершины, прежние рёбра сохраняются, а новые короткие рёбра образуют ещё один уровень графа. Обучаемых параметров сгущение не добавляет.

В методе Дэвиса [4] внутреннее решение в ходе интегрирования релаксируется к заданному извне полю, и без внешней границы и внешнего поля метод не работает. В предложен-

ной схеме нет ни того, ни другого. Прямая проверка бесшовности приведена на рис. 1: смена разрешения видна по размеру ячеек, а разрыва поля на склейке нет. Количественная диагностика по горизонтам дана в п. 4.6.

Вставка задана прямоугольником в координатах широта–долгота и сохраняет неоднородность шага по долготе (п. 3.1). Для 10° по широте отношение $\cos 50^\circ / \cos 60^\circ \approx 1,29$ невелико, но для более протяжённой области его придётся учитывать. Положение и размер вставки задаются четырьмя координатами, и остальная схема от выбора территории не зависит.

Стратегия дообучения

Региональную модель получают дообучением глобальной, которую обучили на той же выборке ERA5 в конфигурации 512×256 . После смены геометрии сетки веса кодировщика и декодировщика не согласованы с новой связностью, а процессор хранит динамику, выученную на глобальной задаче. Если сразу дообучать все параметры, большие градиенты от неадаптированных кодировщика и декодировщика разрушают эту динамику. Такой эффект называют катастрофическим забыванием.

Чтобы его избежать, дообучение идёт в две фазы.

1. Фаза 1 (первые E_f эпох): параметры процессора заморожены, обучаются только кодировщик и декодировщик. Эти блоки подстраиваются под новую геометрию и статистику региона.
2. Фаза 2 (оставшиеся эпохи): процессор размораживается и учится с темпом в 10 раз меньше базового.

В основной конфигурации $E_f = 10$, в конфигурациях для проверки стратегии (п. 4.5) $E_f = 6$. Базовый темп обучения равен 10^{-4} , оптимизатор Adam.

Длина авторегрессионной развёртки растёт по учебному плану. Обучение начинается с одношагового прогноза, затем число шагов K в (7) увеличивается до четырёх. Функция потерь считается по всем шагам развёртки.

Функция потерь считается по всем узлам расчётной сетки: потери только по области интереса портили поля за её пределами и через авторегрессию прогноз внутри неё. Рельеф и маска суши и моря в функцию потерь не входят.

Результаты: качество регионального прогноза

Условия оценки

Все оценки получены на одном окне верификации относительно реанализа ERA5 с шагом $0,25^\circ$ в узлах региональной вставки. Табл. 1 посчитана с широтными весами, табл. 3–5 с

равными: там конфигурации сравниваются между собой, а вес меняет ошибку не больше чем на 0,02 °C, одинаково у всех строк.

Объём выборки в таблицах разный. Табл. 1, 3 и 4 посчитаны на полной тестовой выборке из 1607 сроков (25.11.2019–30.12.2020, все четыре сезона). Табл. 2 и 5 посчитаны на первых 100 сроках периода (по 19.12.2019). Эта подвыборка приходится на холодное полугодие и труднее полной: у итоговой модели ошибка приземной температуры на суточном сроке равна 1,37 °C на 1607 сроках и 1,52 °C на 100. Табл. 2 к тому же получена на 19-канальной линии моделей (п. 4.3). Числа из разных таблиц сравнивать нельзя. Внутри одной таблицы все конфигурации посчитаны на одних сроках.

Качество итоговой модели

На суточном сроке ошибка приземной температуры у итоговой модели равна 1,37 °C по области [1,29; 1,43] и 1,24 °C во внутренней зоне [1,15; 1,33]. По остальным полям региона на том же сроке: ветер 0,63 и 0,61 м/с, давление на уровне моря 0,96 гПа, T850 0,82 °C, Z500 8,2 гпм. Аномальная корреляция приведена в п. 4.7, вместе с GraphCast и по той же климатологии.

Переход с 19 на 33 канала (уровни 250 и 1000 гПа, временной форсинг) уменьшает ошибку на 0,076 °C [0,063; 0,088] на +6 ч и на 0,174 °C [0,141; 0,210] на +24 ч. Весь выигрыш нельзя приписать новым уровням: 33-канальную конфигурацию дообучали от другой глобальной модели, которая сама точнее. Взвешенная конфигурация снижает ошибку приземной температуры относительно базовой 33-канальной ещё на 11,6 % (1,548 против 1,368 °C в среднем по горизонтам), а агрегатную успешность повышает на 1,17 п.п. с интервалом [+1,09; +1,24]. Часть этого выигрыша дают восемь эпох дополнительного обучения; при равном объёме обучения выигрыш равен 10,2 % (п. 4.4).

Итоговая модель получена из взвешенной конфигурации в четыре шага, показанных в табл. 1. Обучение вдвое дольше (16 эпох вместо 8) снижает ошибку приземной температуры на 1,2–1,8 %. Новые декодировщик и кодировщик (п. 3.2 и 4.8), по 8 эпох каждый, снижают ошибку температуры ещё на 4,2–4,5 %, давления на 5,6–7,6 %, ветра на 1,4–3,6 %. Все разности значимы на всех горизонтах. Сгущение графа (п. 3.3) сравнивали с дообучением той же длины без сгущения. Оно снижает ошибку ветра на 4,9–8,1 %, T850 на 2,8–4,9 % и приземной температуры на 1,3–2,3 %, агрегат растёт на 0,46 п.п. [+0,41; +0,51]. Геопотенциал на 500 гПа на +6 ч хуже на 1,2 %, на остальных горизонтах разница незначима. На проверочной выборке выигрыш тот же, и сгущение приняли только после этой проверки.

Что даёт единый граф

Чтобы оценить вклад мультимасштабной конструкции, прогноз глобальной модели с шагом 0,703° билинейно интерполировали в те же 2501 узел и оценили по той же истине. Опыт поставлен на 19-канальной линии моделей, и все строки табл. 2 посчитаны на одних и тех же 100 сроках тестовой выборки.

Единый граф точнее интерполяции по всем полям. По приземной температуре выигрыш умеренный (11 %), по зональному ветру и геопотенциалу на 500 гПа больше (40 и 37 %). Приземную температуру в узле сильнее определяют подсеточные факторы, которых не разрешает ни одна из сравниваемых конфигураций.

Веса в функции потерь

При обучении функция потерь равна среднеквадратической ошибке по нормированным каналам, усреднённой по узлам графа и шагам развёртки. Такое усреднение неявно задаёт, какие части задачи получают обучающий сигнал. В двух отношениях это распределение далеко от постановки задачи.

Первая диспропорция касается узлов. Узлов региональной вставки 2501 из 133 279, то есть 1,9 %, и почти весь обучающий сигнал приходится на глобальную часть графа, хотя публикуемые показатели относятся к вставке.

Вторая диспропорция касается каналов. Каждый канал нормирован на разброс самого поля, а модель предсказывает приращение за шаг, и разбросы приращений у каналов различаются на порядки. По обучающей выборке осадки дают 25,0 % функции потерь, приземная температура 0,46 %, геопотенциал на 500 гПа 0,15 %, приземное давление 0,02 %. Наибольшая доля больше наименьшей в 1218 раз, и вклад канала задаёт масштаб его изменчивости, а не значимость для прогноза.

В функцию потерь введены два веса. Узлы вставки получают вес W , остальные узлы единичный вес. Каналы получают веса, обратные квадрату разброса шестичасовой невязки по обучающей выборке. Все конфигурации табл. 3 получены одинаковым дожигом одной исходной модели, восемь эпох на полной развёртке с косинусным снижением темпа до нуля, и различаются только весами. Первая строка табл. 3 уже включает дожиг и поэтому не совпадает с базовой строкой табл. 1. При равном объёме обучения взвешивание даёт выигрыш 10,2 %, а разность в табл. 1 включает ещё и восемь эпох дожига.

Агрегат достигает максимума при промежуточном весе вставки. Когда доля вставки растёт с 1,7 до 34,1 %, улучшаются агрегат, и приземная температура, а дальнейший рост до 63,3 % агрегат ухудшает. Парный блочный бутстреп по общим срокам даёт для разности агрегатов при $W = 100$ и $W = 30$ величину $-0,05$ п.п. с интервалом $[-0,07; -0,03]$, который не покрывает ноль. Этот интервал учитывает изменчивость по срокам, но не по повторным обучениям, а изменчивость по обучениям оценена в 0,03 п.п. и сравнима с разностью. По приземной температуре максимума нет, ошибка убывает монотонно ($1,503 \rightarrow 1,445 \rightarrow 1,415 \rightarrow 1,407$). Поэтому максимум по агрегату относится к этой выборке и на метод не обобщается.

Последний столбец табл. 3 показывает цену выигрыша во вставке. Точность на глобальной части графа падает, и при $W = 100$ втрое сильнее, чем при $W = 30$ (0,0021 против 0,0007). Суточный прогноз внутри вставки зависит от притока извне, и оптимум определяется балансом между областью и её окружением.

С весами каналов агрегат снижается на 0,30 п.п. (интервал $[-0,32; -0,28]$), а приземная температура улучшается на 4,6 %, и все четыре интервала не накрывают ноль. Агрегат (3) сам равен среднему по каналам с равными весами, и для него равномерное взвешивание оптимально по построению. Как и в случае веса вставки, усиленные каналы отбирают ресурс у полей, от которых сами зависят.

Все следующие конфигурации, включая итоговую, используют $W = 30$ и выравнивающие веса каналов. Веса каналов вычислены по обучающей выборке и по тестовой не подбирались.

Стратегия дообучения и выбор контрольной точки

Стратегию дообучения исследовали на отдельной линии 19-канальных моделей. Сравнивались два варианта: заморозка процессора на первые 6 эпох и обучение всех параметров с первой эпохи. Сборка данных, начальное значение генератора и расписание у вариантов одинаковые. Эта линия предсказывает само поле, а не приращение. Агрегатная успешность этой линии (около 60 %) поэтому ниже, чем у 19-канальной строки табл. 1 (69,2 %), хотя ошибки приземной температуры близки. Числа табл. 1 и 4 относятся к разным моделям, и сравнивать их между собой нельзя.

Если сравнивать контрольные точки с наименьшей ошибкой на проверочной выборке, заморозка выигрывает до 0,14 °C на +24 ч. Эти точки достигнуты на разных эпохах, 16-й и 7-й, поэтому вместе со стратегиями сравниваются и объёмы обучения. При равном бюджете разность по приземной температуре исчезает, обе конфигурации дают 1,82 °C на сутки.

Контрольная точка эпохи 7, «лучшая» по одношаговой ошибке, в авторегрессионной развёртке проигрывает точке эпохи 16 той же конфигурации (1,96 против 1,82 °C). Базовая 33-канальная конфигурация ведёт себя так же. Состояние с минимальной ошибкой на проверочной выборке точнее на +6 ч (1,30 против 1,32 °C), но проигрывает на +18 и +24 ч, и смена знака значима с обеих сторон.

Минимум одношаговой ошибки на проверочной выборке выбирает модель, точную на измеряемом горизонте, и для многошагового прогноза этот критерий ненадёжен. Для многошагового прогноза надёжнее отбор по метрике на полной развёртке и сравнение стратегий при равном бюджете.

По приземной температуре при равном бюджете расписание заморозки на итог не влияет, 1,82 против 1,82 °C, интервалы $[1,72; 1,90]$ и $[1,71; 1,90]$ совпадают. По агрегату заморозка выигрывает 1,30 п.п. с интервалом $[+1,06; +1,59]$, который не накрывает ноль (60,8 против 59,5 %).

Адаптация процессора под регион всё же нужна. При заморозке на всё обучение ошибка на проверочной и на обучающей выборках выше на 7,5 %: модели не хватает свободы подстроить динамику.

Диагностика стыка

Первое положение работы касается стыка. Чтобы проверить его напрямую, ошибку приземной температуры итоговой модели посчитали по полосам расстояния до границы региональной вставки (табл. 5).

У границы остаётся слабый переходный слой. Ошибка там на 3–5 % выше, чем в полосе 100–200 км, на всех горизонтах (1,21 против 1,17 °C на +6 ч, 1,58 против 1,51 °C на +24 ч), и о полной бесшовности говорить нельзя. Превышение над глубиной области составляет 10, 9, 7 и 7 % по четырём горизонтам и с горизонтом не растёт. Неограниченный рост ошибки у границы составляет главную трудность региональных моделей с внешними граничными условиями, и у предложенной модели его нет.

Сразу за границей вставки, на глобальной части графа, ошибка на +24 ч равна 1,63 °C, а вдали от границы 1,72 и 1,77 °C.

Сравнение с глобальной моделью

Публикуемые метрики GraphCast [8] посчитаны по всему шару, больше половины которого занимает океан, и с региональными метриками напрямую несопоставимы. Для сравнения прогнозы GraphCast, реанализ и климатология взяты из архива WeatherBench 2 [12] в разрешении 0,25°. Из них вырезаны те же 2501 узел, и метрики посчитаны тем же кодом и с теми же широтными весами.

Архив GraphCast содержит только инициализации 00 и 12 UTC, и сравнение идёт на 802 общих сроках тестового окна. Правильность сопоставления проверена на прогнозе сохранения: по архиву он даёт по приземной температуре 6,71; 6,90; 4,02 и 4,45 °C, по полям этой работы 6,71; 6,90; 4,03 и 4,45 °C. Сравнение ограничено приземными полями: уровни лежат в архиве одним блоком.

GraphCast точнее по всем полям, сильнее всего по давлению на уровне моря. У GraphCast 36,7 млн параметров против 6,7 млн, разрешение 0,25° по всему шару против грубой глобальной сетки со вставкой, 37 уровней против четырёх и обучение на многих ускорителях против одного, так что разрыв ожидаем. Разрыв показывает цену перехода к вычислительной среде регионального подразделения, но предела самого подхода не определяет.

Аномальная корреляция мультимасштабной модели относительно той же климатологии равна 0,978 [0,972; 0,981] по области и 0,985 [0,980; 0,988] во внутренней зоне. По остальным полям области АСС равна 0,958 и 0,943 для составляющих ветра, 0,996 для давления, 0,992 для T850 и 0,998 для Z500.

Отпечаток сетки графа в прогнозе

Чтобы найти, где модель отстаёт от GraphCast, поле ошибки на каждом сроке разложили по масштабам (косинусное преобразование в окне вставки). У модели со свёрточными кодировщиком и декодировщиком отставание сосредоточено на масштабах 100–500 км, а в давлении

модель рисовала ложную рябь короче 100 км вдвое сильнее реанализа. Шаг графа 110–130 км, такие масштабы процессор не передаёт, их строят кодировщик и декодировщик.

Свёрточный слой смешивает вершины треугольника с весами, не зависящими от положения узла сетки, и вклад процессора скачет на сторонах треугольников. Для проверки сравнили средний квадрат разности ошибок у соседних узлов по разные стороны от ребра треугольника и внутри треугольника. Первый больше второго в 1,79 раза по приземной температуре и в 2,80 раза по давлению, а у GraphCast и у самого реанализа это отношение равно 1,1–1,2.

Новый декодировщик и поправка кодировщика (п. 3.2) снижают это отношение до 1,21 и 1,25. При равном объёме обучения новый декодировщик уменьшает ошибку приземной температуры на 1,8–2,0 % и давления на 3,0–4,4 %, но меридиональный ветер ухудшает на 1–2 %. Поправка кодировщика это исправляет: при равном объёме обучения она уменьшает ошибку ветра на 2,1–2,9 %, давления на 1,7–2,6 % и температуры на 0,5–0,7 %. Отставание от GraphCast по приземной температуре сократилось с 1,33 до 1,25 раза, по давлению с 1,79 до 1,64.

После этого основной разрыв оставался на масштабах 100–220 км. Сгущение графа над областью (п. 3.3) уменьшило отношение ошибок к GraphCast в этой полосе с 1,33 до 1,19 по приземной температуре и с 1,51 до 1,19 по меридиональному ветру. Теперь отставание по температуре и ветру почти одинаково на всех масштабах, 1,2–1,3 раза. По давлению половина оставшегося разрыва приходится на среднее давление над областью (п. 5.2).

Обсуждение, выводы и направления дальнейшей работы

Ограничения

Изменчивость между запусками оценена одной парой прогонов с разными начальными значениями генератора. Агрегат у них расходится на 0,03 п.п. (73,41 против 73,40 %), и осмысленны различия от десятых долей пункта. Вес целевой области $W = 30$, стратегию дообучения и итоговую конфигурацию выбрали по табл. 1, 3 и 4, которые посчитаны на тестовой выборке, а не на проверочной. Величины для итоговой модели поэтому слегка оптимистичны, хотя выигрыши между шагами табл. 1 (0,2–0,9 п.п.) намного больше межзапусковой изменчивости. Не помогли шум в авторегрессии, ансамбль дообученных состояний одной модели и развёртка в двенадцать шагов вместо четырёх.

Истинное поле здесь даёт реанализ, а не стационарные наблюдения. Реанализ сглаживает подсеточные эффекты, в том числе городской остров тепла, и оценки этой работы нельзя перенести на прогноз в точке станции без постобработки. Сравнения с оперативной моделью в работе нет, а в таком сравнении модель, обученная на реанализе и оцениваемая против него же, получает преимущество [12]. Результаты получены для одной территории и одного тестового окна. Прямого сравнения с региональной моделью с граничным форсингом [10] в работе нет.

Направления дальнейшей работы

Крупномасштабную ошибку давления определяет глобальная часть модели: четыре уровня по вертикали и 9 лет обучения против 37 уровней и около 40 лет у GraphCast. Вероятно, разрыв сократят более длинная обучающая выборка или дообучение от опубликованной модели GraphCast с шагом 1° . Для оперативной практики схему осталось проверить по данным сети станций и дополнить усвоением наблюдений в цикле выпуска прогноза.

Выводы

1. Построена и проверена мультимасштабная графовая нейронная сеть для регионального прогноза погоды. Глобальная и региональная части в ней соединены без отдельной процедуры сшивания полей. Диагностика стыка показывает слабый переходный слой: у границы ошибка на 3–5 % выше, чем в 100–200 км от неё, и с ростом горизонта превышение не растёт. Обучение и прогноз выполняются на одном ускорителе NVIDIA H100 80 ГБ: эпоха дообучения занимает около 2,8 ч, суточный прогноз меньше 5 с.
2. Кодировщик и декодировщик на свёрточных слоях графа отпечатывают в прогнозе треугольники графа. Передача сообщений с признаками рёбер убирает отпечаток. Вместе с более долгим обучением она снижает ошибку относительно исходной модели на 5,4–6,2 % по приземной температуре, на 6,7–8,9 % по давлению и на 2,3–4,7 % по ветру. Сгущение графа над областью до шага около 55 км снижает ошибку ветра ещё на 4,9–8,1 % и приземной температуры на 1,3–2,3 %.
3. Единый граф точнее интерполяции прогноза глобальной модели в узлы области по всем полям: на суточном сроке выигрыш составляет 11 % по приземной температуре, 26 % по давлению на уровне моря, 37 % по геопотенциалу на 500 гПа и 40 % по зональному ветру.
4. Отбор состояния модели по ошибке одношагового прогноза ненадёжен для многошагового прогноза. Расписание заморозки процессора на итоговую ошибку приземной температуры не влияет, но адаптация процессора нужна: без неё ошибка на проверочной выборке выше на 7,5 %.
5. При равномерном усреднении функции потерь узлы целевой области получают 1,7 % обучающего сигнала, приземная температура 0,46 %. Явные веса снижают ошибку приземной температуры на 10,2 % без изменения архитектуры и объёма обучения. При весе целевой области $W = 100$ (63 % функции потерь) ошибка на глобальной части графа растёт втрое сильнее, чем при $W = 30$, а через приток извне от этого прогноза зависит и сама область.

Список литературы

1. Толстых М.А., Шашкин В.В., Фадеев Р.Ю. и др. Система моделирования атмосферы для бесшовного прогноза. М.: Триада ЛТД, 2017. 166 с.
2. Battaglia P.W., Pascanu R., Lai M. et al. Interaction networks for learning about objects, relations and physics // *Advances in Neural Information Processing Systems (NIPS)*. 2016. Vol. 29. P. 4502–4510.
3. Bi K., Xie L., Zhang H. et al. Accurate medium-range global weather forecasting with 3D neural networks // *Nature*. 2023. Vol. 619, No. 7970. P. 533–538. DOI: 10.1038/s41586-023-06185-3.
4. Davies H.C. A lateral boundary formulation for multi-level prediction models // *Quarterly Journal of the Royal Meteorological Society*. 1976. Vol. 102, No. 432. P. 405–418. DOI: 10.1002/qj.49710243210.
5. Gao Y., Wu H., Shu R. et al. OneForecast: A universal framework for global and regional weather forecasting // *Proceedings of the 42nd International Conference on Machine Learning (ICML)*. PMLR, 2025. Vol. 267. P. 18658–18697.
6. Hersbach H., Bell B., Berrisford P. et al. The ERA5 global reanalysis // *Quarterly Journal of the Royal Meteorological Society*. 2020. Vol. 146, No. 730. P. 1999–2049. DOI: 10.1002/qj.3803.
7. Künsch H.R. The jackknife and the bootstrap for general stationary observations // *The Annals of Statistics*. 1989. Vol. 17, No. 3. P. 1217–1241. DOI: 10.1214/aos/1176347265.
8. Lam R., Sanchez-Gonzalez A., Willson M. et al. Learning skillful medium-range global weather forecasting // *Science*. 2023. Vol. 382, No. 6677. P. 1416–1421. DOI: 10.1126/science.adi2336.
9. Nipen T.N., Haugen H.H., Ingstad M.S. et al. Regional data-driven weather modeling with a global stretched grid // *Artificial Intelligence for the Earth Systems*. 2026. Vol. 5, No. 2. Art. e250001. DOI: 10.1175/AIES-D-25-0001.1.
10. Oskarsson J., Landelius T., Lindsten F. Graph-based neural weather prediction for limited area modeling // *arXiv:2309.17370*. 2023.
11. Pathak J., Subramanian S., Harrington P. et al. FourCastNet: A global data-driven high-resolution weather model using adaptive Fourier neural operators // *arXiv:2202.11214*. 2022.
12. Rasp S., Hoyer S., Merose A. et al. WeatherBench 2: A benchmark for the next generation of data-driven global weather models // *Journal of Advances in Modeling Earth Systems*. 2024. Vol. 16, No. 6. Art. e2023MS004019. DOI: 10.1029/2023MS004019.
13. Wijnands J.S., Van Ginderachter M., François B. et al. Data-driven regional weather forecasting: A comparison of stretched-grid and limited-area modelling // *Machine Learning with Applications*. 2026. Vol. 24. Art. 100887. DOI: 10.1016/j.mlwa.2026.100887.

References

1. Tolstykh M.A., Shashkin V.V., Fadeev R.Yu. et al. Sistema modelirovaniya atmosfery dlya besshovnogo prognoza [Atmosphere Modelling System for Seamless Prediction]. Moscow, Triada Ltd. Publ., 2017, 166 p. [in Russ.]
2. Battaglia P.W., Pascanu R., Lai M. et al. Interaction networks for learning about objects, relations and physics. *Advances in Neural Information Processing Systems (NIPS)*, 2016, vol. 29, pp. 4502–4510.
3. Bi K., Xie L., Zhang H. et al. Accurate medium-range global weather forecasting with 3D neural networks. *Nature*, 2023, vol. 619, no. 7970, pp. 533–538. DOI: 10.1038/s41586-023-06185-3.
4. Davies H.C. A lateral boundary formulation for multi-level prediction models. *Quarterly Journal of the Royal Meteorological Society*, 1976, vol. 102, no. 432, pp. 405–418. DOI: 10.1002/qj.49710243210.
5. Gao Y., Wu H., Shu R. et al. OneForecast: A universal framework for global and regional weather forecasting. *Proceedings of the 42nd International Conference on Machine Learning (ICML)*, PMLR, 2025, vol. 267, pp. 18658–18697.
6. Hersbach H., Bell B., Berrisford P. et al. The ERA5 global reanalysis. *Quarterly Journal of the Royal Meteorological Society*, 2020, vol. 146, no. 730, pp. 1999–2049. DOI: 10.1002/qj.3803.
7. Künsch H.R. The jackknife and the bootstrap for general stationary observations. *The Annals of Statistics*, 1989, vol. 17, no. 3, pp. 1217–1241. DOI: 10.1214/aos/1176347265.
8. Lam R., Sanchez-Gonzalez A., Willson M. et al. Learning skillful medium-range global weather forecasting. *Science*, 2023, vol. 382, no. 6677, pp. 1416–1421. DOI: 10.1126/science.adi2336.
9. Nipen T.N., Haugen H.H., Ingstad M.S. et al. Regional data-driven weather modeling with a global stretched grid. *Artificial Intelligence for the Earth Systems*, 2026, vol. 5, no. 2, art. e250001. DOI: 10.1175/AIES-D-25-0001.1.
10. Oskarsson J., Landelius T., Lindsten F. Graph-based neural weather prediction for limited area modeling. *arXiv:2309.17370*, 2023.
11. Pathak J., Subramanian S., Harrington P. et al. FourCastNet: A global data-driven high-resolution weather model using adaptive Fourier neural operators. *arXiv:2202.11214*, 2022.
12. Rasp S., Hoyer S., Merose A. et al. WeatherBench 2: A benchmark for the next generation of data-driven global weather models. *Journal of Advances in Modeling Earth Systems*, 2024, vol. 16, no. 6, art. e2023MS004019. DOI: 10.1029/2023MS004019.
13. Wijnands J.S., Van Ginderachter M., François B. et al. Data-driven regional weather forecasting: A comparison of stretched-grid and limited-area modelling. *Machine Learning with Applications*, 2026, vol. 24, art. 100887. DOI: 10.1016/j.mlwa.2026.100887.

Таблица 1. Ошибка приземной температуры (°C) по горизонтам и агрегатная успешность $\bar{S}$ (%) относительно прогноза сохранения согласно (3). Тестовая выборка 1607 сроков. Регион содержит 2501 узел, внутренняя зона 45 узлов.

Зона	Конфигурация	+6 ч	+12 ч	+18 ч	+24 ч	$\bar{S}$, %
Регион	19 каналов	1,41	1,67	1,75	1,85	69,2
	33 канала, базовая	1,33	1,55	1,61	1,68	73,2
	33 канала, взвешенная	1,19	1,38	1,41	1,47	74,4
	+ обучение 16 эпох	1,17	1,35	1,39	1,45	74,6
	+ декодировщик с признаками рёбер	1,14	1,31	1,35	1,41	75,5
	+ поправка кодировщика	1,13	1,29	1,33	1,39	76,0
	+ сгущение графа (итоговая)	1,09	1,25	1,30	1,37	76,6
Внутренняя зона	33 канала, базовая	1,21	1,41	1,47	1,53	74,5
	33 канала, взвешенная	1,06	1,23	1,26	1,31	75,4
итоговая		0,99	1,15	1,18	1,24	77,3

Table 1. RMSE of 2 m temperature (°C) by lead time and aggregate skill score S (%) per (3). 1607 initial times; region 2501 nodes, inner zone 45 nodes.

Таблица 2. Ошибка прогноза на горизонте +24 ч в узлах региональной вставки: прогноз сохранения, интерполяция прогноза глобальной модели и мультимасштабная модель. 19-канальная линия моделей, первые 100 сроков.

Поле	Прогноз сохранения	Глобальная 0,703° + интерполяция	Мультимасштабная	Выигрыш
t2m, °C	4,20	2,30	2,05	11 %
10u, м/с	2,71	0,99	0,59	40 %
msl, гПа	9,36	2,23	1,66	26 %
t@850, °C	6,27	1,48	1,23	17 %
z@500, гпм	88,5	21,0	13,3	37 %

Table 2. Error at +24 h at the insert nodes: persistence, interpolated global forecast, multiscale model. 19-channel model line, first 100 initial times.

Таблица 3. Влияние весов в функции потерь. Регион, 1607 сроков. Ошибка t2m усреднена по четырём горизонтам. Последний столбец показывает ошибку по всей сетке графа.

Конфигурация	Доля вставки в потерях	$\bar{S}$, %	t2m, °C	RMSE по сетке
Исходная (без весов, после дожига)	1,7 %	73,8	1,503	0,1696
Вес вставки $W = 10$	14,7 %	74,7	1,445	0,1697
Вес вставки $W = 30$	34,1 %	74,9	1,415	0,1703
Вес вставки $W = 100$	63,3 %	74,8	1,407	0,1717
$W = 30$ и веса каналов	34,1 %	74,6	1,350	0,1708

Table 3. Effect of loss weighting. Region, 1607 initial times; t2m averaged over four lead times, last column — error over the whole graph.

Таблица 4. Ошибка приземной температуры (°C) по региону и агрегатная успешность при разных способах отбора контрольной точки.

Конфигурация	Состояние	+6 ч	+12 ч	+18 ч	+24 ч	$\bar{S}$, %
С заморозкой	лучшая по val (эпоха 16)	1,34	1,59	1,71	1,82	60,8
Без заморозки	лучшая по val (эпоха 7)	1,36	1,65	1,81	1,96	59,9
Без заморозки	равный бюджет (эпоха 16)	1,35	1,62	1,72	1,82	59,5

Table 4. RMSE of 2 m temperature (°C) and aggregate skill score for different ways of selecting the checkpoint.

Таблица 5. Ошибка приземной температуры (°C) по расстоянию до границы вставки. Положительное расстояние отсчитывается внутрь вставки (шаг 0,25°), отрицательное наружу, на глобальную часть графа (шаг 0,703°).

Зона	Расстояние до границы, км	Узлов	+6 ч	+12 ч	+18 ч	+24 ч
Вставка 0,25°	0–25	278	1,21	1,44	1,52	1,58
	25–50	240	1,18	1,40	1,48	1,54
	50–100	414	1,19	1,41	1,49	1,56
	100–200	698	1,17	1,38	1,45	1,51
	200–1000	871	1,10	1,32	1,42	1,48
Глобальная 0,703°	–100...0	143	1,12	1,39	1,53	1,63
	–300...–100	308	1,23	1,50	1,64	1,72
	–1000...–300	1708	1,22	1,52	1,67	1,77

Table 5. RMSE of 2 m temperature (°C) by distance to the insert boundary. Positive — inside (0.25°), negative — outside (0.703°).

Таблица 6. Сравнение с GraphCast на одних узлах и сроках: 802 инициализации, 2501 узел, широтные веса. Ошибка осреднена по горизонтам +6...+24 ч, аномальная корреляция вычислена относительно климатологии WeatherBench 2 за 1990–2019 гг.

Поле	GraphCast	Мультимасштабная модель	Отношение
Приземная температура, °C	1,04	1,26	1,21
Зональная составляющая ветра, м/с	0,45	0,57	1,26
Меридиональная составляющая, м/с	0,44	0,56	1,26
Давление на уровне моря, гПа	0,47	0,75	1,61
Аномальная корреляция t2m	0,984	0,978	—

Table 6. Comparison with GraphCast on shared nodes and times: 802 initialisations, 2501 nodes, latitude weights. RMSE averaged over +6...+24 h; ACC against the WeatherBench 2 1990–2019 climatology.




Рис. 1. Прогноз приземной температуры на +24 ч в окрестности границы региональной вставки. Размер ячейки равен шагу сетки: 0,25° внутри вставки и 0,703° снаружи. Штриховой линией показана граница вставки.

Fig. 1. 2 m temperature forecast at +24 h near the insert boundary. Cell size follows the grid spacing, 0.25° inside and 0.703° outside; dashed line — the boundary.