

Мультимасштабная графовая нейросетевая модель регионального прогноза погоды

А.С. Табаков^{1,2}, А.В. Пененко¹, А.Б. Колкер^{3,4}

¹Институт вычислительной математики и математической геофизики СО РАН, г. Новосибирск, Россия; ²Новосибирский государственный университет, г. Новосибирск, Россия; ³Сибирский региональный научно-исследовательский гидрометеорологический институт, г. Новосибирск, Россия; ⁴Новосибирский государственный технический университет, г. Новосибирск, Россия

artur.tabakov11@gmail.com

Статья описывает графовую нейросетевую модель регионального прогноза погоды над югом Красноярского края. Глобальная сетка с шагом $0,703^\circ$ и региональная вставка с шагом $0,25^\circ$ образуют одну расчётную сетку из 133 279 узлов. Внешние граничные условия модели не нужны: поля на стыке двух разрешений согласуют обмен сообщениями по графу. У модели 6,7 млн обучаемых параметров, для обучения и прогноза хватает одного графического ускорителя. На независимой выборке из 1607 сроков за все сезоны среднеквадратическая ошибка прогноза приземной температуры на сутки равна $1,39^\circ\text{C}$, агрегатная успешность относительно инерционного прогноза 76,0 %, аномальная корреляция 0,976. На общих узлах и сроках ошибка по приземной температуре в 1,25 раза больше, чем у глобальной модели GraphCast, у которой в 5,5 раза больше параметров. Разложение ошибки по масштабам показало, что кодировщик и декодировщик на свёрточных слоях графа отпечатывают в прогнозе треугольники графа. Передача сообщений с признаками рёбер убирает отпечаток и вместе с более долгим обучением снижает ошибку относительно исходной модели на 7–9 % по давлению и на 5–6 % по температуре. При равномерном усреднении функции потерь целевые узлы и приземные каналы получают малую долю обучающего сигнала, а явные веса снижают ошибку приземной температуры на 10,2 %. Ошибка одношагового прогноза на проверочной выборке ненадёжна как критерий отбора модели многошагового прогноза.

Ключевые слова: численный прогноз погоды, графовая нейронная сеть, региональный прогноз, мультимасштабная сетка, авторегрессионный прогноз, функция потерь, машинное обучение

A multiscale graph neural network for regional weather forecasting

A.S. Tabakov^{1,2}, A.V. Penenko¹, A.B. Kolker^{3,4}

¹Institute of Computational Mathematics and Mathematical Geophysics SB RAS, Novosibirsk, Russia; ²Novosibirsk State University, Novosibirsk, Russia; ³Siberian Regional

Research Hydrometeorological Institute, Novosibirsk, Russia; ⁴Novosibirsk State Technical University, Novosibirsk, Russia

artur.tabakov11@gmail.com

A graph neural network model for regional weather forecasting over the south of Krasnoyarsk Krai is presented. A global mesh of 0.703° and a regional insert of 0.25° form a single graph of 133,279 nodes, so no lateral boundary conditions are needed: message passing reconciles the resolutions at the interface. The model has 6.7 million trainable parameters and runs on a single GPU. On 1607 independent initial times the 2-m temperature error is 1.39°C at the 24-h lead time, the aggregate skill score 76.0 % against persistence and the anomaly correlation 0.976. On shared nodes and initial times it trails the global GraphCast by a factor of 1.25 with 5.5 times fewer parameters. A scale decomposition of the error showed that an encoder and decoder built on graph convolutions imprint the mesh triangles on the forecast; message passing with edge features removes the imprint and, together with longer training, cuts the pressure error by 7–9 % and the temperature error by 5–6 %. Explicit loss weighting of the target nodes and channels cuts the 2-m temperature error by 10.2 %. The single-step validation error proves an unreliable criterion for selecting a model for multi-step forecasting.

Keywords: numerical weather prediction, graph neural network, regional forecasting, multiscale mesh, autoregressive forecast, loss function, machine learning

Введение

Численный прогноз погоды интегрирует уравнения гидротермодинамики атмосферы на сетке высокого разрешения. В России такой прогноз оперативно выпускают по полулагранжевой модели ПЛАВ [1]. Подход точен, но один глобальный прогноз на средние сроки занимает часы работы суперкомпьютера. Это ограничивает частоту обновления прогноза и размер ансамбля.

В 2022–2023 годах нейросетевые модели, обученные на архиве реанализа, догнали по точности оперативные модели крупнейших прогностических центров, а считают во много раз быстрее. GraphCast [8] на сроках от трёх до десяти суток превзошла оперативную систему Европейского центра по большинству переменных, сопоставимых результатов достигли Pangu-Weather [3] и FourCastNet [11]. В основе GraphCast лежит граф, узлы которого почти равномерно покрывают сферу (п. 3.1).

Большинство таких систем решает глобальную задачу, а на практике часто нужен более детальный прогноз над ограниченной территорией. Главная трудность такого перехода связана с граничными условиями: у краевых узлов вырезанной области нет корректного окружения. В классическом прогнозе поле в буферной зоне релаксируют к внешнему полю [4]. Для этого нужна отдельная процедура, которая вносит собственные погрешности.

Для нейросетевых региональных моделей предложено несколько способов обойти проблему границ. Архитектура Neural-LAM [10] получает граничный форсинг от глобальной

модели. В [9] разрешение плавно меняется на растянутой сетке. В [5] вложенные сетки обмениваются информацией между уровнями. Подходы с растянутой сеткой и с ограниченной областью сравнивали в [13].

Наша работа посвящена региональной модели прогноза над югом Красноярского края. Вклад работы состоит в следующем.

1. Мы построили единую мультимасштабную сетку. Глобальная сетка с шагом $0,703^\circ$ и региональная вставка с шагом $0,25^\circ$ соединены в один граф без внешних границ. Разрешения согласует обмен сообщениями, отдельная процедура сшивания не нужна. Сама идея мультимасштабного представления известна [5, 9]. Наш вариант отличается способом построения: узлы глобальной решётки внутри области заменены узлами вставки, и связность для всех узлов строится одинаково. Такая конструкция точнее интерполяции прогноза глобальной модели в те же узлы.
2. Модель намеренно сделана лёгкой: у неё 6,7 млн параметров, у моделей [3, 8, 9] от десятков до сотен миллионов. Для обучения и выпуска прогноза хватает одного графического ускорителя, и схема по силам вычислительной среде регионального управления гидрометслужбы.
3. Мы исследовали стратегию дообучения глобальной модели под региональную сетку и нашли методическую ловушку при отборе модели. Ошибка одношагового прогноза на проверочной выборке ненадёжна как критерий отбора, если модель строит многошаговый прогноз.
4. При равномерном усреднении функции потерь обучающий сигнал распределяется не так, как требует задача: узлы целевой области получают 1,7 % сигнала, приземная температура 0,46 %. Явные веса по узлам и каналам снижают ошибку приземной температуры на 10,2 %, архитектура и объём обучения остаются прежними.
5. Сравнение с GraphCast по масштабам показало, где модель теряет точность. Кодировщик и декодировщик на свёрточных слоях графа не учитывают положение узла сетки относительно вершин графа, и в прогнозе проступают границы треугольников. Передача сообщений с признаками рёбер, как в GraphCast, убирает этот отпечаток (п. 4.8).

Данные, базовая модель и метрики качества

Исходные данные

Модель обучали и оценивали на реанализе ERA5 Европейского центра среднесрочных прогнозов погоды [6] за 2010–2020 гг. с шагом 6 ч. Это 16 072 последовательных срока.

Состояние атмосферы описывают 19 полей. Семь из них приземные: температура воздуха на высоте 2 м, зональная и меридиональная составляющие ветра на высоте 10 м, давле-

ние на уровне моря, приземное давление, суммарные осадки за 6 ч и общее содержание водяного пара в столбе атмосферы. Два поля статические: геопотенциал поверхности и маска суши и моря. Модель получает статические поля на вход, но не прогнозирует, и в оценках они не участвуют. На уровнях 850 и 500 гПа заданы по пять полей: температура, две составляющие ветра, геопотенциал и удельная влажность. Вертикальную структуру описывает набор признаков узла, отдельных узлов по высоте нет.

Поля хранятся в физических единицах, геопотенциал ERA5 поделён на $g = 9,80665 \text{ м/с}^2$. Перед подачей в сеть каждый канал стандартизуется по среднему и разбросу за 2010–2020 гг., включая проверочную и тестовую части; влияние этих двух чисел на канал пренебрежимо мало.

На вход модель получает два последовательных срока (12 ч). Прогноз строится авторегрессионно с шагом 6 ч, оценки приводятся для горизонтов +6, +12, +18 и +24 ч.

Целевая область (регион) ограничена координатами 50–60° с. ш., 83–98° в. д. Область покрывает решётка с шагом 0,25° размером $61 \times 41 = 2501$ узел. Внутри региона выделена зона 55,5–56,5° с. ш., 92–94° в. д. (45 узлов) с Красноярском и окрестностями. Метрики считаются относительно полей ERA5 с шагом 0,25° в этих узлах, без интерполяции с более грубой сетки.

Итоговая модель использует 33 канала. К 19 полям в ней добавлены температура, обе составляющие ветра, геопотенциал и удельная влажность на уровнях 250 и 1000 гПа, а также четыре канала временного форсинга, синусы и косинусы часа суток и дня года. При развёртке форсинг и статические поля берутся из данных и в число прогностических каналов не входят.

Хронологическое разбиение выборки

Выборку разбили по времени, без перемешивания: обучающая часть предшествует проверочной, а та тестовой. Окно примера включает 2 входных среза и 4 прогностических шага, и из 16 072 сроков получается 16 067 примеров. Примеры разделили в долях 80, 10 и 10 %: 12 853 для обучения, 1607 для подбора гиперпараметров и отбора состояния модели, 1607 для тестов. Все публикуемые числа получены на тестовой выборке, которая охватывает полный годовой цикл. Сроки начала прогноза в обучающей выборке идут с 01.01.2010 06 UTC по 19.10.2018 06 UTC, в проверочной с 19.10.2018 12 UTC по 25.11.2019 00 UTC, в тестовой с 25.11.2019 06 UTC по 30.12.2020 18 UTC.

Базовая глобальная модель

Региональное дообучение начинается с глобальной модели. Глобальную модель обучили на тех же 19 полях на широтно-долготной сетке 512×256 узлов с шагом около 0,703°. Устроена она так же, как региональная (п. 3.2), но без слоёв с признаками рёбер в кодировщике и декодировщике. Меш объединяет уровни детализации 4 и 6. У глобальной модели 6,0 млн

обучаемых параметров, в шесть раз меньше, чем у GraphCast [8], и для обучения и оперативного выпуска прогноза хватает одного графического ускорителя.

Функция потерь равна среднеквадратической ошибке в стандартизованных переменных, осреднённой по узлам, каналам и горизонтам. Длина авторегрессионной развёртки при обучении растёт поэтапно. При подготовке работы мы нашли особенность реализации. При глобальном предобучении широтные веса узлов оказались почти равномерными, а при региональном дообучении (п. 3.4) применялись веса $\cos\varphi$, где φ обозначает широту узла. Региональное дообучение стартовало с промежуточного состояния глобальной модели с наименьшей ошибкой на проверочной выборке (эпоха 30 из 36 пройденных). На собственной сетке базовая модель даёт агрегатную успешность 65,4 % и ошибку приземной температуры 1,07 °C в среднем по горизонтам +6...+24 ч (200 сроков). С региональными числами работы эти значения сравнивать нельзя. Эти значения посчитаны по всему шару на грубой сетке 0,703°, где истинное поле сглажено, и на другой подвыборке сроков.

Метрики качества

Для канала c и горизонта τ среднеквадратическая ошибка считается в физических единицах канала:

$$\text{RMSE}_c(\tau) = \left[\frac{1}{N|G|} \sum_{n=1}^N \sum_{g \in G} (\hat{x}_{c,g}^{(n)}(\tau) - x_{c,g}^{(n)}(\tau))^2 \right]^{1/2}, \quad (1)$$

где N — число сроков ($N = 1607$ для тестовой выборки); G — множество оцениваемых узлов (2501 для региона, 45 для внутренней зоны); $\hat{x}$ — прогноз, x — значение реанализа, то есть истинное поле. Ошибка приводится в единицах переменной: °C, м/с, гПа, гПм. Узлы входят в сумму с весами $\cos\varphi$, нормированными на единичное среднее, как принято в протоколе верификации нейросетевых моделей прогноза [12]. Ячейка широтно-долготной сетки на 60° с. ш. вдвое уже экваториальной, и при равных весах высокие широты получили бы завышенный вклад. Для полосы 50–60° с. ш. наибольший вес больше наименьшего в 1,29 раза.

Прогноз сравнивается с двумя эталонами. Инерционный эталон переносит поля последнего входного среза t_0 на все горизонты без изменений, климатический описан ниже. Успешность относительно эталона вычисляется так:

$$S_c(\tau) = \left(1 - \frac{\text{RMSE}_c(\tau)}{\text{RMSE}^{\text{эт}}_c(\tau)} \right) \cdot 100 \%, \quad (2)$$

где $\text{RMSE}^{\text{эт}}$ — ошибка (1) для эталона на том же окне и той же маске узлов.

Инерционный эталон подходит не для всех полей. По приземной температуре его ошибка на горизонтах +6...+24 ч равна 4,99; 6,88; 5,88 и 4,42 °C: к суткам поле возвращается к тому же часу местного времени. Успешность относительно него немонотонна (76,4; 80,2; 76,2 и 67,0 %) и говорит об эталоне не меньше, чем о модели.

Климатический эталон от часа суток не зависит. Климатологию построили по обучающей части выборки разложением по гармоникам (три годовые и суточный ход), тестовые сроки в подгонку не входили. Ошибка этого эталона почти не меняется с горизонтом и равна 6,25 °C по приземной температуре, 5,42 °C по температуре на 850 гПа, 9,19 гПа по давлению на уровне моря, 2,05 и 1,74 м/с по составляющим ветра. На суточном сроке успешность итоговой модели относительно климатологии равна 77,7 % по приземной температуре, 84,2 % по T850, 89,4 % по давлению, 67,1 и 62,0 % по ветру.

Сводную оценку даёт агрегатный показатель. Единицы у каналов разные, и агрегат считается в стандартизованных переменных:

$$\overline{\text{RMSE}} = \left[\frac{1}{N |G| C H} \sum_n \sum_{g \in G} \sum_{c=1}^C \sum_{\tau} \left(\frac{x_{c,g}^{(n)}(\tau) - \bar{x}_{c,g}}{\sigma_c} \right)^2 \right]^{1/2}, \quad \bar{S} = \left(1 - \frac{\overline{\text{RMSE}}}{\overline{\text{RMSE}}^{\text{ЭТ}}} \right) \cdot 100 \%, \quad (3)$$

где σ_c — стандартное отклонение канала при стандартизации; C — число прогностических каналов (17 для 19-канальной конфигурации, 27 для 33-канальной: исключены два статических поля и четыре канала форсинга); $H = 4$. В табл. 1 столбец $\bar{S}$ осредняет разные наборы каналов, и строки с 19 и 33 каналами по нему сравнивать нельзя. Сравнимы поканальные значения и строки внутри одного набора.

Кроме ошибки, приводится аномальная корреляция. Эта мера показывает, насколько прогноз воспроизводит отклонение от обычного состояния:

$$\text{ACC}_c(\tau) = \frac{\sum_g w_g (x_{c,g}^{(n)} - \bar{x}_{c,g})(x_{c,g} - \bar{x}_{c,g})}{\left[\sum_g w_g (x_{c,g}^{(n)} - \bar{x}_{c,g})^2 \sum_g w_g (x_{c,g} - \bar{x}_{c,g})^2 \right]^{1/2}}, \quad (4)$$

где $\bar{x}$ — климатология ERA5 за 1990–2019 гг. из архива WeatherBench 2 [12], w_g — тот же широтный вес. Суммирование идёт сразу по узлам и срокам, то есть ACC равна отношению сумм, а не среднему посрочных корреляций. Из прогноза и истины вычитается климатология, а не среднее поля, чтобы убрать из обоих общий сезонный ход.

Точность оценок характеризуют доверительные интервалы блочного бутстрепа. Сроки идут через 6 ч и коррелированы внутри одного синоптического процесса, и при ресэмплинге берутся блоки подряд идущих сроков [7]. Интервалы строятся из посрочных вкладов в ошибку, и конфигурации сравниваются парно на общих сроках. Интервал учитывает изменчивость по срокам верификации, но не по повторным обучениям. Изменчивость по обучениям оценена в п. 5.1.

Мультимасштабная графовая модель и стратегия дообучения

Ограничения регулярной сетки на сфере

Значение переменной в узле через шесть часов определяется состоянием его окрестности, и чтобы модель выучила эту зависимость, окрестность должна везде быть примерно одного физического размера. На регулярной сетке это не так: при шаге $0,703^\circ$ расстояние между узлами вдоль параллели равно около 78 км на экваторе, 50 км на 50° с. ш. и 14 км на 80° с. ш., а у полюсов сетка вырождается.

Узлы почти равномерно распределяет по сфере икосаэдрическая триангуляция. Икосаэдр рекурсивно измельчают, деля каждый треугольник на четыре и проецируя новые вершины на сферу. У каждой вершины пять или шесть соседей, длины рёбер различаются мало, и окрестность узла везде отвечает близкому физическому масштабу.

Архитектура

Модель построена по схеме «кодировщик–процессор–декодировщик» [2, 8]. Узлы обмениваются информацией на графе, а входные и выходные поля остаются на регулярной сетке.

Кодировщик переносит значения из узлов сетки в вершины графа. Каждая вершина собирает признаки узлов, которые попали в её окрестность (радиус связи 0,6 в единицах длины ребра графа). Сначала это делают свёрточные слои графа, которые смешивают узлы с весами, зависящими только от числа связей. Затем слой передачи сообщений с признаками рёбер, как в GraphCast [8], добавляет поправку, которая зависит от смещения узла относительно вершины. Размерность скрытого представления вершины равна 256.

Процессор выполняет $R = 12$ раундов обмена сообщениями по рёбрам графа. Каждый раунд реализован блоком Interaction Network [2] и состоит из двух шагов. Сначала для каждого ребра ($i \rightarrow j$) вычисляется сообщение

$$m_{ij}^{(r)} = \phi_e(h_i^{(r-1)}, h_j^{(r-1)}, e_{ij}), \quad (5)$$

затем состояние вершины обновляется по среднему входящих сообщений:

$$h_j^{(r)} = \phi_v(h_j^{(r-1)}, \frac{1}{|N(j)|} \sum_{i \in N(j)} m_{ij}^{(r)}), \quad (6)$$

где $h_j^{(r)}$ — скрытое представление вершины j после раунда r (размерность 256); e_{ij} — постоянные признаки ребра (длина и три компоненты единичного вектора направления в геоцентрических координатах); $N(j)$ — вершины, соединённые с j ; ϕ_e и ϕ_v — персептроны с активацией Swish и послойной нормировкой. Веса раундов не разделяются, как и в [8].

Декодировщик переносит скрытые представления вершин обратно в узлы регулярной сетки и выдаёт приращения полей. Каждый узел сетки получает сообщения от трёх вершин треугольника графа, в который он попадает. Сообщение строится по формуле (5), где призна-

ки ребра задают смещение узла относительно вершины, так что вклад вершины зависит от положения узла внутри треугольника. Зачем это нужно, показано в п. 4.8.

Прогноз строится авторегрессионно с шагом 6 ч. Выход модели снова подаётся на её вход и даёт следующий срок:

$$\tilde{x}(t_0 + 6(k+1)) = F(\tilde{x}(t_0 + 6k), \tilde{x}(t_0 + 6(k-1))), \quad k = 0, 1, \dots, K-1, \quad (7)$$

где F — обученное отображение; при $k = 0$ на вход идут два среза анализа. Конфигурации на 19 и 33 канала различаются только входным слоем кодировщика и выходным слоем декодировщика. Разница составляет около 9 тыс. параметров (0,15 %), и после округления число параметров у них одинаково. Слои с признаками рёбер в кодировщике и декодировщике добавляют 0,6 млн, всего у итоговой модели 6,7 млн параметров.

Мультимасштабная расчётная сетка

Мы используем другой приём: глобальная и региональная сетки объединены в один граф, и внешней границы у модели нет. Из глобальной сетки 512×256 (шаг $0,703^\circ$) удалены узлы внутри области интереса. На их место поставлена регулярная решётка с шагом $0,25^\circ$ ($61 \times 41 = 2501$ узел) в границах $50\text{--}60^\circ$ с. ш., $83\text{--}98^\circ$ в. д. Итоговая расчётная сетка содержит 130 778 глобальных узлов и 2501 узел вставки, всего 133 279.

Рёбра между узлами и вершинами графа строятся поиском ближайших соседей по геоцентрическим координатам. Для узлов обоих разрешений процедура одна и та же, и переходную зону при построении связности никак не выделяют.

Соединение жёсткое: множества узлов не пересекаются, и значения собираются в один вектор состояния без весовой функции и сглаживания на стыке. Разрешения согласуются в ходе обмена сообщениями. Узлы по обе стороны стыка связаны рёбрами и обмениваются признаками на каждом из 12 раундов, так что переходный слой модель формирует сама при обучении.

В методе Дэвиса [4] внутреннее решение в ходе интегрирования релаксируется к заданному извне полю, и без внешней границы и внешнего поля метод не работает. В нашей схеме нет ни того, ни другого. Прямая проверка бесшовности приведена на рис. 1: смена разрешения видна по размеру ячеек, а разрыва поля на склейке нет. Количественная диагностика по горизонтам дана в п. 4.6.

Вставка задана прямоугольником в координатах широта–долгота и сохраняет неоднородность шага по долготе (п. 3.1). Для 10° по широте отношение $\cos 50^\circ / \cos 60^\circ \approx 1,29$ невелико, но для более протяжённой области его придётся учитывать.

Стратегия дообучения

Региональную модель получают дообучением глобальной, которую обучили на той же выборке ERA5 в конфигурации 512×256 . После смены геометрии сетки веса кодировщика и деко-

дировщика не согласованы с новой связностью, а процессор хранит динамику, выученную на глобальной задаче. Если сразу дообучать все параметры, большие градиенты от неадаптированных кодировщика и декодировщика разрушают эту динамику. Такой эффект называют катастрофическим забыванием.

Чтобы его избежать, дообучение идёт в две фазы.

1. Фаза 1 (первые E_f эпох): параметры процессора заморожены, обучаются только кодировщик и декодировщик. Эти блоки подстраиваются под новую геометрию и статистику региона.
2. Фаза 2 (оставшиеся эпохи): процессор размораживается и учится с темпом в 10 раз меньше базового.

В основной конфигурации $E_f = 10$, в конфигурациях для проверки стратегии (п. 4.5) $E_f = 6$. Базовый темп обучения равен 10^{-4} , оптимизатор Adam.

Длина авторегрессионной развёртки растёт по учебному плану. Обучение начинается с одношагового прогноза, затем число шагов K в (7) увеличивается до четырёх. Функция потерь считается по всем шагам развёртки.

Функция потерь считается по всем узлам расчётной сетки: потери только по области интереса портили поля за её пределами и через авторегрессию прогноз внутри неё. Рельеф и маска суши и моря в функцию потерь не входят.

Результаты: качество регионального прогноза

Условия оценки

Все оценки получены на одном окне верификации относительно реанализа ERA5 с шагом $0,25^\circ$ в узлах региональной вставки. Табл. 1 посчитана с широтными весами, табл. 3–5 с равными: там конфигурации сравниваются между собой, а вес меняет ошибку не больше чем на $0,02^\circ\text{C}$, одинаково у всех строк.

Объём выборки в таблицах разный. Табл. 1, 3 и 4 посчитаны на полной тестовой выборке из 1607 сроков (25.11.2019–30.12.2020, все четыре сезона). Табл. 2 и 5 посчитаны на первых 100 сроках периода (по 19.12.2019). Эта подвыборка приходится на холодное полугодие и труднее полной: у итоговой модели ошибка приземной температуры на суточном сроке равна $1,39^\circ\text{C}$ на 1607 сроках и $1,57^\circ\text{C}$ на 100. Табл. 2 к тому же получена на 19-канальной линии моделей (п. 4.3). Числа из разных таблиц сравнивать нельзя. Внутри одной таблицы все конфигурации посчитаны на одних сроках.

Качество итоговой модели

На суточном сроке ошибка приземной температуры у итоговой модели равна 1,39 °C по области [1,31; 1,45] и 1,25 °C во внутренней зоне [1,15; 1,35]. По остальным полям региона на том же сроке: ветер 0,68 и 0,66 м/с, давление на уровне моря 0,97 гПа, T850 0,85 °C, Z500 8,1 гпм. Аномальная корреляция приведена в п. 4.7 вместе со сравнением с глобальной моделью, чтобы обе модели оценивались по одной климатологии.

Переход с 19 на 33 канала (уровни 250 и 1000 гПа, временной форсинг) уменьшает ошибку на всех горизонтах: на 0,076; 0,121; 0,149 и 0,174 °C с интервалами [0,063; 0,088], [0,104; 0,138], [0,125; 0,171] и [0,141; 0,210]. Весь выигрыш нельзя приписать новым уровням: 33-канальную конфигурацию дообучали от другой глобальной модели, которая сама точнее. Взвешенная конфигурация снижает ошибку приземной температуры относительно базовой 33-канальной ещё на 11,6 % (1,548 против 1,368 °C в среднем по горизонтам), а агрегатную успешность повышает на 1,17 п.п. с интервалом [+1,09; +1,24]. Часть этого выигрыша дают восемь эпох дополнительного обучения; при равном объёме обучения выигрыш равен 10,2 % (п. 4.4).

Итоговая модель получена из взвешенной конфигурации в три шага, показанных в табл. 1. Обучение вдвое дольше (16 эпох вместо 8) снижает ошибку приземной температуры на 1,2–1,8 %: прежнюю модель недоучили. Новые декодировщик и кодировщик (п. 3.2 и 4.8), по 8 эпох каждый, снижают ошибку температуры ещё на 4,2–4,5 %, давления на 5,6–7,6 %, ветра на 1,4–3,6 %. Все разности значимы на всех горизонтах.

Что даёт единый граф

Чтобы оценить вклад мультимасштабной конструкции, прогноз глобальной модели с шагом 0,703° билинейно интерполировали в те же 2501 узел и оценили по той же истине. Опыт поставлен на 19-канальной линии моделей, и все строки табл. 2 посчитаны на одних и тех же 100 сроках тестовой выборки.

Единый граф точнее интерполяции по всем полям. По приземной температуре выигрыш умеренный (11 %), по ветру и геопотенциалу больше (37–40 %). Вероятная причина в том, что обмен сообщениями уточняет всё поле сразу. Приземную температуру в конкретном узле сильнее определяют подсеточные факторы, которых не разрешает ни одна из сравниваемых конфигураций.

Веса в функции потерь

При обучении функция потерь равна среднеквадратической ошибке по нормированным каналам, усреднённой по узлам графа и шагам развёртки. Такое усреднение неявно задаёт, какие части задачи получают обучающий сигнал. В двух отношениях это распределение далеко от постановки задачи.

Первая диспропорция касается узлов. Узлов региональной вставки 2501 из 133 279, то есть 1,9 %, и почти весь обучающий сигнал приходится на глобальную часть графа, хотя публикуемые показатели относятся к вставке.

Вторая диспропорция касается каналов. Каждый канал нормирован на разброс самого поля, а модель предсказывает приращение за шаг, и разбросы приращений у каналов различаются на порядки. По обучающей выборке осадки дают 25,0 % функции потерь, приземная температура 0,46 %, геопотенциал на 500 гПа 0,15 %, приземное давление 0,02 %. Наибольшая доля больше наименьшей в 1218 раз, и вклад канала задаёт масштаб его изменчивости, а не значимость для прогноза.

Мы ввели два веса. Узлы вставки получают вес W , остальные узлы единичный вес. Каналы получают веса, обратные квадрату разброса шестичасовой невязки по обучающей выборке. Все конфигурации табл. 3 получены одинаковым дожигом одной исходной модели, восемь эпох на полной развёртке с косинусным снижением темпа до нуля, и различаются только весами. Первая строка табл. 3 (1,503 °C) не совпадает со строкой «33 канала, базовая» табл. 1 (1,525 °C без широтных весов), потому что в неё уже включён дожиг. При равном объёме обучения взвешивание даёт выигрыш 10,2 %, а разность с табл. 1 (11,5 %) включает ещё и восемь эпох дожига.

Агрегат достигает максимума при промежуточном весе вставки. Когда доля вставки растёт с 1,7 до 34,1 %, улучшаются и агрегат, и приземная температура, а дальнейший рост до 63,3 % агрегат ухудшает. Парный блочный бутстреп по общим срокам даёт для разности агрегатов при $W = 100$ и $W = 30$ величину $-0,05$ п.п. с интервалом $[-0,07; -0,03]$, который не накрывает ноль. Этот интервал учитывает изменчивость по срокам, но не по повторным обучением, а изменчивость по обучением оценена в 0,03 п.п. и сравнима с разностью. По приземной температуре максимума нет, ошибка убывает монотонно (1,503 $\rightarrow$ 1,445 $\rightarrow$ 1,415 $\rightarrow$ 1,407). Максимум по агрегату мы поэтому относим к этой выборке и на метод не обобщаем.

Последний столбец табл. 3 показывает цену выигрыша во вставке. Точность на глобальной части графа падает, и при $W = 100$ втрое сильнее, чем при $W = 30$ (0,0021 против 0,0007). Суточный прогноз внутри вставки зависит от притока извне, и оптимум определяется балансом между областью и её окружением.

С весами каналов агрегат снижается на 0,30 п.п. (интервал $[-0,32; -0,28]$), а приземная температура улучшается на 4,6 %, и все четыре интервала не накрывают ноль. Агрегат (3) сам равен среднему по каналам с равными весами, и для него равномерное взвешивание оптимально по построению. Как и в случае веса вставки, усиленные каналы отбирают ресурс у полей, от которых сами зависят.

Все следующие конфигурации, включая итоговую, используют $W = 30$ и выравнивающие веса каналов. Веса каналов вычислены по обучающей выборке и по тестовой не подбирались. Целевые каналы для усиления отдельно не выбирали.

Стратегия дообучения и выбор контрольной точки

Стратегию дообучения исследовали на отдельной линии 19-канальных моделей. Сравнивались два варианта: заморозка процессора на первые 6 эпох и обучение всех параметров с первой эпохи. Сборка данных, начальное значение генератора и расписание у вариантов одинаковые. Эта линия предсказывает само поле, а не приращение. Агрегатная успешность этой линии (около 60 %) поэтому ниже, чем у 19-канальной строки табл. 1 (69,2 %), хотя ошибки приземной температуры близки. Числа табл. 1 и 4 относятся к разным моделям, и сравнивать их между собой нельзя.

Если сравнивать контрольные точки с наименьшей ошибкой на проверочной выборке, заморозка выигрывает до 0,14 °C на +24 ч. Но эти точки достигнуты на разных эпохах, 16-й и 7-й, и вместе со стратегиями сравниваются объёмы обучения. При равном бюджете разность по приземной температуре исчезает, обе конфигурации дают 1,82 °C на сутки.

Контрольная точка эпохи 7, «лучшая» по одношаговой ошибке, в авторегрессионной развёртке проигрывает точке эпохи 16 той же конфигурации (1,96 против 1,82 °C). Базовая 33-канальная конфигурация ведёт себя так же. Состояние с минимальной ошибкой на проверочной выборке точнее на +6 ч (1,30 против 1,32 °C), но проигрывает на +18 и +24 ч, и смена знака значима с обеих сторон.

Минимум одношаговой ошибки на проверочной выборке выбирает модель, точную на измеряемом горизонте, и для многошагового прогноза этот критерий ненадёжен. Отбирать модель следует по метрике на полной развёртке, а стратегии сравнивать при равном бюджете.

По приземной температуре при равном бюджете расписание заморозки на итог не влияет, 1,82 против 1,82 °C, интервалы [1,72; 1,90] и [1,71; 1,90] совпадают. По агрегату заморозка выигрывает 1,30 п.п. с интервалом [+1,06; +1,59], который не накрывает ноль (60,8 против 59,5 %).

Агрегат и поканальные значения расходятся второй раз после п. 4.4, и причина та же: вклад канала в агрегат определяется отношением его ошибки к разбросу поля, а не его значимостью. Полный отчёт о верификации содержит и агрегат, и поканальные значения целевых полей.

Адаптация процессора под регион всё же нужна. При заморозке на всё обучение ошибка на проверочной и на обучающей выборках выше на 7,5 %, то есть модели не хватает свободы подстроить динамику.

Диагностика стыка

Главное утверждение работы состоит в том, что жёсткая склейка узлов не требует отдельной процедуры сшивания. Чтобы проверить его напрямую, ошибку приземной температуры итоговой модели посчитали по полосам расстояния до границы региональной вставки (табл. 5).

У границы остаётся слабый переходный слой. Ошибка там на 3–4 % выше, чем в полосе 100–200 км, на всех горизонтах (1,24 против 1,20 °C на +6 ч, 1,62 против 1,56 °C на +24 ч),

и о полной бесшовности говорить нельзя. Превышение над глубиной области составляет 10, 8, 6 и 6 % по четырём горизонтам и с горизонтом не растёт. Неограниченный рост ошибки у границы составляет главную трудность региональных моделей с внешними граничными условиями, и у нашей модели его нет.

Сразу за границей вставки, на глобальной части графа, ошибка на +24 ч равна 1,64 °С, а вдали от границы 1,75 и 1,76 °С. Склейка создаёт переходный слой ограниченной величины и не требует отдельной процедуры сшивания полей.

Сравнение с глобальной моделью

Публикуемые метрики GraphCast [8] относятся ко всему шару, где больше половины площади занимает океан с более точным прогнозом, и с нашими напрямую несопоставимы. Мы взяли прогнозы GraphCast, реанализ и климатологию из архива WeatherBench 2 [12] в разрешении 0,25°, вырезали те же 2501 узел и посчитали метрики тем же кодом и с теми же широтными весами.

Архив GraphCast содержит только инициализации 00 и 12 UTC, и сравнение идёт на 803 общих сроках тестового окна. Правильность сопоставления проверена на инерционном прогнозе: по архиву он даёт по приземной температуре 6,71; 6,90; 4,02 и 4,45 °С, нашим кодом 6,71; 6,90; 4,03 и 4,45 °С. Сравнение ограничено приземными полями: уровни лежат в архиве одним блоком.

GraphCast точнее по всем полям, сильнее всего по давлению на уровне моря. У GraphCast 36,7 млн параметров против 6,7 млн, разрешение 0,25° по всему шару против грубой глобальной сетки со вставкой, 37 уровней против четырёх и обучение на многих ускорителях против одного, так что разрыв ожидаем. Он показывает цену перехода к вычислительной среде регионального подразделения, но предела самого подхода не определяет.

Аномальная корреляция нашей модели относительно той же климатологии равна 0,976 [0,971; 0,980] по области и 0,984 [0,979; 0,988] во внутренней зоне. По остальным полям области она равна 0,950 и 0,931 для составляющих ветра, 0,996 для давления, 0,991 для T850 и 0,998 для Z500.

Отпечаток сетки графа в прогнозе

Чтобы найти, где модель отстаёт от GraphCast, мы разложили поле ошибки на каждом сроке по масштабам (косинусное преобразование в окне вставки). У модели со свёрточными кодировщиком и декодировщиком отставание сосредоточено на масштабах 100–500 км, а в давлении модель рисовала ложную рябь короче 100 км вдвое сильнее реанализа. Шаг графа около 110 км, такие масштабы процессор не передаёт, их строят кодировщик и декодировщик.

Свёрточный слой смешивает вершины треугольника с весами, не зависящими от положения узла сетки, и вклад процессора скачет на сторонах треугольников. Мы сравнили средний квадрат разности ошибок у соседних узлов по разные стороны от ребра треугольни-

ка и внутри треугольника. Первый больше второго в 1,79 раза по приземной температуре и в 2,80 раза по давлению, а у GraphCast и у самого реанализа это отношение равно 1,1–1,2.

Новый декодировщик и поправка кодировщика (п. 3.2) снижают это отношение до 1,21 и 1,25. При равном объёме обучения новый декодировщик уменьшает ошибку приземной температуры на 1,8–2,0 % и давления на 3,0–4,4 %, но меридиональный ветер ухудшает на 1–2 %. Поправка кодировщика это исправляет: при равном объёме обучения она уменьшает ошибку ветра на 2,1–2,9 %, давления на 1,7–2,6 % и температуры на 0,5–0,7 %. Отставание от GraphCast по приземной температуре сократилось с 1,33 до 1,25 раза, по давлению с 1,79 до 1,64.

Обсуждение, выводы и направления дальнейшей работы

Модель улучшали двумя путями. Первый не трогает архитектуру: веса функции потерь перераспределяют обучающий сигнал. Оба веса улучшают целевую часть задачи за счёт остальной. Большой вес вставки ухудшает прогноз на глобальной части графа, а через приток извне от этого прогноза зависит и сама вставка. Веса каналов улучшают приземную температуру и снижают агрегат по всем каналам. Вторым путём меняет перенос полей между сеткой и графом, и найти его помогло сравнение с GraphCast по масштабам.

Ограничения

Изменчивость между запусками оценена одной парой прогонов с разными начальными значениями генератора. Агрегат у них расходится на 0,03 п.п. (73,41 против 73,40 %), и различия осмысленны начиная с десятых долей пункта. Вес целевой области $W = 30$, стратегию дообучения и итоговую конфигурацию выбрали по табл. 1, 3 и 4, которые посчитаны на тестовой выборке, а не на проверочной. Величины для итоговой модели поэтому слегка оптимистичны, хотя выигрыши между шагами табл. 1 (0,2–0,9 п.п.) намного больше межзапусковой изменчивости. К весам каналов эта оговорка не относится: их вычислили по обучающей выборке.

Не помогли шум в авторегрессии, ансамбль дообученных состояний одной модели и развёртка в двенадцать шагов вместо четырёх.

Истинное поле здесь даёт реанализ, а не стационарные наблюдения. Реанализ сглаживает подсеточные эффекты, в том числе городской остров тепла, и наши оценки нельзя перенести на прогноз в точке станции без постобработки. С оперативной моделью мы не сравнивались, а в таком сравнении модель, обученная на реанализе и оцениваемая против него же, получает преимущество [12]. Результаты получены для одной территории и одного тестового окна. Прямого сравнения с региональной моделью с граничным форсингом [10] в работе нет.

Направления дальнейшей работы

Оставшееся отставание от GraphCast по-прежнему сосредоточено на масштабах 100–220 км. Процессор увидит эти масштабы, если сгустить граф над регионом до шага около 55 км. Второе направление связано с данными: модель видела 9 лет реанализа, GraphCast около 40. Вероятно, разрыв сократят более длинная обучающая выборка или дообучение от опубликованной модели GraphCast с шагом 1°. Для оперативной практики схему осталось проверить по данным сети станций и дополнить усвоением наблюдений в цикле выпуска прогноза.

Выводы

1. Построена и проверена мультимасштабная графовая нейронная сеть для регионального прогноза погоды. Глобальная и региональная части в ней соединены без отдельной процедуры сшивания полей. Диагностика стыка показывает слабый переходный слой: у границы ошибка на 3–4 % выше, чем в 100–200 км от неё, и с ростом горизонта превышение не растёт. Для обучения и расчёта хватает одного графического ускорителя.
2. Кодировщик и декодировщик на свёрточных слоях графа отпечатывают в прогнозе треугольники графа. Передача сообщений с признаками рёбер убирает отпечаток. Вместе с более долгим обучением она снижает ошибку относительно исходной модели на 5,4–6,2 % по приземной температуре, на 6,7–8,9 % по давлению и на 2,3–4,7 % по ветру.
3. Единый граф точнее интерполяции прогноза глобальной модели в узлы области по всем полям: выигрыш составляет 11 % по приземной температуре и 37–40 % по ветру и геопотенциалу.
4. Отбор состояния модели по ошибке одношагового прогноза ненадёжен для многошагового прогноза. Расписание заморозки процессора на итоговую ошибку приземной температуры не влияет, но адаптация процессора нужна: без неё ошибка на проверочной выборке выше на 7,5 %.
5. Один агрегатный показатель скрывает разное поведение модели по отдельным полям. Полные результаты верификации приводятся по каждому целевому полю отдельно.
6. При равномерном усреднении функции потерь узлы целевой области получают 1,7 % обучающего сигнала, приземная температура 0,46 %. Явные веса снижают ошибку приземной температуры на 10,2 % без изменения архитектуры и объёма обучения. При слишком большом весе целевой области ухудшается прогноз на глобальной части графа, а через приток извне от этого прогноза зависит и сама область.

Список литературы

1. Толстых М.А., Шашкин В.В., Фадеев Р.Ю. и др. Система моделирования атмосферы для бесшовного прогноза. М.: Триада ЛТД, 2017. 166 с.

2. Battaglia P.W., Pascanu R., Lai M. et al. Interaction networks for learning about objects, relations and physics // *Advances in Neural Information Processing Systems (NIPS)*. 2016. Vol. 29. P. 4502–4510.
3. Bi K., Xie L., Zhang H. et al. Accurate medium-range global weather forecasting with 3D neural networks // *Nature*. 2023. Vol. 619, No. 7970. P. 533–538. DOI: 10.1038/s41586-023-06185-3.
4. Davies H.C. A lateral boundary formulation for multi-level prediction models // *Quarterly Journal of the Royal Meteorological Society*. 1976. Vol. 102, No. 432. P. 405–418. DOI: 10.1002/qj.49710243210.
5. Gao Y., Wu H., Shu R. et al. OneForecast: A universal framework for global and regional weather forecasting // *Proceedings of the 42nd International Conference on Machine Learning (ICML)*. PMLR, 2025. Vol. 267. P. 18658–18697.
6. Hersbach H., Bell B., Berrisford P. et al. The ERA5 global reanalysis // *Quarterly Journal of the Royal Meteorological Society*. 2020. Vol. 146, No. 730. P. 1999–2049. DOI: 10.1002/qj.3803.
7. Künsch H.R. The jackknife and the bootstrap for general stationary observations // *The Annals of Statistics*. 1989. Vol. 17, No. 3. P. 1217–1241. DOI: 10.1214/aos/1176347265.
8. Lam R., Sanchez-Gonzalez A., Willson M. et al. Learning skillful medium-range global weather forecasting // *Science*. 2023. Vol. 382, No. 6677. P. 1416–1421. DOI: 10.1126/science.adi2336.
9. Nipen T.N., Haugen H.H., Ingstad M.S. et al. Regional data-driven weather modeling with a global stretched grid // *Artificial Intelligence for the Earth Systems*. 2026. Vol. 5, No. 2. Art. e250001. DOI: 10.1175/AIES-D-25-0001.1.
10. Oskarsson J., Landelius T., Lindsten F. Graph-based neural weather prediction for limited area modeling // *arXiv:2309.17370*. 2023.
11. Pathak J., Subramanian S., Harrington P. et al. FourCastNet: A global data-driven high-resolution weather model using adaptive Fourier neural operators // *arXiv:2202.11214*. 2022.
12. Rasp S., Hoyer S., Merose A. et al. WeatherBench 2: A benchmark for the next generation of data-driven global weather models // *Journal of Advances in Modeling Earth Systems*. 2024. Vol. 16, No. 6. Art. e2023MS004019. DOI: 10.1029/2023MS004019.
13. Wijnands J.S., Van Ginderachter M., François B. et al. Data-driven regional weather forecasting: A comparison of stretched-grid and limited-area modelling // *Machine Learning with Applications*. 2026. Vol. 24. Art. 100887. DOI: 10.1016/j.mlwa.2026.100887.

References

1. Tolstykh M.A., Shashkin V.V., Fadeev R.Yu. et al. Sistema modelirovaniya atmosfery dlya besshovnogo prognoza [Atmosphere Modelling System for Seamless Prediction]. Moscow, Triada Ltd. Publ., 2017, 166 p. [in Russ.]

2. Battaglia P.W., Pascanu R., Lai M. et al. Interaction networks for learning about objects, relations and physics. *Advances in Neural Information Processing Systems (NIPS)*, 2016, vol. 29, pp. 4502–4510.
3. Bi K., Xie L., Zhang H. et al. Accurate medium-range global weather forecasting with 3D neural networks. *Nature*, 2023, vol. 619, no. 7970, pp. 533–538. DOI: 10.1038/s41586-023-06185-3.
4. Davies H.C. A lateral boundary formulation for multi-level prediction models. *Quarterly Journal of the Royal Meteorological Society*, 1976, vol. 102, no. 432, pp. 405–418. DOI: 10.1002/qj.49710243210.
5. Gao Y., Wu H., Shu R. et al. OneForecast: A universal framework for global and regional weather forecasting. *Proceedings of the 42nd International Conference on Machine Learning (ICML)*, PMLR, 2025, vol. 267, pp. 18658–18697.
6. Hersbach H., Bell B., Berrisford P. et al. The ERA5 global reanalysis. *Quarterly Journal of the Royal Meteorological Society*, 2020, vol. 146, no. 730, pp. 1999–2049. DOI: 10.1002/qj.3803.
7. Künsch H.R. The jackknife and the bootstrap for general stationary observations. *The Annals of Statistics*, 1989, vol. 17, no. 3, pp. 1217–1241. DOI: 10.1214/aos/1176347265.
8. Lam R., Sanchez-Gonzalez A., Willson M. et al. Learning skillful medium-range global weather forecasting. *Science*, 2023, vol. 382, no. 6677, pp. 1416–1421. DOI: 10.1126/science.adi2336.
9. Nipen T.N., Haugen H.H., Ingstad M.S. et al. Regional data-driven weather modeling with a global stretched grid. *Artificial Intelligence for the Earth Systems*, 2026, vol. 5, no. 2, art. e250001. DOI: 10.1175/AIES-D-25-0001.1.
10. Oskarsson J., Landelius T., Lindsten F. Graph-based neural weather prediction for limited area modeling. *arXiv:2309.17370*, 2023.
11. Pathak J., Subramanian S., Harrington P. et al. FourCastNet: A global data-driven high-resolution weather model using adaptive Fourier neural operators. *arXiv:2202.11214*, 2022.
12. Rasp S., Hoyer S., Merose A. et al. WeatherBench 2: A benchmark for the next generation of data-driven global weather models. *Journal of Advances in Modeling Earth Systems*, 2024, vol. 16, no. 6, art. e2023MS004019. DOI: 10.1029/2023MS004019.
13. Wijnands J.S., Van Ginderachter M., François B. et al. Data-driven regional weather forecasting: A comparison of stretched-grid and limited-area modelling. *Machine Learning with Applications*, 2026, vol. 24, art. 100887. DOI: 10.1016/j.mlwa.2026.100887.

Таблица 1. Ошибка приземной температуры (°C) по горизонтам и агрегатная успешность $\bar{S}$ (%) согласно (3). Тестовая выборка 1607 сроков. Регион содержит 2501 узел, внутренняя зона 45 узлов.

Зона	Конфигурация	+6 ч	+12 ч	+18 ч	+24 ч	$\bar{S}$, %
Регион	19 каналов	1,41	1,67	1,75	1,85	69,2
	33 канала, базовая	1,33	1,55	1,61	1,68	73,2
	33 канала, взвешенная	1,19	1,38	1,41	1,47	74,4
	+ обучение 16 эпох	1,17	1,35	1,39	1,45	74,6
	+ декодировщик с признаками рёбер	1,14	1,31	1,35	1,41	75,5
	+ поправка кодировщика (итоговая)	1,13	1,29	1,33	1,39	76,0
Внутренняя зона	33 канала, базовая	1,21	1,41	1,47	1,53	74,5
	33 канала, взвешенная	1,06	1,23	1,26	1,31	75,4
	итоговая	1,00	1,16	1,19	1,25	77,2

Table 1. RMSE of 2 m temperature (°C) by lead time and aggregate skill score S (%) per (3). 1607 initial times; region 2501 nodes, inner zone 45 nodes.

Таблица 2. Ошибка прогноза на горизонте +24 ч в узлах региональной вставки: инерционный прогноз, интерполяция прогноза глобальной модели и мультимасштабная модель. 19-канальная линия моделей, первые 100 сроков.

Поле	Инерционный прогноз	Глобальная 0,703° + интерполяция	Мультимасштабная	Выигрыш
t2m, °C	4,20	2,30	2,05	11 %
10u, м/с	2,71	0,99	0,59	40 %
msl, гПа	9,36	2,23	1,66	26 %
t@850, °C	6,27	1,48	1,23	17 %
z@500, гпм	88,5	21,0	13,3	37 %

Table 2. Error at +24 h at the insert nodes: persistence, interpolated global forecast, multiscale model. 19-channel model line, first 100 initial times.

Таблица 3. Влияние весов в функции потерь. Регион, 1607 сроков. Ошибка t2m усреднена по четырём горизонтам. Последний столбец показывает ошибку по всей сетке графа.

Конфигурация	Доля вставки в потерях	$\bar{S}$, %	t2m, °C	RMSE по сетке
Исходная (без весов, после дожига)	1,7 %	73,8	1,503	0,1696
Вес вставки $W = 10$	14,7 %	74,7	1,445	0,1697
Вес вставки $W = 30$	34,1 %	74,9	1,415	0,1703
Вес вставки $W = 100$	63,3 %	74,8	1,407	0,1717
$W = 30$ и веса каналов	34,1 %	74,6	1,350	0,1708

Table 3. Effect of loss weighting. Region, 1607 initial times; t2m averaged over four lead times, last column — error over the whole graph.

Таблица 4. Ошибка приземной температуры (°C) по региону и агрегатная успешность при разных способах отбора контрольной точки.

Конфигурация	Состояние	+6 ч	+12 ч	+18 ч	+24 ч	$\bar{S}$, %
С заморозкой	лучшая по val (эпоха 16)	1,34	1,59	1,71	1,82	60,8
Без заморозки	лучшая по val (эпоха 7)	1,36	1,65	1,81	1,96	59,9
Без заморозки	равный бюджет (эпоха 16)	1,35	1,62	1,72	1,82	59,5

Table 4. RMSE of 2 m temperature (°C) and aggregate skill score for different ways of selecting the checkpoint.

Таблица 5. Ошибка приземной температуры (°C) по расстоянию до границы вставки. Положительное расстояние отсчитывается внутрь вставки (шаг 0,25°), отрицательное наружу, на глобальную часть графа (шаг 0,703°).

Зона	Расстояние до границы, км	Узлов	+6 ч	+12 ч	+18 ч	+24 ч
Вставка 0,25°	0–25	278	1,24	1,48	1,56	1,62
	25–50	240	1,21	1,44	1,52	1,58
	50–100	414	1,23	1,46	1,54	1,61
	100–200	698	1,20	1,43	1,50	1,56
	200–1000	871	1,13	1,37	1,47	1,53
Глобальная 0,703°	–100...0	143	1,13	1,41	1,54	1,64
	–300...–100	308	1,23	1,51	1,66	1,75
	–1000...–300	1708	1,22	1,51	1,66	1,76

Table 5. RMSE of 2 m temperature (°C) by distance to the insert boundary. Positive — inside (0.25°), negative — outside (0.703°).

Таблица 6. Сравнение с GraphCast на одних узлах и сроках: 803 инициализации, 2501 узел, широтные веса. Ошибка осреднена по горизонтам +6...+24 ч, аномальная корреляция вычислена относительно климатологии WeatherBench 2 за 1990–2019 гг.

Поле	GraphCast	Наша модель	Отношение
Приземная температура, °C	1,04	1,30	1,25
Зональная составляющая ветра, м/с	0,45	0,62	1,37
Меридиональная составляющая, м/с	0,44	0,61	1,39
Давление на уровне моря, гПа	0,47	0,77	1,64
Аномальная корреляция t2m	0,984	0,976	—

Table 6. Comparison with GraphCast on shared nodes and times: 803 initialisations, 2501 nodes, latitude weights. RMSE averaged over +6...+24 h; ACC against the WeatherBench 2 1990–2019 climatology.




Рис. 1. Прогноз приземной температуры на +24 ч в окрестности границы региональной вставки. Размер ячейки равен шагу сетки: 0,25° внутри вставки и 0,703° снаружи. Штриховой линией показана граница вставки.

Fig. 1. 2 m temperature forecast at +24 h near the insert boundary. Cell size follows the grid spacing, 0.25° inside and 0.703° outside; dashed line — the boundary.