

Мультимасштабная графовая нейросетевая модель регионального прогноза погоды с усвоением данных наблюдений

А.С. Табаков^{1,2}, А.В. Пененко¹

¹Институт вычислительной математики и математической геофизики СО РАН, г. Новосибирск, Россия; ²Новосибирский государственный университет, г. Новосибирск, Россия
artur.tabakov11@gmail.com

Представлена региональная нейросетевая модель прогноза погоды над югом Красноярского края, построенная на графовом представлении атмосферного состояния. Глобальная расчётная сетка с шагом $0,703^\circ$ и региональная вставка с шагом $0,25^\circ$ объединены в единую расчётную сетку из 133 279 узлов, образующую единый граф, что устраняет необходимость задания внешних граничных условий: согласование разрешений на стыке достигается механизмом обмена сообщениями в процессе обучения. Модель содержит 5,9 млн обучаемых параметров, обучение и выпуск прогноза выполняются на одном графическом ускорителе. Оценка на независимой выборке из 1607 сроков (все сезоны) показала среднеквадратическую ошибку прогноза приземной температуры $1,46^\circ\text{C}$ на суточном сроке при агрегатной успешности 74,6 % относительно инерционного прогноза. Показано, что распределение обучающего сигнала по узлам графа и по каналам, возникающее при равномерном усреднении функции потерь, далеко от постановки задачи; явное взвешивание снижает ошибку приземной температуры на 10,2 % в среднем по горизонтам при равном объёме обучения (12,0 % на суточном сроке) без изменения архитектуры. В контрольном эксперименте с равным бюджетом обучения установлено, что ошибка на проверочной выборке при одношаговом прогнозе является ненадёжным критерием отбора модели для многошагового прогноза. Исследовано усвоение наблюдений методами релаксации и оптимальной интерполяции внутри авторегрессионного цикла: непрерывное усвоение ограничивает рост ошибки при работе цикла до 336 ч, тогда как «память» модели о прекратившемся поступлении наблюдений составляет порядка суток.

Ключевые слова: численный прогноз погоды, графовая нейронная сеть, региональный прогноз, мультимасштабная сетка, усвоение данных, оптимальная интерполяция, авторегрессионный прогноз, машинное обучение

A multiscale graph neural network for regional weather forecasting with data assimilation

A.S. Tabakov^{1,2}, A.V. Penenko¹

¹Institute of Computational Mathematics and Mathematical Geophysics SB RAS, Novosibirsk, Russia; ²Novosibirsk State University, Novosibirsk, Russia
artur.tabakov11@gmail.com

A regional neural network weather forecasting model for the south of Krasnoyarsk Krai based on a graph representation of the atmospheric state is presented. A global mesh with a 0.703° spacing and a regional insert with a 0.25° spacing are combined into a single graph of 133,279 nodes, which removes the need for external lateral boundary conditions: the resolutions are reconciled at the interface by the message passing mechanism during training. The model has 5.9 million trainable parameters; both training and forecast production run on a single GPU. Evaluation on an independent sample of 1607 initial times covering all seasons yields a root-mean-square error of the 2-m temperature forecast of 1.46°C at the 24-h lead time with an aggregate skill score of 74.6 % relative to persistence. The distribution of the training signal over graph nodes and channels that arises from uniform averaging of the loss is shown to be far from the task at hand; explicit weighting reduces the 2-m temperature error by 12 % with no change to the architecture or the training budget. A controlled experiment with an equal training budget shows that the single-step validation error is an unreliable criterion for selecting a model intended for multi-step forecasting. Observation assimilation by relaxation (nudging) and optimal interpolation within the autoregressive cycle is examined: continuous assimilation limits error growth over a 336-h rollout, whereas the model's memory of discontinued observations lasts about one day.

Keywords: numerical weather prediction, graph neural network, regional forecasting, multiscale mesh, data assimilation, optimal interpolation, autoregressive forecast, machine learning

Введение

Численный прогноз погоды основан на интегрировании уравнений гидротермодинамики атмосферы на сетке высокого разрешения. За десятилетия развития подход достиг высокой точности, однако расчёт одного глобального прогноза на средние сроки требует часов работы суперкомпьютерного комплекса, что ограничивает и частоту обновления прогноза, и возможность построения больших ансамблей.

В 2022–2023 годах произошёл качественный сдвиг: нейросетевые модели, обученные на архиве реанализа, показали точность, сопоставимую с оперативными системами ведущих метеоцентров, при несопоставимо меньших затратах на выпуск прогноза. Модель GraphCast [1], построенная на графовом представлении атмосферного состояния, превзошла оперативную систему Европейского центра по большинству переменных на сроках от трёх до десяти суток; сопоставимые результаты получены моделями Pangu-Weather [2] и FourCastNet [3]. Ключевым элементом GraphCast является представление расчётной области графом с квазиравномерным распределением узлов по сфере: это позволяет выучивать локальные закономерности независимо от географического положения — свойство, недостижимое для регулярной сетки в координатах широта–долгота.

Подавляющее большинство таких систем решает глобальную задачу, тогда как практический интерес часто представляет прогноз повышенной детальности над ограниченной территорией. Перенос подхода на региональный масштаб порождает специфические трудности. Главная из них — граничные условия: у краевых узлов вырезанной области нет корректного окружения, и в классическом численном прогнозе это решается заданием внешних гранич-

ных условий с релаксацией к внешнему полю в буферной зоне [4], что требует отдельной процедуры и вносит собственные погрешности. К этому добавляется накопление ошибки в авторегрессионной развёртке, для ограниченной области выраженное сильнее, и разрежённость наблюдений, согласование которых с полем модели составляет предмет теории усвоения данных [5] — её применимость к авторегрессионному нейросетевому прогнозу остаётся открытым вопросом.

В нейросетевых региональных моделях предложено несколько способов обойти проблему границ: подача граничного форсинга от глобальной модели в архитектуре Neural-LAM [6]; растянутая сетка с плавным изменением разрешения [7]; вложенные сетки с обменом информацией между уровнями [8]. Сравнение подходов с растянутой сеткой и с ограниченной областью выполнено в [9].

Настоящая работа посвящена региональной модели прогноза над югом Красноярского края. Вклад состоит в следующем.

1. Реализована конструкция единой мультимасштабной сетки, в которой глобальная сетка с шагом $0,703^\circ$ и региональная вставка с шагом $0,25^\circ$ объединены в один граф без внешних границ, а согласование разрешений достигается не отдельной процедурой сшивания, а самим механизмом обмена сообщениями. Идея мультимасштабного представления не нова [7, 8]; предлагаемый вариант отличается способом построения — прямой заменой узлов глобальной решётки региональной вставкой с единообразным построением связности. Количественно показано, что такая конструкция превосходит интерполяцию прогноза глобальной модели в те же узлы, и приведена прямая диагностика стыка.
2. Модель намеренно выполнена лёгкой — 5,9 млн параметров против сотен миллионов у [1, 2, 7]; обучение и выпуск прогноза производятся на одном графическом ускорителе, что делает воспроизведение результата осуществимым в вычислительной среде регионального управления гидрометслужбы.
3. Количественно исследована стратегия дообучения глобальной модели под региональную сетку. Получен методический результат, имеющий, по мнению авторов, самостоятельное значение: ошибка одношагового прогноза на проверочной выборке — ненадёжный критерий отбора состояния модели, предназначенной для многошагового прогноза.
4. Показано, что распределение обучающего сигнала, возникающее при равномерном усреднении функции потерь, далеко от постановки задачи: узлы целевой области получают 1,9 % сигнала, а приземная температура — 0,46 %. Явное взвешивание по узлам и каналам снижает ошибку приземной температуры на 12 % без изменения архитектуры и объёма обучения.
5. Исследована совместимость классических методов усвоения данных — релаксационного и оптимальной интерполяции — с авторегрессионным нейросетевым прогнозом; вклад усвоения оценён по горизонтам вплоть до четырнадцати суток.

Отечественный контекст задачи составляют оперативные системы Гидрометцентра России, в том числе полулагранжева модель ПЛАВ [10].

Данные, базовая модель и метрики качества

Исходные данные

Обучение и оценка выполнены на реанализе ERA5 Европейского центра среднесрочных прогнозов погоды [11] за 2010–2020 гг. с шагом 6 ч, что даёт 16 072 последовательных срока.

Состояние атмосферы описывается набором из 19 полей. Приземные и статические: температура воздуха на высоте 2 м, зональная и меридиональная компоненты ветра на высоте 10 м, давление на уровне моря, приземное давление, суммарные осадки за 6 ч, общее содержание водяного пара в столбе атмосферы, геопотенциал поверхности и маска «суша — море». Два последних поля статические: подаются на вход, но не прогнозируются, переносятся между шагами без изменений и исключены из всех приводимых оценок. На каждом из уровней 850 и 500 гПа задаются пять полей: температура, две компоненты ветра, геопотенциал и удельная влажность. Вертикальная структура атмосферы кодируется, таким образом, составом признаков узла, а не отдельными узлами по вертикали.

Поля хранятся в физических единицах: температура — в кельвинах, ветер — в м/с, давление на уровне моря и приземное — в гПа, геопотенциал — в геопотенциальных метрах (поле ERA5 в $\text{м}^2/\text{с}^2$ однократно поделено на $g = 9,80665 \text{ м/с}^2$), содержание водяного пара — в кг/м^2 . Перед подачей в сеть каждый канал стандартизуется вычитанием среднего и делением на стандартное отклонение; оба скаляра оценены по всему периоду 2010–2020 гг., включая проверочную и тестовую части, — влияние двух чисел на канал пренебрежимо, но факт указывается явно.

Входное окно — два последовательных срока (12 ч предыстории); прогноз строится авторегрессионно с шагом 6 ч. Основные горизонты оценки — +6, +12, +18 и +24 ч; поведение при развёртке до +168 ч рассматривается в разделе об усвоении наблюдений.

Целевая область (регион) ограничена координатами 50–60° с. ш., 83–98° в. д. и покрывается решёткой с шагом 0,25° размером $61 \times 41 = 2501$ узел. Внутри выделена внутренняя зона 55,5–56,5° с. ш., 92–94° в. д. (45 узлов), включающая Красноярск и окрестности. Все метрики вычислены относительно реальных полей ERA5 с шагом 0,25° в этих узлах, без интерполяции с более грубой сетки.

Состав 33-канальной конфигурации, использованной для основной модели, получается добавлением к перечисленным 19 полям пяти полей на уровне 250 гПа и пяти на уровне 1000 гПа (температура, обе составляющие ветра, геопотенциал, удельная влажность), а также четырёх каналов временного форсинга — синусов и косинусов часа суток и дня года. Форсинг и статические поля модель предсказывает формально, но при развёртке они заменяются известными значениями и в число прогностических каналов не входят.

Хронологическое разбиение выборки

Разбиение выполнено строго хронологически, без перемешивания сроков: обучающая выборка целиком предшествует проверочной, а проверочная — тестовой, что исключает попадание в обучение информации о будущих состояниях. Из 16 072 сроков при окне «2 входных среза + 4 прогностических шага» формируется 16 067 примеров, делящихся в отношении 80/10/10: 12 853 — обучение, 1607 — проверочная выборка (подбор гиперпараметров и отбор состояния модели), 1607 — тестовая выборка, на которой получены все публикуемые числа. Тестовая выборка охватывает конец 2019 г. и полностью 2020 г., то есть содержит непрерывный годовой цикл и все четыре сезона: обучающая выборка — сроки начала прогноза с 01.01.2010 06 UTC по 19.10.2018 06 UTC, проверочная — с 19.10.2018 12 UTC по 25.11.2019 00 UTC, тестовая — с 25.11.2019 06 UTC по 30.12.2020 18 UTC. Это существенно, поскольку оценки, полученные на срезе одного холодного сезона, не характеризуют качество модели в целом.

Базовая глобальная модель

Отправной точкой регионального дообучения служит глобальная модель, обученная на тех же 19 полях на широтно-долготной сетке 512×256 узлов (шаг около $0,703^\circ$). Она реализует схему «кодировщик — процессор — декодировщик» на графе: кодировщик переносит признаки узлов расчётной сетки на вершины икосаэдрической мозаики (уровни детализации 4 и 6), процессор выполняет 12 раундов обмена сообщениями блоком типа Interaction Network [12] с четырёхмерными геометрическими признаками рёбер, декодировщик возвращает результат в узлы сетки. Латентная размерность — 256, число обучаемых параметров — 5,9 млн, что на два-три порядка меньше, чем у известных глобальных нейросетевых моделей [1–3], и позволяет вести обучение и оперативный выпуск прогноза на одной видеокарте.

Функция потерь — среднеквадратическая ошибка в стандартизованных переменных, осреднённая по узлам, каналам и горизонтам, с поэтапным наращиванием длины авторегрессионной развёртки. Отметим особенность реализации, выявленную при подготовке работы: при глобальном предобучении широтное взвешивание узлов оказалось практически равномерным, тогда как при региональном дообучении (см. следующий раздел) применялись веса $\cos\varphi$, где φ — широта узла. Региональное дообучение стартовало с промежуточного набора весов глобальной модели: лучшее по проверочной выборке состояние (эпоха 30 из 36 пройденных). Качество базовой модели на её собственной сетке: агрегатная успешность 65,4 % при ошибке приземной температуры $1,07^\circ\text{C}$ в среднем по горизонтам $+6...+24$ ч (200 сроков, собственная сетка модели). Сопоставлять это значение с региональными числами настоящей работы нельзя: оценка ведётся на грубой сетке $0,703^\circ$, где истинное поле сглажено, по всему шару, а не по рассматриваемой области, и на другой подвыборке сроков.

Метрики качества

Для канала s и горизонта t среднеквадратическая ошибка вычисляется в физических единицах канала:

$$\text{RMSE}_c(\tau) = \left[\frac{1}{N|G|} \sum_{n=1}^N \sum_{g \in G} (x_{c,g}^{(n)}(\tau) - x_{c,g}^{(n)}(\tau))^2 \right]^{1/2}, \quad (1)$$

где N — число сроков ($N = 1607$ для тестовой выборки); G — множество оцениваемых узлов ($|G| = 2501$ для региона, 45 для внутренней зоны); $x_{c,g}^{(n)}(\tau)$ — прогностическое значение канала c в узле g на горизонте τ из срока n ; $x_{c,g}^{(n)}(\tau)$ — соответствующее значение реанализа, принимаемое за истинное. Ошибка приводится в единицах переменной: температура — в °C (для разности градус Цельсия численно совпадает с кельвином), ветер — в м/с, давление — в гПа, геопотенциал — в гпм. Узлы суммируются с равными весами, без взвешивания на площадь ячейки; при широтном диапазоне 50–60° с. ш. отношение площадей ячеек на границах области составляет около 1,29, что одинаково для всех сравниваемых конфигураций и не влияет на их упорядочение.

В качестве простейшего эталона используется инерционный прогноз: значения полей в последний срок входного окна t_0 переносятся без изменений на все горизонты, $x_{\text{ин}}^{(n)}(t_0 + \tau) = x(t_0)$. Успешность относительно него определяется как

$$S_c(\tau) = \left(1 - \frac{\text{RMSE}_c(\tau)}{\text{RMSE}_{\text{ин}}(\tau)} \right) \cdot 100 \%, \quad (2)$$

где $\text{RMSE}_{\text{ин}}(\tau)$ — ошибка (1) для инерционного прогноза на том же окне и той же маске узлов. Значение $S = 0$ соответствует совпадению с эталоном, $S > 0$ — превосходству над ним. По большинству каналов ошибка инерционного эталона растёт с горизонтом, поэтому рост S отражает отчасти деградацию эталона, а не только качество прогноза. Для приземной температуры картина иная и требует оговорок: ошибка инерционного прогноза составляет 4,99 / 6,88 / 5,88 / 4,42 °C на горизонтах +6 / +12 / +18 / +24 ч, то есть на суточном сроке эталон точнее, чем на шестичасовом. Причина — суточный ход: через сутки поле возвращается к тому же часу местного времени. Успешность по приземной температуре относительно инерционного эталона поэтому немонотонна (76,4 / 80,2 / 76,2 / 67,0 %) и характеризует эталон не в меньшей степени, чем модель. По этой причине для приземной температуры предпочтителен климатический эталон, ошибка которого от горизонта практически не зависит. Климатический эталон строился по обучающей части выборки разложением по гармоникам: три годовые гармоники и суточный ход (косинус и синус первой гармоники плюс косинус второй; синус второй при шестичасовой дискретности неопределим). Тестовые сроки в подгонку не входили. Ошибка климатологии по узлам региональной вставки составляет 6,25 °C для приземной температуры, 5,42 °C для температуры на уровне 850 гПа, 9,19 гПа для давления на уровне моря и 2,05 и 1,74 м/с для составляющих приземного ветра; от горизонта она, в отличие от инерционной, практически не зависит (6,25 °C на всех сроках от +6 до +24 ч). Успешность основной модели относительно климатологии на горизонте +24 ч: 76,6 % по приземной температуре, 82,7 % по температуре на 850 гПа, 88,8 % по давлению на уровне моря, 65,9 и 60,9 % по составляющим ветра. Поскольку климатический эталон не деградирует с ростом горизонта, именно он определяет предел полезности прогноза: при развёртке до

168 ч (разд. 5) ошибка приземной температуры достигает уровня климатологии (6,25 °C) после седьмых суток: на +120 ч она равна 4,33 °C, на +168 ч — 6,19 °C, что и следует считать границей осмысленности детерминированного прогноза для рассматриваемой конфигурации.

Для сводной оценки по всем полям применяется агрегатный показатель. Поскольку каналы имеют разные единицы, агрегирование выполняется в стандартизованных переменных:

$$\overline{\text{RMSE}} = \left[\frac{1}{N|G|CH} \sum_n \sum_{g \in G} \sum_{c=1}^C \sum_{\tau} \left(\frac{x_{c,g}^{(n)}(\tau) - x_{c,g}^{(n)}(\tau)}{\sigma_c} \right)^2 \right]^{1/2}, \quad \bar{S} = \left(1 - \frac{\overline{\text{RMSE}}}{\overline{\text{RMSE}}_{\text{ин}}} \right) \cdot 100 \%, \quad (3)$$

где σ_c — стандартное отклонение канала c , использованное при стандартизации; C — число прогностических каналов; $H = 4$ — число горизонтов. Величина C зависит от конфигурации: для 19-канальной $C = 17$ (исключены два статических поля — рельеф и маска суши), для 33-канальной $C = 27$ (дополнительно исключены четыре канала временного форсинга). Отсюда следует, что колонка $\bar{S}$ в табл. 1 сравнивает величины, осреднённые по разным наборам каналов, и строки с 19 и 33 каналами по ней прямо не сопоставимы; сопоставимы поканальные значения и строки внутри одного набора. Величина $\overline{\text{RMSE}}$ безразмерна, поэтому содержательна только в сравнении с эталоном, то есть через $\bar{S}$.

Точность оценок характеризуется доверительными интервалами, полученными блочным бутстрепом: поскольку сроки начала прогноза следуют через 6 ч и коррелированы внутри одного синоптического процесса, ресэмплированию подвергаются блоки подряд идущих сроков длиной в несколько суток, а не отдельные сроки [13]. Интервалы строятся из посрочных вкладов в ошибку, сохраняемых при каждом прогоне, поэтому парное сравнение двух конфигураций ведётся на общих сроках и не требует повторного счёта. Оговорим, что интервал учитывает изменчивость по срокам верификации, но не по повторным обучениям; последняя оценена отдельно и приведена в «Ограничениях».

Мультимасштабная графовая модель и стратегия дообучения

Ограничения регулярной сетки на сфере

Прогностическая модель обучается воспроизводить локальные закономерности эволюции атмосферных полей: значение переменной в узле через шесть часов определяется состоянием в его пространственной окрестности. Чтобы такая закономерность была выучиваема, операция «взять окрестность узла» должна означать во всех точках расчётной области примерно одно и то же — окрестность фиксированного физического размера.

Для регулярной сетки в координатах широта–долгота это условие не выполняется. При шаге $0,703^\circ$ расстояние между соседними узлами вдоль параллели составляет около 78 км на экваторе и убывает пропорционально косинусу широты: примерно 50 км на 50° с.ш. и около

14 км на 80° с.ш. Свёрточный фильтр с фиксированным размером окна охватывает поэтому существенно разные физические области в зависимости от широты, а вблизи полюсов сетка вырождается. Модель вынуждена либо усреднять эту неоднородность, либо расходовать ёмкость на её запоминание; ни то, ни другое не желательно.

Альтернатива — представить расчётную область графом, узлы которого распределены по сфере квазиравномерно. Такое распределение даёт икосаэдрическая триангуляция: исходный икосаэдр из 20 равных треугольных граней рекурсивно измельчается делением каждого треугольника на четыре с проецированием новых вершин на сферу. На любом уровне измельчения каждая вершина имеет пять или шесть соседей, а разброс длин рёбер невелик, поэтому окрестность узла всюду соответствует близкому физическому масштабу. Именно это свойство лежит в основе современных нейросетевых моделей прогноза [1, 2].

Архитектура

Используется схема «кодировщик — процессор — декодировщик» [1, 12], в которой обмен информацией происходит на графе, а входные и выходные поля остаются на регулярной сетке (рис. 1).




Рис. 1. Устройство модели. (а) поток данных: значения расчётной сетки переносятся кодировщиком в вершины графа-мозаики, процессор выполняет 12 раундов обмена сообщениями, декодировщик возвращает приращения полей на сетку; выход подаётся на вход следующего шага. (б) двухфазная схема дообучения.

Кодировщик переносит значения из узлов регулярной сетки в вершины графа. Для каждой вершины графа формируется сообщение от узлов сетки, попавших в её окрестность (радиус связи 0,6 в единицах длины ребра графа), после чего многослойный персептрон преобразует агрегированное сообщение в скрытое представление размерности 256.

Процессор выполняет $R = 12$ раундов обмена сообщениями по рёбрам графа. Один раунд реализован блоком Interaction Network [12] и состоит из двух шагов. Сначала для каждого ребра $(i \rightarrow j)$ вычисляется сообщение

$$m_{ij}^{(r)} = \varphi_e(h_i^{(r-1)}, h_j^{(r-1)}, e_{ij}), \quad (4)$$

затем состояние вершины обновляется по агрегированным входящим сообщениям:

$$h_j^{(r)} = \varphi_v(h_j^{(r-1)}, \frac{1}{|N(j)|} \sum_{i \in N(j)} m_{ij}^{(r)}), \quad (5)$$

где $h_j^{(r)}$ — скрытое представление вершины j после раунда r (размерность 256); e_{ij} — постоянные признаки ребра (четыре величины: длина ребра и три компоненты единичного вектора направления в геоцентрической системе координат); $N(j)$ — множество вершин, соединённых с j ; φ_e и φ_v — многослойные перцептроны с функцией активации Swish и послойной нормировкой. Веса φ_e , φ_v не разделяются между раундами: каждый из 12 раундов имеет собственные параметры, что соответствует организации процессора в [1].

Декодировщик выполняет обратный перенос: скрытые представления вершин графа отображаются в приращения полей в узлах регулярной сетки.

Прогноз строится авторегрессионно с шагом 6 ч: выход модели подаётся на её вход для получения следующего срока,

$$x_{\text{с}}(t_0 + 6(k+1)) = F(x_{\text{с}}(t_0 + 6k), x_{\text{с}}(t_0 + 6(k-1))), \quad k = 0, 1, \dots, K-1, \quad (6)$$

где F — обученное отображение (кодировщик–процессор–декодировщик), входное окно составляет два последовательных срока (12 ч), а при $k = 0$ используются два среза анализа. Общее число обучаемых параметров модели — 5,9 млн. Конфигурации на 19 и 33 канала различаются только входным слоем кодировщика и выходным слоем декодировщика — около 11 тыс. параметров, или 0,2 %, — поэтому обе округляются до одного и того же значения.

Небольшой размер модели — сознательное проектное решение. Обучение и оперативная работа выполняются на одной графической карте, что делает воспроизведение результата возможным в вычислительной среде регионального управления гидрометслужбы, тогда как модели с сотнями миллионов параметров [2, 7] требуют многоузловых конфигураций.

Мультимасштабная расчётная сетка

Классический способ построения региональной модели — вырезать область из глобальной сетки и задавать на её краю внешние граничные условия. У такого подхода есть известный недостаток: граничные узлы не имеют корректного окружения, из-за чего у края накапливаются искажения, а для их подавления требуется отдельная процедура сшивания с внешним полем [4].

В настоящей работе используется иной приём: глобальная и региональная сетки объединяются в единый граф, и понятие внешней границы для модели исчезает. Из глобальной сетки 512×256 (шаг $0,703^\circ$) удаляются узлы, попадающие внутрь области интереса, а на их место помещается регулярная региональная решётка с шагом $0,25^\circ$ ($61 \times 41 = 2501$ узел) в границах $50\text{--}60^\circ$ с.ш., $83\text{--}98^\circ$ в.д. Итоговая расчётная сетка содержит

$$N = \frac{130\,778}{\text{глобальные узлы}} + \frac{2\,501}{\text{региональная вставка}} = 133\,279 \text{ узлов.}$$

Рёбра между узлами и вершинами графа строятся поиском ближайших соседей в трёхмерном пространстве по геоцентрическим координатам, единообразно для узлов обоих разрешений; никакой специальной обработки переходной зоны при построении связности не выполняется.

Соединение областей выполнено жёстко: множества узлов не пересекаются по построению, значения просто объединяются в единый вектор состояния,

$$x = [x_{\text{вне области}}^{\text{глоб}}, x_{\text{внутри области}}^{\text{рег}}], \quad (7)$$

без весовой функции и сглаживания на стыке. Согласование разрешений происходит неявно, в ходе обмена сообщениями: узлы по обе стороны стыка связаны рёбрами и на каждом из 12 раундов обмениваются признаками, так что переходный слой формируется самой моделью в процессе обучения.

Это принципиально отличает предлагаемый приём от метода Дэвиса [4] и его модификаций: там внутреннее решение релаксируется к заданному извне полю в буферной зоне в ходе интегрирования, то есть внешняя граница и внешнее поле остаются необходимыми, тогда как здесь их нет вовсе — объединённая сетка является частью входного представления и участвует в обучении. Прямая экспериментальная проверка бесшовности стыка приведена на рис. 2. На панели (а) показано поле приземной температуры на горизонте +24 ч в окрестности границы вставки: смена разрешения видна по размеру ячеек, разрыва поля на склейке нет. На панели (б) — среднеквадратическая ошибка в зависимости от расстояния до границы (100 сроков). В полосе 0–25 км внутри вставки ошибка составляет 2,12 °С против 2,07 °С в её середине (200–1000 км), то есть на 2,4 % выше; снаружи, в полосе 0–100 км от границы, — 1,87 °С. На суточном сроке, таким образом, всплеск ошибки у стыка мал. На коротких сроках он заметнее: количественная диагностика по горизонтам приведена в п. 4.7, где превышение у стыка составляет 6–9 %.




Рис. 2. Стык региональной вставки. (а) прогноз приземной температуры на +24 ч; размер ячейки соответствует шагу сетки — 0,25° внутри вставки и 0,703° снаружи. (б) среднеквадратическая ошибка по расстоянию до границы, 100 сроков.

Отметим ограничение подхода: региональная вставка задана прямоугольником в координатах широта–долгота, то есть внутри неё сохраняется та же неоднородность шага по долготе, что

обсуждалась в п. 3.1. Для области протяжённостью 10° по широте это отношение составляет $\cos 50^\circ / \cos 60^\circ \approx 1,29$ и на масштабе задачи несущественно, однако при переносе схемы на область большей широтной протяжённости этот фактор потребует учёта.

Стратегия дообучения

Региональная модель получается дообучением глобальной, обученной на той же выборке ERA5 в конфигурации 512×256 . При смене геометрии расчётной сетки веса кодировщика и декодировщика оказываются несогласованными с новой связностью, тогда как процессор содержит выученную на глобальной задаче динамику. Прямое дообучение всех параметров сразу несёт риск разрушения этой динамики большими градиентами со стороны неадаптированных кодировщика и декодировщика — эффект, известный как катастрофическое забывание.

Применяется двухфазная схема:

1. Фаза 1 (первые E_f эпох): параметры процессора зафиксированы, обучаются только кодировщик и декодировщик, приспосабливаясь к новой геометрии и статистике региона.
2. Фаза 2 (оставшиеся эпохи): процессор размораживается, но его темп обучения устанавливается в 10 раз меньше базового.

В основной конфигурации $E_f = 10$, в конфигурациях, использованных для проверки самой стратегии (п. 4.5), $E_f = 6$; базовый темп обучения 10^{-4} , оптимизатор Adam.

Одновременно применяется учебный план по длине авторегрессионной развёртки: обучение начинается с одношагового прогноза, а затем число шагов K в (6) последовательно увеличивается до четырёх, причём функция потерь вычисляется по всем шагам развёртки. Это согласует режим обучения с режимом применения, где модель работает авторегрессионно.

Функция потерь — среднеквадратическая ошибка в стандартизованных переменных, вычисляемая по всем узлам расчётной сетки (не только по региональной вставке; вариант с ограничением потерь областью интереса приводил к деградации полей за её пределами и через авторегрессионную обратную связь ухудшал прогноз внутри области). Статические поля — рельеф и маска суши/моря — исключены из функции потерь и переносятся между шагами развёртки без изменений.

Результаты: качество регионального прогноза

Условия оценки

Все оценки получены на едином окне верификации и при единственном определении истинного поля (разд. 2): реанализ ERA5 с шагом $0,25^\circ$ в узлах региональной вставки. Показатели

— среднеквадратическая ошибка в физических единицах (1), успешность относительно инерционного прогноза (2) и агрегатная успешность по прогностическим каналам (3).

Объём выборки в таблицах различается. На полной тестовой выборке из 1607 сроков (25.11.2019 — 30.12.2020, все четыре сезона) посчитаны табл. 1, 3 и 8. Расчёты, требующие длинной развёртки или внешних данных, выполнены на подвыборках из **первых** сроков тестового периода: 100 (по 19.12.2019) в табл. 2 и 5, 200 (по 13.01.2020) в табл. 8, 500 (по 28.03.2020) при оценке на пяти сутках. Они представляют холодное полугодие и систематически труднее полной выборки: ошибка приземной температуры на суточном сроке равна 1,46 °C на 1607 сроках, 1,72 °C на 200 и 2,05 °C на 100. Числа из разных таблиц между собой несопоставимы; внутри таблицы все конфигурации посчитаны на одних сроках.

Качество основной модели

Табл. 1. Ошибка приземной температуры (°C) по горизонтам и агрегатная успешность $\bar{S}$ (%). Здесь и далее $\bar{S}$ — агрегат по всем прогностическим каналам и всем четырём горизонтам согласно (3), а не значение на отдельном сроке. Тестовая выборка 1607 сроков; регион — 2501 узел, внутренняя зона — 45 узлов.

Зона	Конфигурация	+6 ч	+12 ч	+18 ч	+24 ч	$\bar{S}$, %
Регион	19 каналов	1,39	1,66	1,74	1,84	69,4
	33 канала, базовая	1,32	1,53	1,59	1,66	73,4
	33 канала, взвешенная (основная)	1,18	1,36	1,40	1,46	74,6
Внутренняя зона	33 канала, базовая	1,21	1,41	1,47	1,53	74,5
	33 канала, взвешенная (основная)	1,06	1,23	1,26	1,31	75,4

Ошибка приземной температуры основной модели на суточном сроке составляет 1,46 °C по области и 1,31 °C во внутренней зоне. По остальным полям на том же сроке (регион): компоненты приземного ветра 0,70 и 0,68 м/с, давление на уровне моря 1,03 гПа, температура на уровне 850 гПа 0,94 °C, геопотенциал на уровне 500 гПа 8,7 гпм.

Три строки таблицы отвечают трём независимым изменениям. Расширение состава полей с 19 до 33 каналов (уровни 250 и 1000 гПа, временной форсинг) даёт значимый выигрыш на всех горизонтах: 0,076 / 0,121 / 0,149 / 0,174 °C с 95 %-ми доверительными интервалами [0,063; 0,088], [0,104; 0,138], [0,125; 0,171] и [0,141; 0,210] (блочный бутстреп, блок 5 суток, 2000 реплик, парное сравнение на совпадающих сроках). Отнести весь выигрыш к добавленным уровням нельзя: 33-канальная конфигурация дообучалась от иной глобальной модели, которая и сама точнее по общим полям. Переход от базовой 33-канальной конфигурации к взвешенной — предмет п. 4.4; он снижает ошибку приземной температуры ещё на 12 % при равном объёме обучения и неизменной архитектуре.

Что даёт единый граф

Чтобы оценить вклад собственно мультимасштабной конструкции, прогноз глобальной модели с шагом $0,703^\circ$ интерполирован билинейно в те же 2501 узел и оценён против той же истины. Все строки табл. 2 посчитаны на одних и тех же 100 сроках тестовой выборки.

Табл. 2. Ошибка прогноза на горизонте +24 ч в узлах региональной вставки: инерционный прогноз, интерполяция прогноза глобальной модели и мультимасштабная модель.

Поле	Инерционный прогноз	Глобальная $0,703^\circ$ + интерполяция	Мультимасштабная	Выигрыш
t2m, °C	4,20	2,30	2,05	11 %
10u, м/с	2,71	0,99	0,59	40 %
msl, гПа	9,36	2,23	1,66	26 %
t@850, °C	6,27	1,48	1,23	17 %
z@500, гПм	88,5	21,0	13,3	37 %

Единый граф превосходит интерполяцию по всем полям. Выигрыш умеренный по приземной температуре (11 %) и существенный по ветру и геопотенциалу (37–40 %). Это согласуется с устройством приёма: обмен сообщениями уточняет поле как целое, тогда как приземная температура в конкретном узле сильнее определяется подсеточными факторами, которых не разрешает ни одна из сравниваемых конфигураций.

Веса в функции потерь

Функция потерь при обучении — среднеквадратическая ошибка по нормированным каналам, усреднённая по узлам графа и шагам развёртки. Такое усреднение задаёт распределение обучающего сигнала неявно, и оно оказывается далёким от постановки задачи в двух отношениях.

Пространственная диспропорция. Узлов региональной вставки 2501 из 133 279, то есть 1,9 %. Почти весь обучающий сигнал приходится на глобальную часть графа, тогда как публикуемые показатели относятся к вставке.

Поканальная диспропорция. Нормировка выполнена на разброс самого поля, тогда как модель предсказывает приращение за шаг, и разбросы приращений различаются у каналов на порядки. Прямой замер по обучающей выборке: осадки составляют 25,0 % функции потерь, приземная температура — 0,46 %, геопотенциал на 500 гПа — 0,15 %, а наименьшую долю получает приземное давление — 0,02 %; отношение крайнего максимума к минимуму равно 1218. Иными словами, вклад канала определяется не его значимостью, а масштабом его собственной изменчивости.

Обе диспропорции устраняются весами: узлам вставки присваивается вес W при единичном весе остальных, каналам — веса, обратные квадрату разброса шестичасовой невязки, вычисленного по обучающей выборке. Все конфигурации в табл. 3 получены одинаковым дожигом одной и той же исходной модели: восемь эпох на полной четырёхшаговой развёртке с косинусным снижением темпа до нуля. Различаются они только весами, поэтому сравнение прямое. Отметим, что первая строка табл. 3 (1,503 °C, 73,8 %) не совпадает со строкой «33 канала, базовая» табл. 1 (1,525 °C, 73,4 %) именно потому, что дожиг в неё уже включён, а в табл. 1 — нет. Поэтому выигрыш взвешивания при равном объёме обучения составляет 10,2 % (1,503 → 1,350), тогда как разность с табл. 1 (11,5 %) включает и восемь эпох дожига.

Табл. 3. Влияние весов в функции потерь. Регион, 1607 сроков. $\bar{S}$ — агрегатная успешность, t_{2m} — ошибка приземной температуры, усреднённая по четырём горизонтам; последний столбец — ошибка по всей сетке графа.

Конфигурация	Доля вставки в потерях	$\bar{S}$, %	t_{2m} , °C	RMSE по сетке
Исходная (без весов, после дожига)	1,7 %	73,8	1,503	0,1696
Вес вставки $W = 10$	14,7 %	74,7	1,445	0,1697
Вес вставки $W = 30$	34,1 %	74,9	1,415	0,1703
Вес вставки $W = 100$	63,3 %	74,8	1,407	0,1717
$W = 30$ и веса каналов	34,1 %	74,6	1,350	0,1708

У веса вставки обнаруживается внутренний максимум по агрегату. Рост доли вставки с 1,7 до 34,1 % улучшает и агрегат, и приземную температуру, тогда как дальнейший рост до 63,3 % агрегат ухудшает. Мера утверждения такова. Парный блочный бутстреп по общим срокам даёт для разности агрегатов при $W = 100$ и $W = 30$ величину $-0,05$ п.п. с интервалом $[-0,07; -0,03]$, не накрывающим ноль: на данной тестовой выборке падение агрегата воспроизводимо. Оговорим границу этого вывода: интервал учитывает изменчивость по срокам, но не по повторным обучением, а межзапусковая изменчивость оценена нами в 0,03 п.п. и сравнима с самой разностью. По приземной температуре максимума нет вовсе, она убывает монотонно (1,503 → 1,445 → 1,415 → 1,407). Внутренний максимум по агрегату, таким образом, установлен как свойство данной выборки, но не как свойство метода; объясняющий его механизм виден в последнем столбце увереннее. Механизм виден в последнем столбце: платой служит точность на глобальной части графа: сама ошибка при $W = 100$ выше, чем при $W = 30$, лишь на 0,8 % (0,1717 против 0,1703), но её ПРИРАЩЕНИЕ относительно конфигурации без весов втрое больше — 0,0021 против 0,0007. Прогноз внутри вставки за сутки существенно зависит от притока извне, поэтому деградация окружающего поля возвращается в область через развёртку. Оптимум, таким образом, определяется не самой областью, а балансом между ней и её окружением.

Веса каналов действуют как регулятор, а не как исправление ошибки: агрегатная успешность при их введении снижается на 0,30 п.п. (парный бутстреп, интервал $[-0,32; -0,28]$), тогда как приземная температура улучшается на 4,6 % (от 0,056 °C на +6 ч до 0,071 °C на +24 ч, все четыре интервала не покрывают ноль). Причина в том, что агрегат (3) сам представляет собой среднее по каналам с равными весами, то есть равномерное взвешивание для него оптимально по построению. Выравнивание вкладов смещает точность к каналам с малой собственной изменчивостью — приземной температуре, давлению, геопотенциалу — за счёт каналов с большой. В пределах измеренного диапазона выигрыш канала описывается логарифмом полученного им веса (коэффициент корреляции 0,98 по 12 каналам), однако за его пределы эта зависимость не переносится: усиление пяти приземных каналов вчетверо сверх выравнивания дало меньше предсказанного, а геопотенциал на 500 гПа при возросшем весе стал хуже. Механизм тот же, что и у веса вставки: усиленные каналы отбирают ресурс у полей, которые их же и определяют.

Основная конфигурация статьи использует $W = 30$ и выравнивающие веса каналов. Веса каналов вычислены по обучающей выборке и не подбирались по тестовой; целевые каналы для усиления не выделялись.

Стратегия дообучения и выбор контрольной точки

Стратегия регионального дообучения исследована на отдельной, 19-канальной линии моделей: сравниваются конфигурация с заморозкой процессора на первые 6 эпох и конфигурация, где все параметры обучаются с первой эпохи. Обе обучены на одной сборке данных, при одном начальном значении генератора случайных чисел и одинаковом расписании, поэтому различаются только стратегией.

Эта линия использует прямое предсказание поля, а не остаточную формулировку, и потому её агрегатная успешность (около 60 %) существенно ниже, чем у 19-канальной строки табл. 1 (69,4 %), посчитанной на остаточной модели, — при близких значениях приземной температуры. Числа табл. 1 и табл. 4 относятся, таким образом, к разным моделям и между собой не сравниваются; внутри табл. 4 все конфигурации сравнимы.

Табл. 4. Ошибка приземной температуры (°C) по региону и агрегатная успешность при разных способах отбора контрольной точки.

Конфигурация	Состояние	+6 ч	+12 ч	+18 ч	+24 ч	$\bar{S}$, %
С заморозкой	лучшая по val (эпоха 16)	1,34	1,59	1,71	1,82	60,8
Без заморозки	лучшая по val (эпоха 7)	1,36	1,65	1,81	1,96	59,9
Без заморозки	равный бюджет (эпоха 16)	1,35	1,62	1,72	1,82	59,5

Сравнение по лучшим контрольным точкам даёт выигрыш в пользу заморозки, растущий с горизонтом — до 0,14 °C на +24 ч. Однако лучшие точки достигаются на разных эпохах, 16-й и 7-й, то есть такое сравнение сопоставляет не только стратегии, но и объёмы обучения. При

равном бюджете разность по приземной температуре исчезает: обе конфигурации дают 1,82 °C на суточном сроке.

Более того, контрольная точка эпохи 7, отобранная как «лучшая» по одношаговой ошибке, в авторегрессионной развёртке уступает собственной же точке эпохи 16 (1,96 против 1,82 °C). Тот же эффект независимо воспроизводится на базовой 33-канальной конфигурации: её состояние, отобранное по минимуму ошибки на проверочной выборке, точнее на горизонте +6 ч (1,30 против 1,32 °C), но уступает на +18 и +24 ч (1,63 против 1,59 и 1,71 против 1,66 °C), причём смена знака значима с обеих сторон.

Отсюда методический вывод: минимум одношаговой ошибки на проверочной выборке — ненадёжный критерий выбора состояния модели, предназначенной для многошагового прогноза. Такой критерий отбирает модель, оптимальную ровно на том горизонте, который он измеряет. Отбор следует вести по метрике при полной авторегрессионной развёртке, а сравнения стратегий обучения — при равном бюджете.

Роль самой заморозки формулируется сдержанно: по приземной температуре при равном бюджете расписание на итог не влияет (1,82 против 1,82 °C), тогда как по агрегату различие составляет 1,3 п.п. (60,8 против 59,5 %) в пользу заморозки. Это ещё один случай расхождения агрегата и поканальных значений, разбираемый в п. 4.6. Однако адаптация процессора под регион необходима: при заморозке на всё обучение ошибка одношагового прогноза на проверочной выборке оказывается на 7,5 % выше, обучение выходит на плато уже к восьмой эпохе, и растёт также ошибка на обучающей выборке — модели не хватает свободы подстроить динамику, а не данных. Оговорим, что эта величина измерена той самой метрикой, ненадёжность которой для отбора состояния показана выше; здесь она привлекается не для отбора, а как признак недообучения (одновременный рост ошибки на обучающей выборке), и в этом качестве законна. Оценка того же эффекта при полной развёртке не выполнялась.

Расхождение агрегатного показателя и поканальных значений

Сопоставление строк табл. 4 обнаруживает обстоятельство, существенное для методики отчётности: по агрегатной успешности конфигурации различаются на 1,3 процентного пункта (60,8; 59,9 и 59,5 %), тогда как по приземной температуре при равном бюджете совпадают в точности (1,82 = 1,82 °C). Причина та же, что и в п. 4.4: агрегат усредняет нормированные ошибки по всем каналам, и вклад каждого определяется отношением его ошибки к разбросу поля, а не значимостью канала для практики. Ранжирование конфигураций поэтому зависит от того, какое поле и какая область осреднения объявлены целевыми, и в отчётности следует приводить и агрегат, и поканальные значения по целевым полям на одной и той же маске узлов.

Диагностика стыка

Утверждение о том, что жёсткая склейка узлов не требует отдельной процедуры сшивания, проверено прямо: ошибка приземной температуры вычислена по полосам расстояния до границы региональной вставки (табл. 5). Оценка выполнена на 100 сроках тестовой выборки.

Табл. 5. Ошибка приземной температуры (°C) по расстоянию до границы вставки. Положительное расстояние — внутри вставки (шаг 0,25°), отрицательное — снаружи, на глобальной части графа (шаг 0,703°).

Зона	Расстояние до границы, км	Узлов	+6 ч	+12 ч	+18 ч	+24 ч
Вставка 0,25°	0–25	278	1,58	1,97	2,06	2,12
	25–50	240	1,54	1,92	2,00	2,08
	50–100	414	1,51	1,85	1,94	2,02
	100–200	698	1,49	1,81	1,91	1,99
	200–1000	871	1,40	1,80	1,97	2,07
Глобальная 0,703°	–100...0	143	1,37	1,74	1,82	1,87
	–300...–100	308	1,42	1,76	1,88	1,95
	–1000...–300	1708	1,36	1,73	1,91	2,05

Переходный слой существует. На горизонте +6 ч ошибка убывает монотонно по мере удаления от границы: 1,58 °C в полосе шириной 25 км против 1,40 °C в глубине области, то есть у стыка она выше на 13 %; эффект прослеживается примерно на 100–200 км. Утверждать полную бесшовность неправомерно.

Однако в авторегрессии он не усиливается. Относительно полосы 200–1000 км превышение убывает с 13 % на +6 ч до 2 % на +24 ч, но эта полоса перестаёт быть минимумом на дальних сроках: на +18 и +24 ч наименьшая ошибка приходится на полосу 100–200 км. Относительно минимума превышение у стыка составляет 6,0 / 8,8 / 7,9 / 6,5 % по четырём горизонтам, то есть держится на уровне 6–9 % и с горизонтом не растёт. Убывание относительно дальней полосы отражает рост ошибки в глубине области, а не рассасывание переходного слоя. Это принципиально, поскольку именно неограниченный рост приграничной ошибки составляет основную трудность региональных моделей с внешними граничными условиями. Убывание объясняется тем, что на дальних сроках преобладает другой источник ошибки — рельеф: в глубине области расположены горные районы.

Глобальная часть не страдает: непосредственно за границей вставки ошибка (1,87 °C на +24 ч) не превышает значений вдали от неё (1,95 и 2,05 °C).

Итоговая формулировка: склейка порождает контролируемый переходный слой шириной порядка 100 км, заметный на ближних горизонтах и затухающий на дальних, и не требует отдельной процедуры сшивания полей.

Усвоение наблюдений в цикле прогноза

Постановка задачи и методы

Ошибка авторегрессионного прогноза нарастает с горизонтом, поэтому естественный способ ограничить рост — периодически корректировать состояние по измерениям. Специальная процедура необходима из-за несоответствия двух представлений информации: модели требуется значение каждой переменной во всех 133 279 узлах, тогда как наблюдения доступны в отдельных точках и распределены неравномерно. Задача усвоения — совместить полноту прогностического поля с точностью измерений, распространив информацию из точек наблюдений на окрестность физически осмысленным образом [5].

Исследуются два классических метода, применяемых пошагово внутри авторегрессионной развёртки: после каждого шага прогноза поле корректируется, и уже исправленное состояние подаётся на вход следующего шага.

Существенна оговорка о том, какая именно величина оценивается. Коррекция на шаге k использует наблюдения, действительные на срок этого же шага; поле после коррекции представляет собой анализ, а не прогноз, и его сопоставление с истиной завышает качество тем сильнее, чем плотнее сеть. Поэтому во всех приводимых ниже оценках метрика вычисляется по полю **до** коррекции, тогда как вперёд передаётся исправленное состояние. Измеряется таким образом шестичасовой прогноз из предыдущего анализа — стандартная проверка циклической системы усвоения. Прямое следствие такого определения видно в табл. 7: на горизонте +6 ч все режимы совпадают, поскольку до первой коррекции усвоение ещё не действовало.

Релаксационное усвоение (нуджинг). Простейшая схема — линейная релаксация к наблюдениям в узлах, где они доступны:

$$x_g^a = x_g^b + \alpha m_g (y_g - x_g^b), \quad (8)$$

где x_g^b — прогностическое (фоновое) значение в узле g ; y_g — наблюдение; $m_g \in \{0,1\}$ — индикатор наличия наблюдения; α — коэффициент релаксации; x_g^a — скорректированное значение. Схема вычислительно тривиальна, но коррекция применяется только в наблюдаемых узлах: при разрежённой сети это порождает локальные возмущения, не согласованные с окружающим полем.

Оптимальная интерполяция [5] учитывает пространственную структуру ошибок и распространяет поправку на окрестность каждого наблюдения:

$$\mathbf{x}^a = \mathbf{x}^b + \mathbf{K}(\mathbf{y} - \mathbf{H}\mathbf{x}^b), \quad \mathbf{K} = \mathbf{B}\mathbf{H}^T (\mathbf{H}\mathbf{B}\mathbf{H}^T + \mathbf{R})^{-1}, \quad (9)$$

где $\mathbf{H}$ — оператор наблюдений, сопоставляющий состоянию модели значения в точках измерений (реализован как выбор ближайшего узла сетки); $\mathbf{B}$ — ковариационная матрица ошибок фона; $\mathbf{R}$ — ковариационная матрица ошибок наблюдений; $\mathbf{K}$ — матрица усиления. Ковариации ошибок фона задаются гауссовой моделью, убывающей с расстоянием: $B_{ij} =$

$\sigma_b^2 \exp(-d_{ij}^2/L^2)$, где d_{ij} — расстояние между узлами по формуле гаверсина, L — радиус корреляции, σ_b — среднеквадратическое отклонение ошибки фона. Ошибки наблюдений полагаются некоррелированными: $\mathbf{R} = \sigma_o^2 \mathbf{I}$. Усвоение выполняется независимо для каждой переменной, матрица $\mathbf{B}$ строится однократно.

Матрица усиления зависит не от σ_b и σ_o по отдельности, а только от их отношения, поэтому $\sigma_b = 0,8$ фиксировано, а подбирается σ_o .

Обоснование выбора методов

Современные оперативные системы усвоения используют преимущественно вариационные методы либо ансамблевые фильтры Калмана, превосходящие оптимальную интерполяцию по точности [15, 16]. Выбор более простых схем здесь продиктован постановкой задачи. Во-первых, целью является не построение оптимальной системы усвоения, а проверка принципиальной совместимости пошаговой коррекции с авторегрессионным нейросетевым прогнозом: прогностический оператор — обученная сеть, а не численное интегрирование уравнений, и поведение цикла «прогноз — коррекция» в таком сочетании заранее неочевидно. Во-вторых, вариационные методы требуют построения сопряжённой модели, ансамблевые — многократного прогона модели; и то, и другое составляет самостоятельную задачу. В-третьих, схемы (8) и (9) вычислительно пренебрежимы на фоне самого прогноза и не нарушают основного свойства подхода — выпуска прогноза за секунды на одном ускорителе.

Постановка эксперимента

Эксперименты выполнены по схеме «идентичных близнецов»: в качестве наблюдений используются значения реанализа в случайно выбранном подмножестве узлов региональной вставки. Рассмотрены две плотности — 10 % узлов (около 250 условных станций) и 1 % (около 25), причём вторая ближе к реальной плотности наземной сети в регионе.

Постановка идеализирована: наблюдения не содержат инструментальной погрешности и ошибки репрезентативности, размещены строго в узлах сетки и доступны для всех переменных одновременно. Полученные величины характеризуют поэтому верхнюю границу возможного эффекта.

Радиус корреляции ошибок фона L и дисперсия ошибок наблюдений σ_o подбирались на проверочной выборке, результаты приводятся на тестовой; прогоны на тестовой выборке повторены с тремя различными расстановками условных станций.

Табл. 6. Подбор гиперпараметров оптимальной интерполяции на проверочной выборке (200 сроков, регион): агрегатная успешность и ошибка приземной температуры по горизонтам +6 / +12 / +18 / +24 ч.

L , км	σ_o	$\bar{S}$, %	RMSE t2m по горизонтам, °C
50	0,3	80,61	1,24 / 1,35 / 1,38 / 1,42
50	0,5	80,56	1,24 / 1,36 / 1,39 / 1,42
50	1,0	80,31	1,24 / 1,39 / 1,42 / 1,46
100	0,3	80,51	1,24 / 1,35 / 1,40 / 1,43
100	0,5	80,57	1,24 / 1,36 / 1,39 / 1,42
100	1,0	80,52	1,24 / 1,37 / 1,40 / 1,43
150	0,3	80,50	1,24 / 1,37 / 1,40 / 1,43
150	0,5	80,53	1,24 / 1,37 / 1,40 / 1,43
150	1,0	80,50	1,24 / 1,38 / 1,41 / 1,44
200	0,3	80,47	1,24 / 1,37 / 1,41 / 1,44
200	0,5	80,50	1,24 / 1,38 / 1,41 / 1,44
200	1,0	80,48	1,24 / 1,38 / 1,42 / 1,45

Качество прогноза оказывается слабо чувствительным к обоим параметрам: весь разброс по двенадцати сочетаниям укладывается в 0,30 процентного пункта. Это само по себе содержательно. Радиус корреляции и доверие к наблюдениям определяют, насколько точно анализ ляжет на измерения, но для последующего прогноза этот выбор второстепенен — модель переуравновешивает поле за один шаг. Различима лишь общая тенденция: $\sigma_o = 1,0$ систематически хуже на всех радиусах, то есть чрезмерное недоверие к наблюдениям ослабляет коррекцию заметнее, чем неточный радиус. Во всех расчётах на тестовой выборке используется $L = 100$ км, $\sigma_o = 0,5$.

Табл. 7. Усвоение наблюдений на тестовой выборке (1607 сроков, все сезоны, регион — 2501 узел). Ошибка приземной температуры, °C, по горизонтам и агрегатная успешность $\bar{S}$. Метрика вычислена по полю до коррекции (см. п. 5.1). Оптимальная интерполяция при 10 % — среднее по трём независимым расстановкам условных станций.

Режим усвоения	+6 ч	+12 ч	+18 ч	+24 ч	$\bar{S}$, %
Без усвоения	1,18	1,36	1,40	1,46	74,55
Нуджинг, 10 % узлов, $\alpha = 0,5$	1,18	1,35	1,38	1,43	74,81
Нуджинг, 10 % узлов, $\alpha = 0,7$	1,18	1,35	1,38	1,43	74,88
Нуджинг, 10 % узлов, $\alpha = 0,9$	1,18	1,34	1,38	1,43	74,93
Оптимальная интерполяция, 1 % узлов	1,18	1,34	1,37	1,40	75,62
Оптимальная интерполяция, 10 % узлов	1,18	1,26	1,27	1,28	76,52

Из табл. 7 следуют четыре наблюдения.

Во-первых, выигрыш отсутствует на горизонте +6 ч и растёт с горизонтом: 0 %, 7,4 %, 9,3 % и 12,3 % при плотности 10 %. Это прямое следствие определения метрики: первый шаг выполняется из настоящего начального поля, и корректировать в нём нечего, тогда как на последующих шагах прогноз стартует из всё более точного анализа. Совпадение всех режимов в первом столбце служит проверкой корректности расчёта.

Во-вторых, оптимальная интерполяция превосходит релаксационное усвоение при одной и той же плотности наблюдений: 1,28 против 1,43 °C на суточном сроке. Нуджинг правит поле только в наблюдаемых узлах, тогда как оптимальная интерполяция распространяет поправку на окрестность согласно структуре ковариаций ошибок фона.

В-третьих, среди испытанных значений коэффициента релаксации лучшим оказывается $\alpha = 0,9$, причём зависимость монотонна. В идеализированной постановке, где наблюдения не содержат приборной погрешности, оптимальным был бы предельный случай прямой подстановки; при реальных наблюдениях такой вывод не переносится.

В-четвёртых, разброс по трём расстановкам условных станций пренебрежимо мал: агрегатная успешность 76,48, 76,54 и 76,54 %. Результат не зависит от конкретного размещения сети.

Усвоение на длинных горизонтах

Мотивировка усвоения опирается на деградацию прогноза при длительной развёртке, тогда как приведённые выше оценки ограничены сроком +24 ч. Поэтому выполнена серия расчётов с развёрткой на 56 шагов (336 ч) в четырёх режимах: без усвоения; с оптимальной интерполяцией на каждом шаге при плотности 10 %; с усвоением только на первых четырёх шагах; с усвоением на каждом шаге при плотности 1 %. Оценка — на 200 сроках тестовой выборки, область — региональная вставка (табл. 8).

Табл. 8. Ошибка прогноза приземной температуры (°C) при развёртке до 336 ч (14 суток). Основная конфигурация, 200 сроков, регион (2501 узел).

Горизонт	Без усвоения	ОИ, 10 %	ОИ, 10 %, первые 4 шага	ОИ, 1 %
+24 ч	1,72	1,43	1,43	1,62
+48 ч	2,10	1,57	1,97	1,84
+72 ч	2,66	1,67	2,59	1,99
+120 ч	4,33	1,93	4,28	2,38
+168 ч	6,19	2,20	6,16	2,76
+336 ч	9,94	3,10	10,02	3,86
$\bar{S}$ за все 56 шагов, %	28,4	54,2	28,8	51,1

Из табл. 8 следуют три вывода.

Без усвоения ошибка растёт монотонно во всём диапазоне — от 1,72 °C на суточном сроке до 9,94 °C на четырнадцатисуточном. Резкого обрыва не происходит, деградация постепенная, однако ошибка свыше 4 °C на сроках более пяти суток делает прогноз практически непригодным.

Непрерывное усвоение принципиально меняет характер деградации: ошибка возрастает лишь вдвое, с 1,43 до 3,10 °C, а агрегатная успешность держится на уровне 54,2 % против 28,4 %. Существенна оговорка о смысле величины: в режиме с усвоением значение в колонке «+336 ч» — это ошибка шестичасового прогноза из анализа, действительного на 330-м часу работы цикла, а не прогноза на 336 ч. Сопоставлять её с прогнозом без усвоения на том же горизонте нельзя: это разные величины. Корректное сравнение таково: ошибка шестичасового прогноза в цикле усвоения на четырнадцатые сутки работы цикла (3,10 °C) меньше, чем ошибка свободного прогноза уже на пятые сутки (4,33 °C на +120 ч). Коррекция снимает накопленную погрешность, и авторегрессия перестаёт быть источником неограниченного роста ошибки.

Действие коррекции недолговечно, и режим с усвоением только на первых четырёх шагах позволяет измерить его длительность прямо. После прекращения поступления наблюдений выигрыш составляет 19,6 % через шесть часов, 11,9 % через двенадцать, 8,5 % через восемнадцать и 6,2 % через сутки; к четвёртым суткам кривая сливается с прогоном без усвоения. «Память» модели о коррекции составляет, таким образом, порядка суток, и улучшение качества требует регулярного поступления наблюдений, а не точной инициализации.

Снижение плотности наблюдений в десять раз (с 10 до 1 % узлов, то есть примерно с 250 до 25 условных станций, что ближе к реальной сети) ослабляет эффект, но не устраняет: 1,62 против 1,72 °C на суточном сроке и 3,86 против 9,94 °C на четырнадцатисуточном. Вывод устойчив к разрежённости сети.

Устойчивость и остаточная формулировка

Отдельного внимания заслуживает роль остаточной формулировки, то есть предсказания приращения поля вместо самого поля. В 19-канальной линии моделей (п. 4.5) конфигурация без неё до суточного срока практически не отличалась от основной, но на дальних сроках теряла устойчивость: ошибка достигала 15,6 °С на семисуточном сроке против 7,3 °С, а успешность обращалась в ноль около +126 ч и далее становилась отрицательной. Признаком раскачки служила немонотонность ошибки по горизонтам, отсутствующая у основной конфигурации.

Существенно, что усвоение этот дефект ослабляет, но не устраняет: при непрерывной коррекции переход успешности через ноль лишь отодвигается примерно на сутки. Остаточная формулировка и усвоение решают разные задачи и друг друга не заменяют.

Обсуждение, выводы и направления дальнейшей работы

Обсуждение

Полученные результаты объединяются тремя соображениями.

Регион не требует большой модели. Прогноз над областью 50–60° с. ш., 83–98° в. д. получен моделью объёмом 5,9 млн параметров, обучение и расчёт которой укладываются в одну видеокарту, — на два-три порядка меньше, чем у известных региональных нейросетевых систем [7, 9], построенных на глобальных моделях с сотнями миллионов параметров [1]. Воспроизведение схемы посилено региональному управлению по гидрометеорологии, располагающему одним вычислительным узлом. Отдельная процедура согласования полей на стыке разрешений не потребовалась: диагностика (п. 4.7) показывает переходный слой шириной около 100 км, не усиливающийся в авторегрессии.

Качество определяется не архитектурой, а распределением обучающего сигнала. Из проверенных вмешательств ни одно не касалось устройства сети. Расписание заморозки процессора на итог не влияет, тогда как сама адаптация процессора необходима; отбор состояния по одношаговой ошибке ненадёжен для многошагового прогноза; наибольший же выигрыш дало явное взвешивание функции потерь по узлам и каналам — приёмы, ничего не меняющие ни в числе параметров, ни в объёме обучения. При этом у обоих весов обнаруживается внутренний максимум, и по одной причине: усиленная часть задачи отбирает ресурс у той, от которой сама зависит. Для целевой области это приток извне, для приземных каналов — поля, формирующие приземную погоду.

Классическое усвоение переносится на нейросетевую модель без изменений. Обученная сеть используется как детерминированный оператор прогноза, а коррекция наблюдениями выполняется в пространстве состояний между авторегрессионными шагами: переобучения не требуется, стоимость шага усвоения пренебрежима, формулировки схем [5] сохраняются дословно. Существенно, что необходимо именно непрерывное поступление наблюдений: после прекращения коррекции выигрыш убывает с 20 % через шесть часов до 6 % через сутки, а к

четвёртым суткам прогноз неотличим от расчёта вообще без усвоения. Точная инициализация, таким образом, ценна много меньше регулярного потока измерений.

Приёмы, не давшие эффекта

Три приёма, ожидавшихся полезными, проверены и отвергнуты; каждый — по измеренной причине, представляющейся общей для моделей такого класса.

Внесение шума в авторегрессию, известное как средство против накопления ошибки, ухудшило результат: при единой дисперсии для всех каналов ошибка на проверочной выборке оказалась на 15 % выше контрольной, при дисперсии, пропорциональной разбросу шестичасовой невязки канала, — на 5 % выше. Приём защищает от накопления при длинной развёртке, тогда как обучение и оценка здесь ведутся на четырёх шагах: накопление невелико, а плата за обучение на искажённых входах сохраняется.

Ансамблирование не улучшило результата: 74,80 % для двух участников и 74,63 % для трёх против 74,85 % у лучшего одиночного. Причина установлена количественно: ансамбль превосходит средний по участникам результат лишь на 0,18 % для пары и 0,74 % для тройки. Для пары участников с равной дисперсией ошибки отношение ошибки ансамбля к средней равно $\sqrt{(1+\rho)/2}$, откуда $\rho = 0,993$; оценка по тройке дана тем же способом и приводит к близкому значению. Все конфигурации получены дообучением одной исходной модели, которая и определяет поле ошибки; независимого разнообразия, за счёт которого ансамбль работает, между ними нет.

Обучение на удлинённой развёртке (двенадцать шагов вместо четырёх) выигрыша не дало: агрегатная успешность за пять суток 64,38 против 64,49 %, и здесь, в отличие от предыдущих сравнений, различие статистически не установлено — интервал разности $[-1,01; +0,59]$ накрывает ноль (выборка вчетверо меньше, 500 сроков); а на сроках до трёх суток удлинённая конфигурация систематически уступает. Существенно, что при сквозном распространении градиента память растёт пропорционально длине развёртки и двенадцать шагов в память ускорителя не помещаются, поэтому градиент между шагами приходилось разрывать. Вероятно, именно передача градиента между шагами и составляет основную пользу приёма.

Ограничения

Межзапусковая изменчивость оценена одним повторным обучением с иным начальным значением генератора случайных чисел: расхождение по сводному показателю составило 0,03 процентного пункта (73,41 против 73,40 %), что позволяет интерпретировать различия начиная с десятых долей процентного пункта. Оценка получена по одной паре прогонов и на большее число повторов не опирается. Эксперименты по усвоению поставлены по схеме «идентичный двойник»: в роли наблюдений выступают значения реанализа [11] в случайно выбранных узлах, ошибка измерения и ошибка репрезентативности [5] не моделируются, реальная сеть станций разрежена неоднородно, — поэтому полученный вклад усвоения следует считать верхней оценкой. Вес целевой области $W = 30$ и стратегия дообучения выбраны по

табл. 3 и 4, посчитанным на **тестовой** выборке, а не на проверочной (последняя служила для отбора состояния модели и параметров усвоения, табл. 6). Отбор одного гиперпараметра из четырёх значений — слабая форма переиспользования, но она есть, и величины для $W = 30$ следует считать слегка оптимистичными. Веса каналов вычислены по обучающей выборке и этой оговорки не требуют.

Гиперпараметры усвоения подбирались на той же территории, где оценивается качество; разделение выборок по времени соблюдено, но перенос значений радиуса корреляции и дисперсии ошибок наблюдений на другую территорию не проверялся.

Истиной служит реанализ, а не станционные наблюдения; реанализ сглаживает подсеточные эффекты, включая городской остров тепла, поэтому оценки не переносятся напрямую на прогноз в точке станции без постобработки. Эталоном служат инерционный прогноз и прогноз глобальной модели, интерполированный в узлы вставки; сопоставление с оперативной численной моделью атмосферы не проводилось, и при таком сравнении необходимо будет учесть, что модель, обученная на реанализе, оценивается против реанализа и находится в благоприятном положении [14]. Наконец, результаты получены для одной территории и одного тестового окна; прямое сравнение мультимасштабного подхода с региональной моделью с граничным форсингом [6] не проводилось.

Направления дальнейшей работы

Уплотнение мультимасштабного графа за счёт слияния всех уровней икосаэдрической мозаики, а не двух, — приём, дающий дальние связи без роста числа параметров; расширение состава прогностических полей и переход к прогнозу с оценкой неопределённости через ансамбль возмущённых начальных состояний либо порождающие вероятностные модели [17]; верификация по данным сети станций как условие принятия схемы оперативной практикой; наконец, включение циклического усвоения поступающих наблюдений в автоматический цикл выпуска прогноза.

Отдельно отметим направление, естественное именно для нейросетевой постановки. Обученная сеть дифференцируема по входу, поэтому сопряжённая модель, построение которой составляет основную трудность вариационного усвоения в традиционных численных моделях, здесь не нужна: градиент вычисляется обратным распространением через авторегрессионную развёртку. Это открывает путь к четырёхмерному вариационному усвоению, согласующему начальное состояние сразу по нескольким срокам наблюдений вместо пошаговой коррекции поля [15].

Выводы

1. Построена и проверена мультимасштабная графовая нейронная сеть регионального прогноза погоды на едином графе, где глобальная и региональная части соединены без отдельной процедуры сшивающих полей; диагностика стыка показывает переходный слой шириной около 100 км, затухающий с ростом горизонта. Обучение и расчёт

выполняются на одной видеокарте, что делает воспроизведение схемы посильным для регионального гидрометеорологического подразделения.

2. Единый граф превосходит интерполяцию прогноза глобальной модели в узлы области по всем полям: выигрыш от 11 % по приземной температуре до 37–40 % по ветру и геопотенциалу.
3. Установлено, что отбор обученного состояния по ошибке одношагового прогноза ненадёжен для многошагового; расписание заморозки процессора на итог не влияет, тогда как сама адаптация процессора необходима и даёт около 7,5 % по ошибке на проверочной выборке.
4. Показано, что единственный агрегатный показатель скрывает различное поведение модели по отдельным полям; верификацию необходимо отчитывать покомпонентно.
5. Установлено, что распределение обучающего сигнала, возникающее при равномерном усреднении функции потерь, далеко от постановки задачи: узлы целевой области получают 1,9 % сигнала, а приземная температура — 0,46 %. Явное взвешивание снижает ошибку приземной температуры на 12 % без изменения архитектуры и объёма обучения, причём у веса целевой области обнаруживается внутренний максимум, определяемый зависимостью прогноза внутри области от притока извне.
6. Продемонстрирована совместимость классических последовательных схем усвоения с обученной нейросетевой моделью: за четырнадцать суток работы цикла ошибка шестичасового прогноза из анализа возрастает вдвое, тогда как ошибка свободного прогноза на том же горизонте — почти вшестеро (в 5,8 раза); после прекращения поступления наблюдений выигрыш убывает с 20 % через шесть часов до 6 % через сутки.
7. Основные ограничения — единственный прогон обучения, синтетический характер усваиваемых наблюдений, оценка качества против реанализа и отсутствие сравнения с оперативной моделью — определяют содержание ближайших этапов исследования.

Список литературы

1. Lam R., Sanchez-Gonzalez A., Willson M. et al. Learning skillful medium-range global weather forecasting // *Science*. 2023. Vol. 382, No. 6677. P. 1416–1421. DOI: 10.1126/science.adi2336.
2. Bi K., Xie L., Zhang H. et al. Accurate medium-range global weather forecasting with 3D neural networks // *Nature*. 2023. Vol. 619, No. 7970. P. 533–538. DOI: 10.1038/s41586-023-06185-3.
3. Pathak J., Subramanian S., Harrington P. et al. FourCastNet: A global data-driven high-resolution weather model using adaptive Fourier neural operators // *arXiv:2202.11214*. 2022.

4. Davies H. C. A lateral boundary formulation for multi-level prediction models // Quarterly Journal of the Royal Meteorological Society. 1976. Vol. 102, No. 432. P. 405–418. DOI: 10.1002/qj.49710243210.
5. Гандин Л. С. Объективный анализ метеорологических полей. Л.: Гидрометеиздат, 1963. 286 с.
6. Oskarsson J., Landelius T., Lindsten F. Graph-based neural weather prediction for limited area modeling // arXiv:2309.17370. 2023.
7. Nipen T. N., Haugen H. H., Ingstad M. S. et al. Regional data-driven weather modeling with a global stretched grid // Artificial Intelligence for the Earth Systems. 2026. Vol. 5, No. 2. Art. e250001. DOI: 10.1175/AIES-D-25-0001.1.
8. Gao Y., Wu H., Shu R. et al. OneForecast: A universal framework for global and regional weather forecasting // Proceedings of the 42nd International Conference on Machine Learning (ICML). PMLR, 2025. Vol. 267. P. 18658–18697.
9. Wijnands J. S., Van Genderachter M., François B. et al. Data-driven regional weather forecasting: A comparison of stretched-grid and limited-area modelling // Machine Learning with Applications. 2026. Vol. 24. Art. 100887. DOI: 10.1016/j.mlwa.2026.100887.
10. Толстых М. А., Шашкин В. В., Фадеев Р. Ю. и др. Система моделирования атмосферы для бесшовного прогноза. М.: Триада ЛТД, 2017. 166 с.
11. Hersbach H., Bell B., Berrisford P. et al. The ERA5 global reanalysis // Quarterly Journal of the Royal Meteorological Society. 2020. Vol. 146, No. 730. P. 1999–2049. DOI: 10.1002/qj.3803.
12. Battaglia P. W., Pascanu R., Lai M. et al. Interaction networks for learning about objects, relations and physics // Advances in Neural Information Processing Systems (NIPS). 2016. Vol. 29. P. 4502–4510.
13. Künsch H. R. The jackknife and the bootstrap for general stationary observations // The Annals of Statistics. 1989. Vol. 17, No. 3. P. 1217–1241. DOI: 10.1214/aos/1176347265.
14. Rasp S., Hoyer S., Merose A. et al. WeatherBench 2: A benchmark for the next generation of data-driven global weather models // Journal of Advances in Modeling Earth Systems. 2024. Vol. 16, No. 6. Art. e2023MS004019. DOI: 10.1029/2023MS004019.
15. Courtier P., Thépaut J.-N., Hollingsworth A. A strategy for operational implementation of 4D-Var, using an incremental approach // Quarterly Journal of the Royal Meteorological Society. 1994. Vol. 120, No. 519. P. 1367–1387. DOI: 10.1002/qj.49712051912.
16. Evensen G. The Ensemble Kalman Filter: theoretical formulation and practical implementation // Ocean Dynamics. 2003. Vol. 53. P. 343–367. DOI: 10.1007/s10236-003-0036-9.
17. Price I., Sanchez-Gonzalez A., Alet F. et al. Probabilistic weather forecasting with machine learning // Nature. 2025. Vol. 637, No. 8044. P. 84–90. DOI: 10.1038/s41586-024-08252-9.

References

1. Lam R., Sanchez-Gonzalez A., Willson M. et al. Learning skillful medium-range global weather forecasting. *Science*, 2023, vol. 382, no. 6677, pp. 1416–1421. DOI: 10.1126/science.adi2336.
2. Bi K., Xie L., Zhang H. et al. Accurate medium-range global weather forecasting with 3D neural networks. *Nature*, 2023, vol. 619, no. 7970, pp. 533–538. DOI: 10.1038/s41586-023-06185-3.
3. Pathak J., Subramanian S., Harrington P. et al. FourCastNet: A global data-driven high-resolution weather model using adaptive Fourier neural operators. *arXiv:2202.11214*, 2022.
4. Davies H.C. A lateral boundary formulation for multi-level prediction models. *Quarterly Journal of the Royal Meteorological Society*, 1976, vol. 102, no. 432, pp. 405–418. DOI: 10.1002/qj.49710243210.
5. Gandin L.S. Ob"ektivnyi analiz meteorologicheskikh polei [Objective Analysis of Meteorological Fields]. Leningrad, Gidrometeoizdat Publ., 1963, 286 p. [in Russ.]
6. Oskarsson J., Landelius T., Lindsten F. Graph-based neural weather prediction for limited area modeling. *arXiv:2309.17370*, 2023.
7. Nipen T.N., Haugen H.H., Ingstad M.S. et al. Regional data-driven weather modeling with a global stretched grid. *Artificial Intelligence for the Earth Systems*, 2026, vol. 5, no. 2, art. e250001. DOI: 10.1175/AIES-D-25-0001.1.
8. Gao Y., Wu H., Shu R. et al. OneForecast: A universal framework for global and regional weather forecasting. *Proceedings of the 42nd International Conference on Machine Learning (ICML)*, PMLR, 2025, vol. 267, pp. 18658–18697.
9. Wijnands J.S., Van Genderachter M., François B. et al. Data-driven regional weather forecasting: A comparison of stretched-grid and limited-area modelling. *Machine Learning with Applications*, 2026, vol. 24, art. 100887. DOI: 10.1016/j.mlwa.2026.100887.
10. Tolstykh M.A., Shashkin V.V., Fadeev R.Yu. et al. Sistema modelirovaniya atmosfery dlya besshovnogo prognoza [Atmosphere Modelling System for Seamless Prediction]. Moscow, Triada Ltd. Publ., 2017, 166 p. [in Russ.]
11. Hersbach H., Bell B., Berrisford P. et al. The ERA5 global reanalysis. *Quarterly Journal of the Royal Meteorological Society*, 2020, vol. 146, no. 730, pp. 1999–2049. DOI: 10.1002/qj.3803.
12. Battaglia P.W., Pascanu R., Lai M. et al. Interaction networks for learning about objects, relations and physics. *Advances in Neural Information Processing Systems (NIPS)*, 2016, vol. 29, pp. 4502–4510.
13. Künsch H.R. The jackknife and the bootstrap for general stationary observations. *The Annals of Statistics*, 1989, vol. 17, no. 3, pp. 1217–1241. DOI: 10.1214/aos/1176347265.

14. Rasp S., Hoyer S., Merose A. et al. WeatherBench 2: A benchmark for the next generation of data-driven global weather models. *Journal of Advances in Modeling Earth Systems*, 2024, vol. 16, no. 6, art. e2023MS004019. DOI: 10.1029/2023MS004019.
15. Courtier P., Thépaut J.-N., Hollingsworth A. A strategy for operational implementation of 4D-Var, using an incremental approach. *Quarterly Journal of the Royal Meteorological Society*, 1994, vol. 120, no. 519, pp. 1367–1387. DOI: 10.1002/qj.49712051912.
16. Evensen G. The Ensemble Kalman Filter: theoretical formulation and practical implementation. *Ocean Dynamics*, 2003, vol. 53, pp. 343–367. DOI: 10.1007/s10236-003-0036-9.
17. Price I., Sanchez-Gonzalez A., Alet F. et al. Probabilistic weather forecasting with machine learning. *Nature*, 2025, vol. 637, no. 8044, pp. 84–90. DOI: 10.1038/s41586-024-08252-9.