

Мультимасштабная графовая нейросетевая модель регионального прогноза погоды

А.С. Табаков^{1,2}, А.В. Пененко¹

¹Институт вычислительной математики и математической геофизики СО РАН, г. Новосибирск, Россия; ²Новосибирский государственный университет, г. Новосибирск, Россия
artur.tabakov11@gmail.com

Представлена региональная нейросетевая модель прогноза погоды над югом Красноярского края, построенная на графовом представлении атмосферного состояния. Глобальная расчётная сетка с шагом $0,703^\circ$ и региональная вставка с шагом $0,25^\circ$ объединены в единую расчётную сетку из 133 279 узлов, образующую единый граф, что устраняет необходимость задания внешних граничных условий: согласование разрешений на стыке достигается механизмом обмена сообщениями в процессе обучения. Модель содержит 5,9 млн обучаемых параметров, обучение и выпуск прогноза выполняются на одном графическом ускорителе. Оценка на независимой выборке из 1607 сроков (все сезоны) показала среднеквадратическую ошибку прогноза приземной температуры $1,47^\circ\text{C}$ на суточном сроке при агрегатной успешности 74,4 % относительно инерционного прогноза и аномальной корреляции 0,975 относительно климатологии. Показано, что распределение обучающего сигнала по узлам графа и по каналам, возникающее при равномерном усреднении функции потерь, далеко от постановки задачи; явное взвешивание снижает ошибку приземной температуры на 10,2 % в среднем по горизонтам при равном объёме обучения (12,0 % на суточном сроке) без изменения архитектуры. В контрольном эксперименте с равным бюджетом обучения установлено, что ошибка на проверочной выборке при одношаговом прогнозе является ненадёжным критерием отбора модели для многошагового прогноза.

Ключевые слова: численный прогноз погоды, графовая нейронная сеть, региональный прогноз, мультимасштабная сетка, авторегрессионный прогноз, функция потерь, машинное обучение

A multiscale graph neural network for regional weather forecasting

A.S. Tabakov^{1,2}, A.V. Penenko¹

¹Institute of Computational Mathematics and Mathematical Geophysics SB RAS, Novosibirsk, Russia; ²Novosibirsk State University, Novosibirsk, Russia
artur.tabakov11@gmail.com

A regional neural network weather forecasting model for the south of Krasnoyarsk Krai based on a graph representation of the atmospheric state is presented. A global mesh of 0.703° and a

regional insert of 0.25° are combined into a single graph of 133,279 nodes, removing the need for external lateral boundary conditions: the resolutions are reconciled at the interface by the message passing mechanism during training. The model has 5.9 million trainable parameters; both training and forecast production run on a single GPU. On an independent sample of 1607 initial times covering all seasons the root-mean-square error of the 2-m temperature forecast is 1.47°C at the 24-h lead time, with an aggregate skill score of 74.4 % against persistence and an anomaly correlation of 0.975 against climatology. The distribution of the training signal over nodes and channels arising from uniform averaging of the loss is shown to be far from the task; explicit weighting reduces the 2-m temperature error by 10.2 % at an equal training budget and with no change to the architecture. A controlled experiment at an equal training budget shows the single-step validation error to be an unreliable criterion for selecting a model for multi-step forecasting.

Keywords: numerical weather prediction, graph neural network, regional forecasting, multiscale mesh, autoregressive forecast, loss function, machine learning

Введение

Численный прогноз погоды основан на интегрировании уравнений гидротермодинамики атмосферы на сетке высокого разрешения; в России прогноз этого класса выпускается оперативно по полулагранжевой модели ПЛАВ [1]. Подход достиг высокой точности, но расчёт одного глобального прогноза на средние сроки требует часов работы суперкомпьютера, что ограничивает и частоту обновления, и размер ансамбля.

В 2022–2023 годах произошёл качественный сдвиг: нейросетевые модели, обученные на архиве реанализа, показали точность, сопоставимую с оперативными системами ведущих метеоцентров, при несопоставимо меньших затратах на выпуск прогноза. Модель GraphCast [8], построенная на графовом представлении атмосферного состояния, превзошла оперативную систему Европейского центра по большинству переменных на сроках от трёх до десяти суток; сопоставимые результаты получены моделями Pangu-Weather [3] и FourCastNet [11]. Ключевой элемент GraphCast — представление расчётной области графом с квазиравномерным распределением узлов по сфере (п. 3.1).

Большинство таких систем решает глобальную задачу, тогда как практический интерес часто представляет прогноз повышенной детальности над ограниченной территорией. Главная трудность переноса — граничные условия: у краевых узлов вырезанной области нет корректного окружения, и в классическом прогнозе это решается релаксацией к внешнему полю в буферной зоне [4], что требует отдельной процедуры и вносит свои погрешности. Добавляется накопление ошибки в авторегрессионной развёртке, для ограниченной области выраженное сильнее.

В нейросетевых региональных моделях предложено несколько способов обойти проблему границ: подача граничного форсинга от глобальной модели в архитектуре Neural-LAM [10]; растянутая сетка с плавным изменением разрешения [9]; вложенные сетки с обменом

информацией между уровнями [5]. Сравнение подходов с растянутой сеткой и с ограниченной областью выполнено в [13].

Настоящая работа посвящена региональной модели прогноза над югом Красноярского края. Вклад состоит в следующем.

1. Реализована единая мультимасштабная сетка: глобальная сетка с шагом $0,703^\circ$ и региональная вставка с шагом $0,25^\circ$ объединены в один граф без внешних границ, а согласование разрешений достигается механизмом обмена сообщениями, а не отдельной процедурой сшивания. Идея мультимасштабного представления не нова [5, 9]; предлагаемый вариант отличается способом построения — прямой заменой узлов глобальной решётки вставкой с единообразной связностью. Показано, что такая конструкция превосходит интерполяцию прогноза глобальной модели в те же узлы; приведена диагностика стыка.
2. Модель намеренно лёгкая — 5,9 млн параметров против сотен миллионов у [3, 8, 9]; обучение и выпуск прогноза идут на одном графическом ускорителе, что делает результат воспроизводимым в вычислительной среде регионального управления гидрометслужбы.
3. Исследована стратегия дообучения глобальной модели под региональную сетку. Получен методический результат самостоятельного значения: ошибка одношагового прогноза на проверочной выборке — ненадёжный критерий отбора состояния модели, предназначенной для многошагового прогноза.
4. Показано, что распределение обучающего сигнала, возникающее при равномерном усреднении функции потерь, далеко от постановки задачи: узлы целевой области получают 1,7 % сигнала, а приземная температура — 0,46 %. Явное взвешивание по узлам и каналам снижает ошибку приземной температуры на 10,2 % без изменения архитектуры и объёма обучения.

Данные, базовая модель и метрики качества

Исходные данные

Обучение и оценка выполнены на реанализе ERA5 Европейского центра среднесрочных прогнозов погоды [6] за 2010–2020 гг. с шагом 6 ч, что даёт 16 072 последовательных срока.

Состояние атмосферы описывается набором из 19 полей. Приземные и статические: температура воздуха на высоте 2 м, зональная и меридиональная компоненты ветра на высоте 10 м, давление на уровне моря, приземное давление, суммарные осадки за 6 ч, общее содержание водяного пара в столбе атмосферы, геопотенциал поверхности и маска «суша — море». Два последних статические: подаются на вход, но не прогнозируются и исключены из

всех оценок. На уровнях 850 и 500 гПа задаются по пять полей: температура, две компоненты ветра, геопотенциал и удельная влажность. Вертикальная структура кодируется составом признаков узла, а не отдельными узлами по вертикали.

Поля хранятся в физических единицах (геопотенциал ERA5 однократно поделён на $g = 9,80665 \text{ м/с}^2$), перед подачей в сеть каждый канал стандартизуется. Среднее и стандартное отклонение оценены по всему периоду 2010–2020 гг., включая проверочную и тестовую части: влияние двух чисел на канал пренебрежимо, но факт указывается явно.

Входное окно — два последовательных срока (12 ч предыстории); прогноз строится авторегрессионно с шагом 6 ч. Основные горизонты оценки — +6, +12, +18 и +24 ч.

Целевая область (регион) ограничена координатами 50–60° с. ш., 83–98° в. д. и покрывается решёткой с шагом 0,25° размером $61 \times 41 = 2501$ узел. Внутри выделена внутренняя зона 55,5–56,5° с. ш., 92–94° в. д. (45 узлов), включающая Красноярск и окрестности. Все метрики вычислены относительно реальных полей ERA5 с шагом 0,25° в этих узлах, без интерполяции с более грубой сетки.

Состав 33-канальной конфигурации, использованной для основной модели, получается добавлением к перечисленным 19 полям пяти полей на уровне 250 гПа и пяти на уровне 1000 гПа (температура, обе составляющие ветра, геопотенциал, удельная влажность), а также четырёх каналов временного форсинга — синусов и косинусов часа суток и дня года. Форсинг и статические поля модель предсказывает формально, но при развёртке они заменяются известными значениями и в число прогностических каналов не входят.

Хронологическое разбиение выборки

Разбиение выполнено строго хронологически, без перемешивания сроков: обучающая выборка целиком предшествует проверочной, а проверочная — тестовой, что исключает попадание в обучение информации о будущих состояниях. Из 16 072 сроков при окне «2 входных среза + 4 прогностических шага» формируется 16 067 примеров, делящихся в отношении 80/10/10: 12 853 — обучение, 1607 — проверочная выборка (подбор гиперпараметров и отбор состояния модели), 1607 — тестовая выборка, на которой получены все публикуемые числа. Тестовая выборка охватывает конец 2019 г. и полностью 2020 г., то есть содержит непрерывный годовой цикл и все четыре сезона: обучающая выборка — сроки начала прогноза с 01.01.2010 06 UTC по 19.10.2018 06 UTC, проверочная — с 19.10.2018 12 UTC по 25.11.2019 00 UTC, тестовая — с 25.11.2019 06 UTC по 30.12.2020 18 UTC.

Базовая глобальная модель

Отправной точкой регионального дообучения служит глобальная модель, обученная на тех же 19 полях на широтно-долготной сетке 512×256 узлов (шаг около 0,703°). Она реализует схему «кодировщик — процессор — декодировщик» на графе: кодировщик переносит признаки узлов расчётной сетки на вершины икосаэдрической мозаики (уровни детализации 4 и

6), процессор выполняет 12 раундов обмена сообщениями блоком типа Interaction Network [2] с четырёхмерными геометрическими признаками рёбер, декодировщик возвращает результат в узлы сетки. Латентная размерность — 256, число обучаемых параметров — 5,9 млн, что на два-три порядка меньше, чем у известных глобальных нейросетевых моделей [8, 11], и позволяет вести обучение и оперативный выпуск прогноза на одной видеокарте.

Функция потерь — среднеквадратическая ошибка в стандартизованных переменных, осреднённая по узлам, каналам и горизонтам, с поэтапным наращиванием длины авторегрессионной развёртки. Отметим особенность реализации, выявленную при подготовке работы: при глобальном предобучении широтное взвешивание узлов оказалось практически равномерным, тогда как при региональном дообучении (см. следующий раздел) применялись веса $\cos\varphi$, где φ — широта узла. Региональное дообучение стартовало с промежуточного набора весов глобальной модели: лучшее по проверочной выборке состояние (эпоха 30 из 36 пройденных). Качество базовой модели на её собственной сетке — агрегатная успешность 65,4 % при ошибке приземной температуры 1,07 °C в среднем по горизонтам +6...+24 ч (200 сроков). С региональными числами настоящей работы это значение несопоставимо: оценка ведётся по всему шару на грубой сетке 0,703°, где истинное поле сглажено, и на другой подвыборке сроков.

Метрики качества

Для канала c и горизонта τ среднеквадратическая ошибка вычисляется в физических единицах канала:

$$\text{RMSE}_c(\tau) = \left[\frac{1}{N|G|} \sum_{n=1}^N \sum_{g \in G} (\hat{x}_{c,g}^{(n)}(\tau) - x_{c,g}^{(n)}(\tau))^2 \right]^{1/2}, \quad (1)$$

где N — число сроков ($N = 1607$ для тестовой выборки); G — множество оцениваемых узлов (2501 для региона, 45 для внутренней зоны); $\hat{x}$ — прогноз, x — значение реанализа, принимаемое за истинное. Ошибка приводится в единицах переменной: °C, м/с, гПа, гпм. Узлы суммируются с весами $\cos\varphi$, нормированными на единичное среднее, как принято в протоколе верификации нейросетевых моделей прогноза [12]: ячейка широтно-долготной сетки на 60° с. ш. вдвое уже экваториальной, и равные веса завышали бы вклад высоких широт. Для полосы 50–60° с. ш. отношение крайних весов равно 1,29.

Используются два эталона; инерционный переносит поля последнего входного среза t_0 на все горизонты без изменений. Успешность относительно эталона —

$$S_c(\tau) = \left(1 - \frac{\text{RMSE}_c(\tau)}{\text{RMSE}_{\text{эт}}(\tau)} \right) \cdot 100 \%, \quad (2)$$

где $\text{RMSE}_{\text{эт}}$ — ошибка (1) для эталона на том же окне и той же маске узлов.

Инерционный эталон пригоден не для всех полей. По приземной температуре его ошибка равна 4,99 / 6,88 / 5,88 / 4,42 °С на горизонтах +6...+24 ч: на суточном сроке он точнее, чем на шестичасовом, поскольку поле возвращается к тому же часу местного времени. Успешность относительно него немонотонна (76,4 / 80,2 / 76,2 / 67,0 %) и характеризует эталон не меньше, чем модель.

Климатический эталон свободен от этого недостатка. Он построен разложением по гармоникам — три годовые и суточный ход — по обучающей части выборки, тестовые сроки в подгонку не входили. От горизонта его ошибка практически не зависит: 6,25 °С по приземной температуре на всех сроках, 5,42 °С по температуре на 850 гПа, 9,19 гПа по давлению на уровне моря, 2,05 и 1,74 м/с по составляющим ветра. Успешность основной модели относительно климатологии на суточном сроке составляет 76,6 % по приземной температуре, 82,7 % по T850, 88,8 % по давлению, 65,9 и 60,9 % по ветру. Постоянство эталона задаёт предел полезности прогноза: ошибка модели по приземной температуре равна 4,33 °С на +120 ч и 6,19 °С на +168 ч, то есть сравнивается с климатологией после седьмых суток.

Для сводной оценки применяется агрегатный показатель. Каналы имеют разные единицы, поэтому агрегирование выполняется в стандартизованных переменных:

$$\overline{\text{RMSE}} = \left[\frac{1}{N |G| C H} \sum_n \sum_{g \in G} \sum_{c=1}^C \sum_{\tau} \left(\frac{x_{c,g}^{(n)}(\tau) - x_{c,g}^{(n)}(\tau)}{\sigma_c} \right)^2 \right]^{1/2}, \quad \bar{S} = \left(1 - \frac{\overline{\text{RMSE}}}{\overline{\text{RMSE}}_{\text{ЭТ}}} \right) \cdot 100 \%, \quad (3)$$

где σ_c — стандартное отклонение канала при стандартизации; C — число прогностических каналов (17 для 19-канальной конфигурации, 27 для 33-канальной: исключены два статических поля и четыре канала форсинга); $H = 4$. Колонка $\bar{S}$ в табл. 1 поэтому сравнивает величины, осреднённые по разным наборам каналов, и строки с 19 и 33 каналами по ней не сопоставимы; сопоставимы поканальные значения и строки внутри одного набора.

Наряду с ошибкой приводится аномальная корреляция — мера того, насколько прогноз воспроизводит отклонение от обычного состояния:

$$\text{ACC}_c(\tau) = \frac{\sum w_g (x_{c,g} - \bar{x}_{c,g})(x_{c,g} - \bar{x}_{c,g})}{\left[\sum w_g (x_{c,g} - \bar{x}_{c,g})^2 \sum w_g (x_{c,g} - \bar{x}_{c,g})^2 \right]^{1/2}}, \quad (4)$$

где $\bar{x}$ — климатология на тот же срок, w_g — тот же широтный вес; суммирование идёт по узлам и срокам сразу, то есть АСС есть отношение сумм, а не среднее посрочных корреляций. Вычитается именно климатология: общий для прогноза и истины сезонный ход должен быть убран из обоих.

Точность оценок характеризуется доверительными интервалами блочного бутстрепа: сроки идут через 6 ч и коррелированы внутри одного синоптического процесса, поэтому

ресэмплируются блоки подряд идущих сроков [7]. Интервалы строятся из посрочных вкладов в ошибку, поэтому парное сравнение конфигураций ведётся на общих сроках. Интервал учитывает изменчивость по срокам верификации, но не по повторным обучениям; последняя приведена в «Ограничениях».

Мультимасштабная графовая модель и стратегия дообучения

Ограничения регулярной сетки на сфере

Значение переменной в узле через шесть часов определяется состоянием в его пространственной окрестности, поэтому выучиваемость такой закономерности требует, чтобы окрестность узла всюду имела примерно один физический размер. Для регулярной сетки в координатах широта–долгота это условие не выполняется: при шаге $0,703^\circ$ расстояние между соседними узлами вдоль параллели убывает пропорционально косинусу широты — около 78 км на экваторе, 50 км на 50° с.ш. и 14 км на 80° с.ш., — а вблизи полюсов сетка вырождается. Модель вынуждена либо усреднять эту неоднородность, либо расходовать ёмкость на её запоминание.

Альтернатива — граф с квазиравномерным распределением узлов по сфере, которое даёт икосаэдрическая триангуляция: исходный икосаэдр из 20 равных треугольных граней рекурсивно измельчается делением каждого треугольника на четыре с проецированием новых вершин на сферу. На любом уровне измельчения каждая вершина имеет пять или шесть соседей при малом разбросе длин рёбер, поэтому окрестность узла всюду отвечает близкому физическому масштабу. Именно это свойство лежит в основе современных нейросетевых моделей прогноза [3, 8].

Архитектура

Используется схема «кодировщик — процессор — декодировщик» [2, 8], в которой обмен информацией происходит на графе, а входные и выходные поля остаются на регулярной сетке (рис. 1).

Кодировщик переносит значения из узлов сетки в вершины графа: для каждой вершины формируется сообщение от узлов, попавших в её окрестность (радиус связи 0,6 в единицах длины ребра графа), и многослойный персептрон преобразует его в скрытое представление размерности 256.

Процессор выполняет $R = 12$ раундов обмена сообщениями по рёбрам графа. Один раунд реализован блоком Interaction Network [2] и состоит из двух шагов. Сначала для каждого ребра ($i \rightarrow j$) вычисляется сообщение

$$m_{ij}^{(r)} = \varphi_e(h_i^{(r-1)}, h_j^{(r-1)}, e_{ij}), \quad (5)$$

затем состояние вершины обновляется по агрегированным входящим сообщениям:

$$h_j^{(r)} = \varphi_v(h_j^{(r-1)}, \frac{1}{|N(j)|} \sum_{i \in N(j)} m_{ij}^{(r)}), \quad (6)$$

где $h_j^{(r)}$ — скрытое представление вершины j после раунда r (размерность 256); e_{ij} — постоянные признаки ребра (длина и три компоненты единичного вектора направления в геоцентрических координатах); $N(j)$ — вершины, соединённые с j ; φ_e и φ_v — персептроны с активацией Swish и послойной нормировкой. Веса раундов не разделяются, как и в [8].

Декодировщик выполняет обратный перенос: скрытые представления вершин графа отображаются в приращения полей в узлах регулярной сетки.

Прогноз строится авторегрессионно с шагом 6 ч: выход модели подаётся на её вход для получения следующего срока,

$$x(t_0 + 6(k+1)) = F(x(t_0 + 6k), x(t_0 + 6(k-1))), \quad k = 0, 1, \dots, K-1, \quad (7)$$

где F — обученное отображение (кодировщик–процессор–декодировщик), входное окно составляет два последовательных срока (12 ч), а при $k = 0$ используются два среза анализа. Общее число обучаемых параметров — 5,9 млн; конфигурации на 19 и 33 канала различаются лишь входным слоем кодировщика и выходным декодировщика (около 11 тыс. параметров, 0,2 %), поэтому округляются одинаково. Модели с сотнями миллионов параметров [3, 9] требуют многоузловых конфигураций, тогда как здесь обучение и выпуск прогноза выполняются на одной графической карте.

Мультимасштабная расчётная сетка

Классический способ построения региональной модели — вырезать область из глобальной сетки и задавать на её краю внешние граничные условия. У такого подхода есть известный недостаток: граничные узлы не имеют корректного окружения, из-за чего у края накапливаются искажения, а для их подавления требуется отдельная процедура сшивания с внешним полем [4].

В настоящей работе используется иной приём: глобальная и региональная сетки объединяются в единый граф, и понятие внешней границы для модели исчезает. Из глобальной сетки 512×256 (шаг $0,703^\circ$) удаляются узлы, попадающие внутрь области интереса, а на их место помещается регулярная региональная решётка с шагом $0,25^\circ$ ($61 \times 41 = 2501$ узел) в границах $50\text{--}60^\circ$ с.ш., $83\text{--}98^\circ$ в.д. Итоговая расчётная сетка содержит 130 778 глобальных узлов и 2501 узел вставки, всего 133 279.

Рёбра между узлами и вершинами графа строятся поиском ближайших соседей в трёхмерном пространстве по геоцентрическим координатам, единообразно для узлов обоих разрешений; никакой специальной обработки переходной зоны при построении связности не выполняется.

Соединение областей жёсткое: множества узлов не пересекаются по построению, значения объединяются в единый вектор состояния без весовой функции и сглаживания на стыке. Согласование разрешений происходит неявно, в ходе обмена сообщениями: узлы по обе стороны стыка связаны рёбрами и на каждом из 12 раундов обмениваются признаками, так что переходный слой формируется самой моделью в процессе обучения.

В методе Дэвиса [4] внутреннее решение релаксируется к заданному извне полю в ходе интегрирования, то есть внешние граница и поле остаются необходимыми; здесь их нет вовсе. Прямая проверка бесшовности приведена на рис. 2: смена разрешения видна по размеру ячеек, разрыва поля на склейке нет. Количественная диагностика по горизонтам дана в п. 4.6.

Ограничение подхода: вставка задана прямоугольником в координатах широта–долгота и сохраняет ту же неоднородность шага по долготе, что обсуждалась в п. 3.1. Для 10° по широте отношение $\cos 50^\circ / \cos 60^\circ \approx 1,29$ несущественно, но при переносе на область большей широтной протяжённости потребует учёта.

Стратегия дообучения

Региональная модель получается дообучением глобальной, обученной на той же выборке ERA5 в конфигурации 512×256 . При смене геометрии расчётной сетки веса кодировщика и декодировщика оказываются несогласованными с новой связностью, тогда как процессор содержит выученную на глобальной задаче динамику. Прямое дообучение всех параметров сразу несёт риск разрушения этой динамики большими градиентами со стороны неадаптированных кодировщика и декодировщика — эффект, известный как катастрофическое забывание.

Применяется двухфазная схема:

1. Фаза 1 (первые E_f эпох): параметры процессора зафиксированы, обучаются только кодировщик и декодировщик, приспособляясь к новой геометрии и статистике региона.
2. Фаза 2 (оставшиеся эпохи): процессор размораживается, но его темп обучения устанавливается в 10 раз меньше базового.

В основной конфигурации $E_f = 10$, в конфигурациях, использованных для проверки самой стратегии (п. 4.5), $E_f = 6$; базовый темп обучения 10^{-4} , оптимизатор Adam.

Одновременно применяется учебный план по длине авторегрессионной развёртки: обучение начинается с одношагового прогноза, а затем число шагов K в (7) последовательно увеличивается до четырёх, причём функция потерь вычисляется по всем шагам развёртки.

Функция потерь — среднеквадратическая ошибка в стандартизованных переменных, вычисляемая по всем узлам расчётной сетки: ограничение потерь одной областью интереса деградировало поля за её пределами и через авторегрессионную обратную связь ухудшало

прогноз внутри неё. Статические поля — рельеф и маска суши/моря — исключены из функции потерь и переносятся между шагами развёртки без изменений.

Результаты: качество регионального прогноза

Условия оценки

Все оценки получены на едином окне верификации и при единственном определении истинного поля (разд. 2): реанализ ERA5 с шагом $0,25^\circ$ в узлах региональной вставки. Показатели — ошибка (1), успешность относительно эталона (2), агрегатная успешность (3) и аномальная корреляция (4). Табл. 1 посчитана с широтными весами, табл. 3–5 — с равными: это внутренние сравнения конфигураций, а вес смещает ошибку не более чем на $0,02^\circ\text{C}$ и агрегат на 0,2 п.п. одинаково у всех строк.

Объём выборки в таблицах различается. Табл. 1, 3 и 4 посчитаны на полной тестовой выборке из 1607 сроков (25.11.2019 — 30.12.2020, все четыре сезона), табл. 2 и 5 — на подвыборке из **первых** 100 сроков периода (по 19.12.2019). Подвыборка представляет холодное полугодие и систематически труднее полной: ошибка приземной температуры на суточном сроке равна $1,47^\circ\text{C}$ на 1607 сроках и $2,05^\circ\text{C}$ на 100. Числа из разных таблиц между собой несопоставимы; внутри таблицы все конфигурации посчитаны на одних сроках.

Качество основной модели

Ошибка приземной температуры на суточном сроке — $1,47^\circ\text{C}$ по области [1,39; 1,53] и $1,31^\circ\text{C}$ во внутренней зоне [1,21; 1,40]; аномальная корреляция 0,975 [0,970; 0,979] и 0,984 [0,979; 0,987]. У инерционного прогноза на том же окне АСС равна 0,507. По остальным полям на том же сроке (регион): ветер 0,70 и 0,68 м/с, давление на уровне моря 1,03 гПа, T850 $0,94^\circ\text{C}$, Z500 8,7 гпм.

Расширение состава полей с 19 до 33 каналов (уровни 250 и 1000 гПа, временной форсинг) даёт выигрыш на всех горизонтах: 0,076 / 0,121 / 0,149 / 0,174 $^\circ\text{C}$ с интервалами [0,063; 0,088], [0,104; 0,138], [0,125; 0,171] и [0,141; 0,210] (блочный бутстреп, блок 5 суток, 2000 реплик, парное сравнение на совпадающих сроках). Отнести весь выигрыш к добавленным уровням нельзя: 33-канальная конфигурация дообучалась от иной глобальной модели, которая и сама точнее. Переход от базовой 33-канальной конфигурации к взвешенной — предмет п. 4.4; он снижает ошибку приземной температуры ещё на 11,6 % ($1,548$ против $1,368^\circ\text{C}$ в среднем по горизонтам) при равном объёме обучения и неизменной архитектуре, а агрегатную успешность повышает на 1,17 п.п. с интервалом [+1,09; +1,24].

Что даёт единый граф

Чтобы оценить вклад собственно мультимасштабной конструкции, прогноз глобальной модели с шагом $0,703^\circ$ интерполирован билинейно в те же 2501 узел и оценён против той же истины. Все строки табл. 2 посчитаны на одних и тех же 100 сроках тестовой выборки.

Единый граф превосходит интерполяцию по всем полям. Выигрыш умеренный по приземной температуре (11 %) и существенный по ветру и геопотенциалу (37–40 %). Это согласуется с устройством приёма: обмен сообщениями уточняет поле как целое, тогда как приземная температура в конкретном узле сильнее определяется подсеточными факторами, которых не разрешает ни одна из сравниваемых конфигураций.

Веса в функции потерь

Функция потерь при обучении — среднеквадратическая ошибка по нормированным каналам, усреднённая по узлам графа и шагам развёртки. Такое усреднение задаёт распределение обучающего сигнала неявно, и оно оказывается далёким от постановки задачи в двух отношениях.

Пространственная диспропорция. Узлов региональной вставки 2501 из 133 279, то есть 1,9 %. Почти весь обучающий сигнал приходится на глобальную часть графа, тогда как публикуемые показатели относятся к вставке.

Поканальная диспропорция. Нормировка выполнена на разброс самого поля, тогда как модель предсказывает приращение за шаг, а разбросы приращений различаются у каналов на порядки. Замер по обучающей выборке: осадки дают 25,0 % функции потерь, приземная температура — 0,46 %, геопотенциал на 500 гПа — 0,15 %, приземное давление — 0,02 %; отношение крайних равно 1218. Вклад канала определяется не значимостью, а масштабом его изменчивости.

Обе диспропорции устраняются весами: узлам вставки — вес W при единичном весе остальных, каналам — веса, обратные квадрату разброса шестичасовой невязки по обучающей выборке. Все конфигурации табл. 3 получены одинаковым дожигом одной исходной модели (восемь эпох на полной развёртке с косинусным снижением темпа до нуля) и различаются только весами. Первая строка табл. 3 ($1,503^\circ\text{C}$) не совпадает со строкой «33 канала, базовая» табл. 1 ($1,525^\circ\text{C}$) потому, что дожиг в неё уже включён: выигрыш взвешивания при равном объёме обучения равен 10,2 %, а разность с табл. 1 (11,5 %) включает и восемь эпох дожига.

У веса вставки обнаруживается внутренний максимум по агрегату: рост доли вставки с 1,7 до 34,1 % улучшает и агрегат, и приземную температуру, дальнейший рост до 63,3 % агрегат ухудшает. Парный блочный бутстреп по общим срокам даёт для разности агрегатов при $W = 100$ и $W = 30$ величину $-0,05$ п.п. с интервалом $[-0,07; -0,03]$, не накрывающим ноль. Интервал учитывает изменчивость по срокам, но не по повторным обучениям, а та оценена в 0,03 п.п. и сравнима с самой разностью. По приземной температуре максимума

нет, она убывает монотонно ($1,503 \rightarrow 1,445 \rightarrow 1,415 \rightarrow 1,407$). Внутренний максимум по агрегату установлен поэтому как свойство выборки, а не метода.

Механизм виден в последнем столбце. Платой служит точность на глобальной части графа: ошибка при $W = 100$ выше, чем при $W = 30$, лишь на 0,8 % (0,1717 против 0,1703), но её приращение относительно конфигурации без весов втрое больше — 0,0021 против 0,0007. Прогноз внутри вставки за сутки зависит от притока извне, и деградация окружающего поля возвращается в область через развёртку. Оптимум определяется не самой областью, а балансом между ней и её окружением.

Веса каналов действуют как регулятор, а не как исправление ошибки: агрегат при их введении снижается на 0,30 п.п. (интервал $[-0,32; -0,28]$), тогда как приземная температура улучшается на 4,6 % (все четыре интервала не покрывают ноль). Агрегат (3) сам есть среднее по каналам с равными весами, то есть равномерное взвешивание для него оптимально по построению, и выравнивание вкладов смещает точность к каналам с малой собственной изменчивостью за счёт каналов с большой. Выигрыш канала описывается логарифмом его веса (корреляция 0,98 по 12 каналам), но за пределы измеренного диапазона не переносится: усиление пяти приземных каналов вчетверо сверх выравнивания дало меньше предсказанного, а геопотенциал на 500 гПа стал хуже. Механизм тот же, что у веса вставки: усиленные каналы отбирают ресурс у полей, которые их и определяют.

Основная конфигурация статьи использует $W = 30$ и выравнивающие веса каналов. Веса каналов вычислены по обучающей выборке и не подбирались по тестовой; целевые каналы для усиления не выделялись.

Стратегия дообучения и выбор контрольной точки

Стратегия дообучения исследована на отдельной 19-канальной линии моделей: заморозка процессора на первые 6 эпох против обучения всех параметров с первой эпохи, при одной сборке данных, одном начальном значении генератора и одинаковом расписании. Эта линия использует прямое предсказание поля, а не остаточную формулировку, поэтому её агрегатная успешность (около 60 %) ниже, чем у 19-канальной строки табл. 1 (69,4 %), при близких значениях приземной температуры: числа табл. 1 и 4 относятся к разным моделям и между собой не сравниваются.

Сравнение по лучшим контрольным точкам даёт выигрыш заморозки до 0,14 °C на +24 ч, но точки достигаются на разных эпохах, 16-й и 7-й, то есть сопоставляются не только стратегии, но и объёмы обучения. При равном бюджете разность по приземной температуре исчезает: обе конфигурации дают 1,82 °C на сутки.

Более того, контрольная точка эпохи 7, отобранная как «лучшая» по одношаговой ошибке, в авторегрессионной развёртке уступает собственной же точке эпохи 16 (1,96 против 1,82 °C). Тот же эффект независимо воспроизводится на базовой 33-канальной конфигурации: её состояние, отобранное по минимуму ошибки на проверочной выборке, точнее на го-

ризонте +6 ч (1,30 против 1,32 °C), но уступает на +18 и +24 ч (1,63 против 1,59 и 1,71 против 1,66 °C), причём смена знака значима с обеих сторон.

Отсюда методический вывод: минимум одношаговой ошибки на проверочной выборке отбирает модель, оптимальную ровно на измеряемом горизонте, и для многошагового прогноза ненадёжен. Отбор следует вести по метрике при полной развёртке, а сравнения стратегий — при равном бюджете.

Роль самой заморозки формулируется сдержанно: по приземной температуре при равном бюджете расписание на итог не влияет (1,82 против 1,82 °C), тогда как по агрегату различие составляет 1,3 п.п. (60,8 против 59,5 %) в пользу заморозки. Это второй после п. 4.4 случай расхождения агрегата и поканальных значений, и причина та же: агрегат усредняет нормированные ошибки по всем каналам, вклад каждого определяется отношением его ошибки к разбросу поля, а не значимостью канала для практики. Ранжирование конфигураций поэтому зависит от того, какое поле объявлено целевым, и в отчётности следует приводить и агрегат, и поканальные значения по целевым полям на одной маске узлов. Однако адаптация процессора под регион необходима: при заморозке на всё обучение ошибка одношагового прогноза на проверочной выборке оказывается на 7,5 % выше, обучение выходит на плато уже к восьмой эпохе, и растёт также ошибка на обучающей выборке — модели не хватает свободы подстроить динамику, а не данных. Величина измерена той же одношаговой метрикой, но привлекается здесь не для отбора состояния, а как признак недообучения; при полной развёртке этот эффект не оценивался.

Диагностика стыка

Утверждение о том, что жёсткая склейка узлов не требует отдельной процедуры сшивания, проверено прямо: ошибка приземной температуры вычислена по полосам расстояния до границы региональной вставки (табл. 5). Оценка выполнена на 100 сроках тестовой выборки.

Переходный слой существует. На горизонте +6 ч ошибка убывает монотонно по мере удаления от границы: 1,58 °C в полосе шириной 25 км против 1,40 °C в глубине области, то есть у стыка она выше на 13 %; эффект прослеживается примерно на 100–200 км. Утверждать полную бесшовность неправомерно.

Однако в авторегрессии он не усиливается. Относительно полосы 200–1000 км превышение убывает с 13 % на +6 ч до 2 % на +24 ч, но эта полоса перестаёт быть минимумом на дальних сроках: на +18 и +24 ч наименьшая ошибка приходится на полосу 100–200 км. Относительно минимума превышение у стыка составляет 6,0 / 8,8 / 7,9 / 6,5 % по четырём горизонтам, то есть держится на уровне 6–9 % и с горизонтом не растёт. Убывание относительно дальней полосы отражает рост ошибки в глубине области, а не рассасывание переходного слоя: на дальних сроках там преобладает другой источник ошибки — рельеф, в глубине области лежат горные районы. Существенно это потому, что именно неограниченный рост

приграничной ошибки составляет основную трудность региональных моделей с внешними граничными условиями.

Глобальная часть не страдает: непосредственно за границей вставки ошибка (1,87 °C на +24 ч) не превышает значений вдали от неё (1,95 и 2,05 °C). Склейка, таким образом, порождает контролируемый переходный слой и не требует отдельной процедуры сшивания полей.

Обсуждение, выводы и направления дальнейшей работы

Качество полученной модели определялось не архитектурой, а распределением обучающего сигнала: ни одно из проверенных вмешательств не касалось устройства сети. У обоих введённых весов обнаруживается внутренний максимум, и по одной причине: усиленная часть задачи отбирает ресурс у той, от которой сама зависит, — для целевой области это приток извне, для приземных каналов поля, формирующие приземную погоду.

Приёмы, не давшие эффекта

Три приёма, ожидавшихся полезными, проверены и отвергнуты. Внесение шума в авторегрессию ухудшило результат на 15 % при единой дисперсии и на 5 % при дисперсии, пропорциональной разбросу шестичасовой невязки канала: приём защищает от накопления ошибки в длинной развёртке, тогда как обучение и оценка ведутся на четырёх шагах, где накопление невелико. Ансамблирование дало 74,80 % для двух участников против 74,85 % у лучшего одиночного: все конфигурации получены дообучением одной исходной модели, корреляция ошибок в паре 0,993, независимого разнообразия между ними нет. Обучение на развёртке в двенадцать шагов вместо четырёх выигрыша не дало (64,38 против 64,49 % за пять суток, интервал разности $[-1,01; +0,59]$ накрывает ноль), причём двенадцать шагов не помещаются в ускоритель и градиент между ними приходится разрывать — вероятно, сквозной перенос градиента и составляет основную пользу приёма.

Ограничения

Межзапусковая изменчивость оценена одной парой прогонов с разными начальными значениями генератора: расхождение по сводному показателю 0,03 процентного пункта (73,41 против 73,40 %), то есть различия осмысленны начиная с десятых долей пункта. Вес целевой области $W = 30$ и стратегия дообучения выбраны по табл. 3 и 4, посчитанным на **тестовой** выборке, а не на проверочной: отбор одного гиперпараметра из четырёх значений — слабая форма переиспользования, но величины для $W = 30$ следует считать слегка оптимистичными. Веса каналов вычислены по обучающей выборке и оговорки не требуют.

Истиной служит реанализ, а не стационарные наблюдения; он сглаживает подсеточные эффекты, включая городской остров тепла, поэтому оценки не переносятся на прогноз в точке станции без постобработки. Сопоставление с оперативной моделью не проводилось;

при нём придётся учесть, что модель, обученная на реанализе, против реанализа и оценивается, то есть находится в благоприятном положении [12]. Результаты получены для одной территории и одного тестового окна, а прямое сравнение с региональной моделью с граничным форсингом [10] не выполнялось.

Направления дальнейшей работы

Уплотнение мультимасштабного графа за счёт слияния всех уровней икосаэдрической мозаики, а не двух, — приём, дающий дальние связи без роста числа параметров; расширение состава прогностических полей и переход к прогнозу с оценкой неопределённости через ансамбль возмущённых начальных состояний либо порождающие вероятностные модели; верификация по данным сети станций как условие принятия схемы оперативной практикой; наконец, включение циклического усвоения поступающих наблюдений в автоматический цикл выпуска прогноза.

Выводы

1. Построена и проверена мультимасштабная графовая нейронная сеть регионального прогноза погоды, в которой глобальная и региональная части соединены без отдельной процедуры сшивания полей: диагностика стыка показывает переходный слой шириной около 100 км, затухающий с ростом горизонта. Обучение и расчёт уместаются в одну видеокарту, что делает воспроизведение схемы посильным для регионального подразделения гидрометслужбы.
2. Единый граф превосходит интерполяцию прогноза глобальной модели в узлы области по всем полям: выигрыш от 11 % по приземной температуре до 37–40 % по ветру и геопотенциалу.
3. Отбор обученного состояния по ошибке одношагового прогноза ненадёжен для многошагового; расписание заморозки процессора на итог не влияет, тогда как сама его адаптация необходима и даёт около 7,5 % по ошибке на проверочной выборке.
4. Единственный агрегатный показатель скрывает различное поведение модели по отдельным полям, поэтому верификацию следует отчитывать покомпонентно.
5. Распределение обучающего сигнала при равномерном усреднении функции потерь далеко от постановки задачи: узлы целевой области получают 1,7 % сигнала, приземная температура — 0,46 %. Явное взвешивание снижает ошибку приземной температуры на 10,2 % без изменения архитектуры и объёма обучения, причём у веса целевой области есть внутренний максимум, определяемый зависимостью прогноза внутри области от притока извне.

Список литературы

1. Толстых М.А., Шашкин В.В., Фадеев Р.Ю. и др. Система моделирования атмосферы для бесшовного прогноза. М.: Триада ЛТД, 2017. 166 с.
2. Battaglia P.W., Pascanu R., Lai M. et al. Interaction networks for learning about objects, relations and physics // Advances in Neural Information Processing Systems (NIPS). 2016. Vol. 29. P. 4502–4510.
3. Bi K., Xie L., Zhang H. et al. Accurate medium-range global weather forecasting with 3D neural networks // Nature. 2023. Vol. 619, No. 7970. P. 533–538. DOI: 10.1038/s41586-023-06185-3.
4. Davies H.C. A lateral boundary formulation for multi-level prediction models // Quarterly Journal of the Royal Meteorological Society. 1976. Vol. 102, No. 432. P. 405–418. DOI: 10.1002/qj.49710243210.
5. Gao Y., Wu H., Shu R. et al. OneForecast: A universal framework for global and regional weather forecasting // Proceedings of the 42nd International Conference on Machine Learning (ICML). PMLR, 2025. Vol. 267. P. 18658–18697.
6. Hersbach H., Bell B., Berrisford P. et al. The ERA5 global reanalysis // Quarterly Journal of the Royal Meteorological Society. 2020. Vol. 146, No. 730. P. 1999–2049. DOI: 10.1002/qj.3803.
7. Künsch H.R. The jackknife and the bootstrap for general stationary observations // The Annals of Statistics. 1989. Vol. 17, No. 3. P. 1217–1241. DOI: 10.1214/aos/1176347265.
8. Lam R., Sanchez-Gonzalez A., Willson M. et al. Learning skillful medium-range global weather forecasting // Science. 2023. Vol. 382, No. 6677. P. 1416–1421. DOI: 10.1126/science.adi2336.
9. Nipen T.N., Haugen H.H., Ingstad M.S. et al. Regional data-driven weather modeling with a global stretched grid // Artificial Intelligence for the Earth Systems. 2026. Vol. 5, No. 2. Art. e250001. DOI: 10.1175/AIES-D-25-0001.1.
10. Oskarsson J., Landelius T., Lindsten F. Graph-based neural weather prediction for limited area modeling // arXiv:2309.17370. 2023.
11. Pathak J., Subramanian S., Harrington P. et al. FourCastNet: A global data-driven high-resolution weather model using adaptive Fourier neural operators // arXiv:2202.11214. 2022.
12. Rasp S., Hoyer S., Merose A. et al. WeatherBench 2: A benchmark for the next generation of data-driven global weather models // Journal of Advances in Modeling Earth Systems. 2024. Vol. 16, No. 6. Art. e2023MS004019. DOI: 10.1029/2023MS004019.
13. Wijnands J.S., Van Ginderachter M., François B. et al. Data-driven regional weather forecasting: A comparison of stretched-grid and limited-area modelling // Machine Learning with Applications. 2026. Vol. 24. Art. 100887. DOI: 10.1016/j.mlwa.2026.100887.

References

1. Tolstykh M.A., Shashkin V.V., Fadeev R.Yu. et al. Sistema modelirovaniya atmosfery dlya besshovnogo prognoza [Atmosphere Modelling System for Seamless Prediction]. Moscow, Triada Ltd. Publ., 2017, 166 p. [in Russ.]
2. Battaglia P.W., Pascanu R., Lai M. et al. Interaction networks for learning about objects, relations and physics. *Advances in Neural Information Processing Systems (NIPS)*, 2016, vol. 29, pp. 4502–4510.
3. Bi K., Xie L., Zhang H. et al. Accurate medium-range global weather forecasting with 3D neural networks. *Nature*, 2023, vol. 619, no. 7970, pp. 533–538. DOI: 10.1038/s41586-023-06185-3.
4. Davies H.C. A lateral boundary formulation for multi-level prediction models. *Quarterly Journal of the Royal Meteorological Society*, 1976, vol. 102, no. 432, pp. 405–418. DOI: 10.1002/qj.49710243210.
5. Gao Y., Wu H., Shu R. et al. OneForecast: A universal framework for global and regional weather forecasting. *Proceedings of the 42nd International Conference on Machine Learning (ICML)*, PMLR, 2025, vol. 267, pp. 18658–18697.
6. Hersbach H., Bell B., Berrisford P. et al. The ERA5 global reanalysis. *Quarterly Journal of the Royal Meteorological Society*, 2020, vol. 146, no. 730, pp. 1999–2049. DOI: 10.1002/qj.3803.
7. Künsch H.R. The jackknife and the bootstrap for general stationary observations. *The Annals of Statistics*, 1989, vol. 17, no. 3, pp. 1217–1241. DOI: 10.1214/aos/1176347265.
8. Lam R., Sanchez-Gonzalez A., Willson M. et al. Learning skillful medium-range global weather forecasting. *Science*, 2023, vol. 382, no. 6677, pp. 1416–1421. DOI: 10.1126/science.adi2336.
9. Nipen T.N., Haugen H.H., Ingstad M.S. et al. Regional data-driven weather modeling with a global stretched grid. *Artificial Intelligence for the Earth Systems*, 2026, vol. 5, no. 2, art. e250001. DOI: 10.1175/AIES-D-25-0001.1.
10. Oskarsson J., Landelius T., Lindsten F. Graph-based neural weather prediction for limited area modeling. *arXiv:2309.17370*, 2023.
11. Pathak J., Subramanian S., Harrington P. et al. FourCastNet: A global data-driven high-resolution weather model using adaptive Fourier neural operators. *arXiv:2202.11214*, 2022.
12. Rasp S., Hoyer S., Merose A. et al. WeatherBench 2: A benchmark for the next generation of data-driven global weather models. *Journal of Advances in Modeling Earth Systems*, 2024, vol. 16, no. 6, art. e2023MS004019. DOI: 10.1029/2023MS004019.
13. Wijnands J.S., Van Ginderachter M., François B. et al. Data-driven regional weather forecasting: A comparison of stretched-grid and limited-area modelling. *Machine Learning with Applications*, 2026, vol. 24, art. 100887. DOI: 10.1016/j.mlwa.2026.100887.

Таблица 1. Ошибка приземной температуры (°C) по горизонтам, агрегатная успешность $\bar{S}$ (%) согласно (3) и аномальная корреляция приземной температуры согласно (4), осреднённая по четырём горизонтам. Тестовая выборка 1607 сроков; регион — 2501 узел, внутренняя зона — 45 узлов.

Зона	Конфигурация	+6 ч	+12 ч	+18 ч	+24 ч	$\bar{S}$, %	ACC
Регион	19 каналов	1,41	1,67	1,75	1,85	69,2	0,962
	33 канала, базовая	1,33	1,55	1,61	1,68	73,2	0,968
	33 канала, взвешенная (основная)	1,19	1,38	1,41	1,47	74,4	0,975
Внутренняя зона	33 канала, базовая	1,21	1,41	1,47	1,53	74,5	0,979
	33 канала, взвешенная (основная)	1,06	1,23	1,26	1,31	75,4	0,984

Table 1. RMSE of 2 m temperature (°C) by lead time and aggregate skill score S (%) according to (3). Test set of 1607 initial times; region — 2501 nodes, inner zone — 45 nodes.

Таблица 2. Ошибка прогноза на горизонте +24 ч в узлах региональной вставки: инерционный прогноз, интерполяция прогноза глобальной модели и мультимасштабная модель.

Поле	Инерционный прогноз	Глобальная 0,703° + интерполяция	Мультимасштабная	Выигрыш
t2m, °C	4,20	2,30	2,05	11 %
10u, м/с	2,71	0,99	0,59	40 %
msl, гПа	9,36	2,23	1,66	26 %
t@850, °C	6,27	1,48	1,23	17 %
z@500, гПм	88,5	21,0	13,3	37 %

Table 2. Forecast error at +24 h at the nodes of the regional insert: persistence, interpolated global forecast and the multiscale model.

Таблица 3. Влияние весов в функции потерь. Регион, 1607 сроков; t_{2m} усреднена по четырём горизонтам, последний столбец — ошибка по всей сетке графа.

Конфигурация	Доля вставки в потерях	$\bar{S}$, %	t_{2m} , °C	RMSE по сетке
Исходная (без весов, после дожига)	1,7 %	73,8	1,503	0,1696
Вес вставки $W = 10$	14,7 %	74,7	1,445	0,1697
Вес вставки $W = 30$	34,1 %	74,9	1,415	0,1703
Вес вставки $W = 100$	63,3 %	74,8	1,407	0,1717
$W = 30$ и веса каналов	34,1 %	74,6	1,350	0,1708

Table 3. Effect of loss weighting. Region, 1607 initial times; t_{2m} is averaged over four lead times and the last column is the error over the whole computational graph.

Таблица 4. Ошибка приземной температуры (°C) по региону и агрегатная успешность при разных способах отбора контрольной точки.

Конфигурация	Состояние	+6 ч	+12 ч	+18 ч	+24 ч	$\bar{S}$, %
С заморозкой	лучшая по val (эпоха 16)	1,34	1,59	1,71	1,82	60,8
Без заморозки	лучшая по val (эпоха 7)	1,36	1,65	1,81	1,96	59,9
Без заморозки	равный бюджет (эпоха 16)	1,35	1,62	1,72	1,82	59,5

Table 4. RMSE of 2 m temperature (°C) over the region and aggregate skill score for different ways of selecting the checkpoint.

Таблица 5. Ошибка приземной температуры (°C) по расстоянию до границы вставки. Положительное расстояние — внутри вставки (шаг 0,25°), отрицательное — снаружи, на глобальной части графа (шаг 0,703°).

Зона	Расстояние до границы, км	Узлов	+6 ч	+12 ч	+18 ч	+24 ч
Вставка 0,25°	0–25	278	1,58	1,97	2,06	2,12
	25–50	240	1,54	1,92	2,00	2,08
	50–100	414	1,51	1,85	1,94	2,02
	100–200	698	1,49	1,81	1,91	1,99
	200–1000	871	1,40	1,80	1,97	2,07
Глобальная 0,703°	–100...0	143	1,37	1,74	1,82	1,87
	–300...–100	308	1,42	1,76	1,88	1,95
	–1000...–300	1708	1,36	1,73	1,91	2,05

Table 5. RMSE of 2 m temperature ($^{\circ}\text{C}$) by distance to the boundary of the insert. Positive distance is inside the insert (0.25° spacing), negative is outside, on the global part of the graph (0.703° spacing).




Рис. 1. Устройство модели. (а) поток данных: значения расчётной сетки переносятся кодировщиком в вершины графа-мозаики, процессор выполняет 12 раундов обмена сообщениями, декодировщик возвращает приращения полей на сетку; выход подаётся на вход следующего шага. (б) двухфазная схема дообучения.

Fig. 1. Model layout. (a) data flow: the encoder carries grid values onto the vertices of the mesh graph, the processor runs 12 rounds of message passing, the decoder returns field increments to the grid, and the output is fed to the next step. (b) the two-phase fine-tuning schedule.




Рис. 2. Прогноз приземной температуры на +24 ч в окрестности границы региональной вставки. Размер ячейки соответствует шагу сетки — $0,25^{\circ}$ внутри вставки и $0,703^{\circ}$ снаружи; штриховая линия — граница вставки.

Fig. 2. Forecast of 2 m temperature at +24 h near the boundary of the regional insert. Cell size follows the grid spacing — 0.25° inside the insert and 0.703° outside; the dashed line marks the insert boundary.