

Мультимасштабная графовая нейросетевая модель регионального прогноза погоды с усвоением данных наблюдений

А.С. Табаков^{1,2}, А.В. Пененко¹

¹Институт вычислительной математики и математической геофизики СО РАН, г. Новосибирск, Россия; ²Новосибирский государственный университет, г. Новосибирск, Россия

artur.tabakov11@gmail.com

Представлена региональная нейросетевая модель прогноза погоды над югом Красноярского края, построенная на графовом представлении атмосферного состояния. Глобальная расчётная сетка с шагом 0.703° и региональная вставка с шагом 0.25° объединены в единый граф из 133 279 узлов, что устраняет необходимость задания внешних граничных условий: согласование разрешений на стыке достигается механизмом обмена сообщениями в процессе обучения. Модель содержит 5.9 млн обучаемых параметров, обучение и выпуск прогноза выполняются на одном графическом ускорителе. Оценка на независимой выборке из 1607 сроков (все сезоны) показала среднеквадратическую ошибку прогноза приземной температуры 1.84°C на суточном сроке при успешности 69 % относительно инерционного прогноза. В контрольном эксперименте с равным бюджетом обучения установлено, что ошибка на проверочной выборке при одношаговом прогнозе является ненадёжным критерием отбора модели для многошагового прогноза. Исследовано усвоение наблюдений методами релаксации и оптимальной интерполяции внутри авторегрессионного цикла: непрерывное усвоение ограничивает рост ошибки при развёртке до 168 ч, тогда как «память» модели о единичной коррекции составляет порядка суток.

Ключевые слова: численный прогноз погоды, графовая нейронная сеть, региональный прогноз, мультимасштабная сетка, усвоение данных, оптимальная интерполяция, авторегрессионный прогноз, машинное обучение

A multiscale graph neural network for regional weather forecasting with data assimilation

A.S. Tabakov^{1,2}, A.V. Penenko¹

¹Institute of Computational Mathematics and Mathematical Geophysics SB RAS, Novosibirsk, Russia; ²Novosibirsk State University, Novosibirsk, Russia

artur.tabakov11@gmail.com

A regional neural network weather forecasting model for the south of Krasnoyarsk Krai based on a graph representation of the atmospheric state is presented. A global mesh with a 0.703° spacing and a regional insert with a 0.25° spacing are combined into a single graph of 133,279 nodes, which removes the need for external lateral boundary conditions: the resolutions are reconciled at the interface by the message passing mechanism during training. The model has 5.9 million trainable parameters; both training and forecast production run on a single GPU. Evaluation on an independent sample of 1607 initial times covering all seasons yields a root-mean-square error of the 2-m temperature forecast of 1.84°C at the 24-h lead time with a skill score of 69 % relative to persistence. A controlled experiment with an equal training budget shows that the single-step validation error is an unreliable criterion for selecting a model intended for multi-step forecasting. Observation assimilation by relaxation (nudging) and optimal interpolation within the autoregressive cycle is examined: continuous assimilation limits error growth over a 168-h rollout, whereas the

model's memory of a single correction lasts about one day.

Keywords: numerical weather prediction, graph neural network, regional forecasting, multiscale mesh, data assimilation, optimal interpolation, autoregressive forecast, machine learning

Введение

Численный прогноз погоды основан на интегрировании уравнений гидротермодинамики атмосферы на сетке высокого разрешения. За десятилетия развития подход достиг высокой точности, однако расчёт одного глобального прогноза на средние сроки требует часов работы суперкомпьютерного комплекса, что ограничивает и частоту обновления прогноза, и возможность построения больших ансамблей.

В 2022–2023 годах произошёл качественный сдвиг: нейросетевые модели, обученные на архиве реанализа, показали точность, сопоставимую с оперативными системами ведущих метеоцентров, при несопоставимо меньших затратах на выпуск прогноза. Модель GraphCast [1], построенная на графовом представлении атмосферного состояния, превзошла оперативную систему Европейского центра по большинству переменных на сроках от трёх до десяти суток; сопоставимые результаты получены моделями Pangu-Weather [2] и FourCastNet [3]. Ключевым элементом GraphCast является представление расчётной области графом с квазиравномерным распределением узлов по сфере: это позволяет выучивать локальные закономерности независимо от географического положения — свойство, недостижимое для регулярной сетки в координатах широта–долгота.

подавляющее большинство таких систем решает глобальную задачу, тогда как практический интерес часто представляет прогноз повышенной детальности над ограниченной территорией. Перенос подхода на региональный масштаб порождает специфические трудности. Главная из них — граничные условия: у краевых узлов вырезанной области нет корректного окружения, и в классическом численном прогнозе это решается заданием внешних граничных условий с релаксацией к внешнему полю в буферной зоне [4], что требует отдельной процедуры и вносит собственные погрешности. К этому добавляется накопление ошибки в авторегрессионной развёртке, для ограниченной области выраженное сильнее, и разрежённость наблюдений, согласование которых с полем модели составляет предмет теории усвоения данных [9] — её применимость к авторегрессионному нейросетевому прогнозу остаётся открытым вопросом.

В нейросетевых региональных моделях предложено несколько способов обойти проблему границ: подача граничного форсинга от глобальной модели в архитектуре Neural-LAM [5]; растянутая сетка с плавным изменением разрешения [6]; вложенные сетки с обменом информацией между уровнями [7]. Сравнение подходов с растянутой сеткой и с ограниченной областью выполнено в [8].

Настоящая работа посвящена региональной модели прогноза над югом Красноярского края. Вклад состоит в следующем.

1. Реализована конструкция единой мультимасштабной сетки, в которой глобальная сетка с шагом $0,703^\circ$ и региональная вставка с шагом $0,25^\circ$ объединены в один граф без внешних границ, а согласование разрешений достигается не отдельной процедурой сшивания, а самим механизмом обмена сообщениями. Идея мультимасштабного представления не нова [6, 7]; предлагаемый вариант отличается способом построения — прямой заменой узлов глобальной решётки региональной вставкой с единообразным построением связности. Количественно показано, что такая конструкция превосходит интерполяцию прогноза глобальной модели в те же узлы, и приведена прямая диагностика стыка.
2. Модель намеренно выполнена лёгкой — 5,9 млн параметров против сотен миллионов у [1, 2, 6]; обучение и выпуск прогноза производятся на одном графическом ускорителе, что делает

воспроизведение результата осуществимым в вычислительной среде регионального управления гидрометслужбы.

- }. Количественно исследована стратегия дообучения глобальной модели под региональную сетку. Получен методический результат, имеющий, по мнению авторов, самостоятельное значение: ошибка одношагового прогноза на проверочной выборке — ненадёжный критерий отбора состояния модели, предназначенной для многошагового прогноза.
- l. Исследована совместимость классических методов усвоения данных — релаксационного и оптимальной интерполяции — с авторегрессионным нейросетевым прогнозом; вклад усвоения оценён по горизонтам вплоть до четырнадцати суток.

Отечественный контекст задачи составляют оперативные системы Гидрометцентра России, в том числе полулагранжева модель ПЛАВ [10]; нейросетевые методы в отечественной практике применяются преимущественно для наукастинга и постобработки [заполнить: 1-2 ссылки на отечественные работы по машинному обучению в прогнозе погоды](#).

Данные, базовая модель и метрики качества

Исходные данные

Обучение и оценка выполнены на реанализе ERA5 Европейского центра среднесрочных прогнозов погоды [1] за 2010–2020 гг. с шагом 6 ч, что даёт 16 072 последовательных срока.

Состояние атмосферы описывается набором из 19 полей. Приземные и статические: температура воздуха на высоте 2 м, зональная и меридиональная компоненты ветра на высоте 10 м, давление на уровне моря, приземное давление, суммарные осадки за 6 ч, общее содержание водяного пара в столбе атмосферы, геопотенциал поверхности и маска «суша — море». Два последних поля статические: подаются на вход, но не прогнозируются, переносятся между шагами без изменений и исключены из всех приводимых оценок. На каждом из уровней 850 и 500 гПа задаются пять полей: температура, две компоненты ветра, геопотенциал и удельная влажность. Вертикальная структура атмосферы кодируется, таким образом, составом признаков узла, а не отдельными узлами по вертикали.

Поля хранятся в физических единицах: температура — в кельвинах, ветер — в м/с, давление на уровне моря и приземное — в гПа, геопотенциал — в геопотенциальных метрах (поле ERA5 в $\text{м}^2/\text{с}^2$ однократно поделено на $g = 9,80665 \text{ м/с}^2$), содержание водяного пара — в кг/м^3 . Перед подачей в сеть каждый канал стандартизуется вычитанием среднего и делением на стандартное отклонение; оба скаляра оценены по всему периоду 2010–2020 гг., включая проверочную и тестовую части, — влияние двух чисел на канал пренебрежимо, но факт указывается явно.

Входное окно — два последовательных срока (12 ч предыстории); прогноз строится авторегрессионно с шагом 6 ч. Основные горизонты оценки — +6, +12, +18 и +24 ч; поведение при развёртке до +168 ч рассматривается в разделе об усвоении наблюдений.

Целевая область (регион) ограничена координатами 50–60° с. ш., 83–98° в. д. и покрывается решёткой с шагом 0,25° размером $61 \times 41 = 2501$ узел. Внутри выделена внутренняя зона 55,5–56,5° с. ш., 92–94° в. д. (45 узлов), включающая Красноярск и окрестности. Все метрики вычислены относительно реальных полей ERA5 с шагом 0,25° в этих узлах, без интерполяции с более грубой сетки.

Хронологическое разбиение выборки

Разбиение выполнено строго хронологически, без перемешивания сроков: обучающая выборка целиком предшествует проверочной, а проверочная — тестовой, что исключает попадание в обучение информации о будущих состояниях. Из 16 072 сроков при окне «2 входных среза + 4 прогностических шага» формируется 16 067 примеров, делящихся в отношении 80/10/10: 12 853 — обучение, 1607 — проверочная выборка (подбор гиперпараметров и отбор состояния модели), 1607 — тестовая выборка, на которой получены все публикуемые числа. Тестовая выборка охватывает конец 2019 г. и полностью 2020 г., то есть содержит непрерывный годовой цикл и все четыре сезона: обучающая выборка — сроки начала прогноза с 01.01.2010 06 UTC по 19.10.2018 06 UTC, проверочная — с 19.10.2018 12 UTC по 25.11.2019 00 UTC, тестовая — с 25.11.2019 06 UTC по 30.12.2020 18 UTC. Это существенно, поскольку оценки, полученные на срезе одного холодного сезона, не характеризуют качество модели в целом.

Базовая глобальная модель

Отправной точкой регионального дообучения служит глобальная модель, обученная на тех же 19 полях на широтно-долготной сетке 512×256 узлов (шаг около $0,703^\circ$). Она реализует схему «кодировщик — процессор — декодировщик» на графе: кодировщик переносит признаки узлов расчётной сетки на вершины икосаэдрической мозаики (уровни детализации 4 и 6), процессор выполняет 12 раундов обмена сообщениями блоком типа Interaction Network [2] с четырёхмерными геометрическими признаками рёбер, декодировщик возвращает результат в узлы сетки. Латентная размерность — 256, число обучаемых параметров — 5,9 млн, что на два-три порядка меньше, чем у известных глобальных нейросетевых моделей [3], и позволяет вести обучение и оперативный выпуск прогноза на одной видеокарте.

Функция потерь — среднеквадратическая ошибка в стандартизованных переменных, осреднённая по узлам, каналам и горизонтам, с поэтапным наращиванием длины авторегрессионной развёртки. Отметим особенность реализации, выявленную при подготовке работы: при глобальном предобучении широтное взвешивание узлов оказалось практически равномерным, тогда как при региональном дообучении (см. следующий раздел) применялись веса $\cos\varphi$, где φ — широта узла. Региональное дообучение стартовало с промежуточного набора весов глобальной модели: лучшее по проверочной выборке состояние (эпоха 30 из 36 пройденных). Качество базовой модели на её собственной сетке: агрегатная успешность 65,4 % при ошибке приземной температуры $1,07^\circ\text{C}$ в среднем по горизонтам $+6\dots+24$ ч (200 сроков, собственная сетка модели).

Метрики качества

Для канала c и горизонта τ среднеквадратическая ошибка вычисляется в физических единицах канала:

$$\text{RMSE}_c(\tau) = \left[\frac{1}{N|G|} \sum_{n=1}^N \sum_{g \in G} (\hat{x}_{c,g}^{(n)}(\tau) - x_{c,g}^{(n)}(\tau))^2 \right]^{1/2}, \quad (1)$$

где N — число сроков ($N = 1607$ для тестовой выборки); G — множество оцениваемых узлов ($|G| = 2501$ для региона, 45 для внутренней зоны); $\hat{x}_{c,g}^{(n)}(\tau)$ — прогностическое значение канала c в узле g на горизонте τ из срока n ; $x_{c,g}^{(n)}(\tau)$ — соответствующее значение реанализа, принимаемое за истинное. Ошибка приводится в единицах переменной: температура — в $^\circ\text{C}$ (для разности градус Цельсия численно совпадает с кельвином), ветер — в м/с, давление — в гПа, геопотенциал — в гпм. Узлы суммируются с равными весами, без взвешивания на площадь ячейки; при широтном диапазоне $50\text{--}60^\circ$ с. ш. отношение площадей ячеек на границах области составляет около 1,29, что одинаково для всех сравниваемых конфигураций и не влияет на их упорядочение.

В качестве простейшего эталона используется инерционный прогноз: значения полей в последний срок входного окна t_0 переносятся без изменений на все горизонты, $\hat{x}^{\text{ин}}(t_0 + \tau) = x(t_0)$. Успешность относительно него определяется как

$$S_c(\tau) = (1 - \frac{\text{RMSE}_c(\tau)}{\text{RMSE}^{\text{ин}}_c(\tau)}) \cdot 100 \%, \quad (2)$$

где $\text{RMSE}^{\text{ин}}_c(\tau)$ — ошибка (1) для инерционного прогноза на том же окне и той же маске узлов. Значение $S = 0$ соответствует совпадению с эталоном, $S > 0$ — превосходству над ним. Инерционный эталон строг на горизонте +6 ч и слаб на +24 ч, поэтому рост S с горизонтом отражает прежде всего деградацию эталона, тогда как абсолютная ошибка (1) монотонно возрастает. Сопоставление с климатическим эталоном приводится отдельно. Климатология строилась по обучающей части выборки разложением по гармоникам: три годовые гармоники и суточный ход (косинус и синус первой гармоники плюс косинус второй; синус второй при шестичасовой дискретности неопределим). Тестовые сроки в подгонку не входили. Ошибка климатологии по узлам региональной вставки составляет 6,25 °C для приземной температуры, 5,42 °C для температуры на уровне 850 гПа, 9,19 гПа для давления на уровне моря и 2,05 и 1,74 м/с для составляющих приземного ветра; от горизонта она, в отличие от инерционной, практически не зависит (6,25 °C на всех сроках от +6 до +24 ч). Успешность модели относительно климатологии на горизонте +24 ч: 73,4 % по приземной температуре, 80,6 % по температуре на 850 гПа, 87,5 % по давлению на уровне моря, 64,0 и 59,2 % по составляющим ветра. Поскольку климатический эталон не деградирует с ростом горизонта, именно он определяет предел полезности прогноза: при развёртке до 168 ч (п. 5) ошибка приземной температуры достигает уровня климатологии в районе шестых суток, что и следует считать границей осмысленности детерминированного прогноза для рассматриваемой конфигурации.

Для сводной оценки по всем полям применяется агрегатный показатель. Поскольку каналы имеют разные единицы, агрегирование выполняется в стандартизованных переменных:

$$\overline{\text{RMSE}} = [\frac{1}{N|G|CH} \sum_n \sum_{g \in G} \sum_{c=1}^C \sum_{\tau} (\frac{\hat{x}^{(n)}_{c,g}(\tau) - x^{(n)}_{c,g}(\tau)}{\sigma_c})^2]^{1/2}, \quad \bar{S} = (1 - \frac{\overline{\text{RMSE}}}{\overline{\text{RMSE}^{\text{ин}}}}) \cdot 100 \%, \quad (3)$$

где σ_c — стандартное отклонение канала c , использованное при стандартизации; C — число прогностических каналов ($C = 17$); $H = 4$ — число горизонтов. Величина $\overline{\text{RMSE}}$ безразмерна, поэтому содержательна только в сравнении с эталоном, то есть через $\bar{S}$.

Дополнительно используется пространственная корреляция прогностического и фактического полей. Существенная оговорка: центрирование выполняется по среднему значению внутри рассматриваемой области, а не по климатологии, поэтому приводимая величина не является коэффициентом корреляции аномалий в принятом в метеорологии смысле; её значения зависят от размера области и допускают сопоставление только между строками таблиц настоящей работы.

Точность оценок характеризуется доверительными интервалами, полученными блочным бутстрепом: поскольку сроки начала прогноза следуют через 6 ч и коррелированы внутри одного синоптического процесса, ресэмплированию подвергаются блоки подряд идущих сроков длиной в несколько суток, а не отдельные сроки [4].

Мультимасштабная графовая модель и стратегия дообучения

Ограничения регулярной сетки на сфере

Прогностическая модель обучается воспроизводить локальные закономерности эволюции атмосферных полей: значение переменной в узле через шесть часов определяется состоянием в его пространственной окрестности. Чтобы такая закономерность была выучиваема, операция «взять окрестность узла» должна означать во всех точках расчётной области примерно одно и то же — окрестность фиксированного физического размера.

Для регулярной сетки в координатах широта–долгота это условие не выполняется. При шаге 0.703° расстояние между соседними узлами вдоль параллели составляет около 78 км на экваторе и убывает пропорционально косинусу широты: примерно 50 км на 50° с.ш. и около 14 км на 80° с.ш. Свёрточный фильтр с фиксированным размером окна охватывает поэтому существенно разные физические области в зависимости от широты, а вблизи полюсов сетка вырождается. Модель вынуждена либо усреднять эту неоднородность, либо расходовать ёмкость на её запоминание; ни то, ни другое не желательно.

Альтернатива — представить расчётную область графом, узлы которого распределены по сфере квазиравномерно. Такое распределение даёт икосаэдрическая триангуляция: исходный икосаэдр из 20 равных треугольных граней рекурсивно измельчается делением каждого треугольника на четыре с проецированием новых вершин на сферу. На любом уровне измельчения каждая вершина имеет пять или шесть соседей, а разброс длин рёбер невелик, поэтому окрестность узла всюду соответствует близкому физическому масштабу. Именно это свойство лежит в основе современных нейросетевых моделей прогноза [1, 2].

Архитектура

Используется схема «кодировщик — процессор — декодировщик» [1, 3], в которой обмен информацией происходит на графе, а входные и выходные поля остаются на регулярной сетке (рис. 1).

Кодировщик переносит значения из узлов регулярной сетки в вершины графа. Для каждой вершины графа формируется сообщение от узлов сетки, попавших в её окрестность (радиус связи 0.6 в единицах длины ребра графа), после чего многослойный персептрон преобразует агрегированное сообщение в скрытое представление размерности 256.

Процессор выполняет $R = 12$ раундов обмена сообщениями по рёбрам графа. Один раунд реализован блоком Interaction Network [4] и состоит из двух шагов. Сначала для каждого ребра ($i \rightarrow j$) вычисляется сообщение

$$m_{ij}^{(r)} = \varphi_e(h_i^{(r-1)}, h_j^{(r-1)}, e_{ij}), \quad (1)$$

затем состояние вершины обновляется по агрегированным входящим сообщениям:

$$h_j^{(r)} = \varphi_v(h_j^{(r-1)}, \frac{1}{|N(j)|} \sum_{i \in N(j)} m_{ij}^{(r)}), \quad (2)$$

где $h_j^{(r)}$ — скрытое представление вершины j после раунда r (размерность 256); e_{ij} — постоянные признаки ребра (четыре величины: длина ребра и три компоненты единичного вектора направления в геоцентрической системе координат); $N(j)$ — множество вершин, соединённых с j ; φ_e и φ_v — многослойные персептроны с функцией активации Swish и послойной нормировкой. Веса φ_e , φ_v не разделяются между раундами: каждый из 12 раундов имеет собственные параметры, что соответствует организации процессора в [1].

Декодировщик выполняет обратный перенос: скрытые представления вершин графа отображаются в приращения полей в узлах регулярной сетки.

Прогноз строится авторегрессионно с шагом 6 ч: выход модели подаётся на её вход для получения следующего срока,

$$\hat{x}(t_0 + 6(k+1)) = F(\hat{x}(t_0 + 6k), \hat{x}(t_0 + 6(k-1))), \quad k = 0, 1, \dots, K-1, \quad (3)$$

где F — обученное отображение (кодировщик-процессор-декодировщик), входное окно составляет два последовательных срока (12 ч), а при $k = 0$ используются два среза анализа. Общее число обучаемых параметров модели — 5.9 млн.

Небольшой размер модели — сознательное проектное решение. Обучение и оперативная работа выполняются на одной графической карте, что делает воспроизведение результата возможным в вычислительной среде регионального управления гидрометслужбы, тогда как модели с сотнями миллионов параметров [2, 5] требуют многоузловых конфигураций.

Мультимасштабная расчётная сетка

Классический способ построения региональной модели — вырезать область из глобальной сетки и задавать на её краю внешние граничные условия. У такого подхода есть известный недостаток: граничные узлы не имеют корректного окружения, из-за чего у края накапливаются искажения, а для их подавления требуется отдельная процедура сшивания с внешним полем [6].

В настоящей работе используется иной приём: глобальная и региональная сетки объединяются в единый граф, и понятие внешней границы для модели исчезает. Из глобальной сетки 512×256 (шаг 0.703°) удаляются узлы, попадающие внутрь области интереса, а на их место помещается регулярная региональная решётка с шагом 0.25° ($61 \times 41 = 2501$ узел) в границах $50\text{--}60^\circ$ с.ш., $83\text{--}98^\circ$ в.д. Итоговая расчётная сетка содержит

$$N = \frac{130\,778}{\text{глобальные узлы}} + \frac{2\,501}{\text{региональная вставка}} = 133\,279 \text{ узлов.}$$

Рёбра между узлами и вершинами графа строятся поиском ближайших соседей в трёхмерном пространстве по геоцентрическим координатам, единообразно для узлов обоих разрешений; никакой специальной обработки переходной зоны при построении связности не выполняется.

Соединение областей выполнено жёстко: множества узлов не пересекаются по построению, значения просто объединяются в единый вектор состояния,

$$x = [x^{\text{глоб}}_{\text{вне области}}, x^{\text{рег}}_{\text{внутри области}}], \quad (4)$$

без весовой функции и сглаживания на стыке. Согласование разрешений происходит неявно, в ходе обмена сообщениями: узлы по обе стороны стыка связаны рёбрами и на каждом из 12 раундов обмениваются признаками, так что переходный слой формируется самой моделью в процессе обучения.

Это принципиально отличает предлагаемый приём от метода Дэвиса [6] и его модификаций: там сшивание применяется после получения прогноза, как постобработка поля, тогда как здесь объединённая сетка является частью входного представления и участвует в обучении. Прямая экспериментальная проверка бесшовности стыка приведена на рис. 2. На панели (а) показано поле приземной температуры на горизонте +24 ч в окрестности границы вставки: смена разрешения видна по размеру ячеек, разрыва поля на склейке нет. На панели (б) — среднеквадратическая ошибка в зависимости от расстояния до границы (100 сроков). В полосе 0–25 км внутри вставки ошибка составляет $2,12^\circ\text{C}$ против $2,07^\circ\text{C}$ в её середине (200–1000 км), то есть на 2,3 % выше; снаружи, в полосе 0–100 км от границы, — $1,87^\circ\text{C}$. Систематического всплеска ошибки у стыка не наблюдается: разброс между полосами не превышает нескольких процентов и не превосходит различий между зонами, обусловленных разной подстилающей поверхностью.




Рис. 2. Стык региональной вставки. (а) прогноз приземной температуры на +24 ч; размер ячейки соответствует шагу сетки — $0,25^\circ$ внутри вставки и $0,703^\circ$ снаружи. (б) среднеквадратическая ошибка по расстоянию до границы, 100 сроков.

Отметим ограничение подхода: региональная вставка задана прямоугольником в координатах широта-долгота, то есть внутри неё сохраняется та же неоднородность шага по долготе, что обсуждалась в п. 3.1. Для области протяжённостью 10° по широте это отношение составляет $\cos 50^{\text{circ}} / \cos 60^{\text{circ}} \approx 1.29$ и на масштабе задачи несущественно, однако при переносе схемы на область большей широтной протяжённости этот фактор потребует учёта.

Стратегия дообучения

Региональная модель получается дообучением глобальной, обученной на той же выборке ERA5 в конфигурации 512×256 . При смене геометрии расчётной сетки веса кодировщика и декодировщика оказываются несогласованными с новой связностью, тогда как процессор содержит выученную на глобальной задаче динамику. Прямое дообучение всех параметров сразу несёт риск разрушения этой динамики большими градиентами со стороны неадаптированных кодировщика и декодировщика — эффект, известный как катастрофическое забывание.

Применяется двухфазная схема:

1. Фаза 1 (первые E_f эпох): параметры процессора зафиксированы, обучаются только кодировщик и декодировщик, приспосабливаясь к новой геометрии и статистике региона.
2. Фаза 2 (оставшиеся эпохи): процессор размораживается, но его темп обучения устанавливается в 10 раз меньше базового.

В основной конфигурации $E_f = 10$, в конфигурациях, использованных для проверки самой стратегии (п. 4.4), $E_f = 6$; базовый темп обучения 10^{-4} , оптимизатор Adam.

Одновременно применяется учебный план по длине авторегрессионной развёртки: обучение начинается с одношагового прогноза, а затем число шагов K в (3) последовательно увеличивается до четырёх, причём функция потерь вычисляется по всем шагам развёртки. Это согласует режим обучения с режимом применения, где модель работает авторегрессионно.

Функция потерь — среднеквадратическая ошибка в стандартизованных переменных,

вычисляемая по всем узлам расчётной сетки (не только по региональной вставке; вариант с ограничением потерь областью интереса приводил к деградации полей за её пределами и через авторегрессионную обратную связь ухудшал прогноз внутри области). Статические поля — рельеф и маска суши/моря — исключены из функции потерь и переносятся между шагами развёртки без изменений.

Результаты: качество регионального прогноза

Условия оценки

Все оценки получены на едином окне верификации и при единственном определении истинного поля (разд. 2): реанализ ERA5 с шагом $0,25^\circ$ в узлах региональной вставки, тестовая выборка 1607 сроков, все четыре сезона. Показатели — среднеквадратическая ошибка в физических единицах (1), успешность относительно инерционного прогноза (2) и агрегатная успешность по 17 прогностическим каналам (3).

При чтении таблиц следует учитывать свойство инерционного эталона: он строг на горизонте +6 ч и слаб на +24 ч, поэтому рост успешности с горизонтом отражает в первую очередь деградацию эталона, тогда как абсолютная ошибка монотонно возрастает.

Качество основной модели

Табл. 1. Ошибка приземной температуры ($^\circ\text{C}$) по горизонтам и агрегатная успешность $\bar{S}$ (%) основной модели. Здесь и далее $\bar{S}$ — агрегат по всем прогностическим каналам и всем четырём горизонтам согласно (3), а не значение на отдельном сроке. Для сравнения приведена конфигурация с сокращённым составом полей (19 каналов, уровни 850 и 500 гПа). Тестовая выборка 1607 сроков; регион — 2501 узел, внутренняя зона — 45 узлов.

Зона	Конфигурация	+6 ч	+12 ч	+18 ч	+24 ч	$\bar{S}$, %
Регион	основная, 33 канала	1,32	1,53	1,59	1,66	73,4
	19 каналов	1,39	1,66	1,74	1,84	69,4
Внутренняя зона	основная, 33 канала	1,21	1,41	1,47	1,53	74,5
	19 каналов	1,30	1,58	1,69	1,82	заполнить: агрегатная успешность 19-канальной модели во внутренней зоне

Ошибка приземной температуры на суточном сроке составляет $1,66^\circ\text{C}$ по области и $1,53^\circ\text{C}$ во внутренней зоне. По остальным полям на том же сроке (регион): компоненты приземного ветра 0,59 и 0,62 м/с, давление на уровне моря 1,66 гПа, температура на уровне 850 гПа $1,23^\circ\text{C}$, геопотенциал на уровне 500 гПа 13,3 гпм.

Расширение состава полей с 19 до 33 каналов (добавление уровней 250 и 1000 гПа и временного форсинга) даёт выигрыш, значимый на всех горизонтах: 0,076 / 0,121 / 0,149 / 0,174 $^\circ\text{C}$ с 95 %-ми доверительными интервалами [0,063; 0,088], [0,104; 0,138], [0,125; 0,171] и [0,141; 0,210] соответственно (блочный бутстреп, блок 5 суток, 2000 реплик, парное сравнение на совпадающих сроках). Отнести весь выигрыш к добавленным уровням, однако, нельзя: 33-канальная конфигурация дообучалась от иной глобальной модели, которая и сама точнее по общим полям.

Что даёт единый граф

Чтобы оценить вклад собственно мультимасштабной конструкции, прогноз глобальной модели с шагом $0,703^\circ$ интерполирован билинейно в те же 2501 узел и оценён против той же истины. Все строки табл. 2 посчитаны на одних и тех же 100 сроках тестовой выборки.

Табл. 2. Ошибка прогноза на горизонте +24 ч в узлах региональной вставки: инерционный прогноз, интерполяция прогноза глобальной модели и мультимасштабная модель.

Поле	Инерционный прогноз	Глобальная $0,703^\circ$ + интерполяция	Мультимасштабная	Выигрыш
t2m, °C	4,20	2,30	2,05	11 %
10u, м/с	2,71	0,99	0,59	40 %
msl, гПа	9,36	2,23	1,66	26 %
t@850, °C	6,27	1,48	1,23	17 %
z@500, гПм	88,5	21,0	13,3	37 %

Единый граф превосходит интерполяцию по всем полям. Выигрыш умеренный по приземной температуре (11 %) и существенный по ветру и геопотенциалу (37–40 %). Это согласуется с устройством приёма: обмен сообщениями уточняет поле как целое, тогда как приземная температура в конкретном узле сильнее определяется подсеточными факторами, которых не разрешает ни одна из сравниваемых конфигураций.

Стратегия дообучения и выбор контрольной точки

Стратегия регионального дообучения исследована на отдельной, 19-канальной линии моделей: сравниваются конфигурация с заморозкой процессора на первые 6 эпох и конфигурация, где все параметры обучаются с первой эпохи. Обе обучены на одной сборке данных, при одном начальном значении генератора случайных чисел и одинаковом расписании, поэтому различаются только стратегией.

Табл. 3. Ошибка приземной температуры (°C) по региону и агрегатная успешность при разных способах отбора контрольной точки.

Конфигурация	Состояние	+6 ч	+12 ч	+18 ч	+24 ч	$\bar{S}$, %
С заморозкой	лучшая по val (эпоха 16)	1,34	1,59	1,71	1,82	60,8
Без заморозки	лучшая по val (эпоха 7)	1,36	1,65	1,81	1,96	59,9
Без заморозки	равный бюджет (эпоха 16)	1,35	1,62	1,72	1,82	59,5

Сравнение по лучшим контрольным точкам даёт выигрыш в пользу заморозки, растущий с горизонтом — до $0,14^\circ\text{C}$ на +24 ч. Однако лучшие точки достигаются на разных эпохах, 16-й и 7-й, то есть такое сравнение сопоставляет не только стратегии, но и объёмы обучения. При равном бюджете разность по приземной температуре исчезает: обе конфигурации дают $1,82^\circ\text{C}$ на суточном сроке.

Более того, контрольная точка эпохи 7, отобранная как «лучшая» по одношаговой ошибке, в авторегрессионной развёртке уступает собственной же точке эпохи 16 ($1,96$ против $1,82^\circ\text{C}$). Тот же эффект независимо воспроизводится на основной модели: её состояние, отобранное по минимуму ошибки на проверочной выборке, точнее на горизонте +6 ч ($1,30$ против $1,32^\circ\text{C}$), но уступает на +18 и +24 ч ($1,63$ против $1,59$ и $1,71$ против $1,66^\circ\text{C}$), причём смена знака значима с обеих сторон.

Отсюда следует методический вывод, представляющийся самостоятельным результатом. Минимум одношаговой ошибки на проверочной выборке — ненадёжный критерий выбора состояния модели, предназначенной для многошагового прогноза. Такой критерий отбирает

модель, оптимальную ровно на том горизонте, который он измеряет; на целевых горизонтах она проигрывает. Отбор следует вести по метрике при полной авторегрессионной развёртке, а сравнения стратегий обучения — при равном бюджете.

Роль самой заморозки формулируется сдержанно: расписание на итог не влияет. Однако адаптация процессора под регион необходима: при заморозке на всё обучение ошибка на проверочной выборке оказывается на 7,5 % выше, обучение выходит на плато уже к восьмой эпохе, и растёт также ошибка на обучающей выборке — модели не хватает свободы подстроить динамику, а не данных.

Расхождение агрегатного показателя и поканальных значений

Сопоставление строк табл. 3 обнаруживает обстоятельство, существенное для методики отчётности. По агрегатной успешности конфигурации различаются на величину до 8 процентных пунктов, тогда как по приземной температуре — полю, наиболее востребованному потребителем прогноза, — они могут совпадать в точности.

Причина в том, что агрегат усредняет нормированные ошибки по всем каналам, и вклад каждого определяется отношением его ошибки к разбросу поля, а не значимостью канала для практики. Поэтому агрегат может улучшаться за счёт полей, не входящих в число ключевых для потребителя, при неизменной приземной температуре.

Практический вывод: единственный агрегатный показатель недостаточен для выбора рабочей конфигурации, а ранжирование конфигураций зависит от того, какое поле и какая область осреднения объявлены целевыми. В отчётности следует приводить и агрегат, и поканальные значения по целевым полям на одной и той же маске узлов.

Диагностика стыка

Утверждение о том, что жёсткая склейка узлов не требует отдельной процедуры сшивания, проверено прямо: ошибка приземной температуры вычислена по полосам расстояния до границы региональной вставки. Оценка выполнена на 100 сроках тестовой выборки.

Табл. 4. Ошибка приземной температуры (°C) по расстоянию до границы вставки. Положительное расстояние — внутри вставки (шаг 0,25°), отрицательное — снаружи, на глобальной части графа (шаг 0,703°).

Зона	Расстояние до границы, км	Узлов	+6 ч	+12 ч	+18 ч	+24 ч
Вставка 0,25°	0-25	278	1,58	1,97	2,06	2,12
	25-50	240	1,54	1,92	2,00	2,08
	50-100	414	1,51	1,85	1,94	2,02
	100-200	698	1,49	1,81	1,91	1,99
	200-1000	871	1,40	1,80	1,97	2,07
Глобальная 0,703°	-100...0	143	1,37	1,74	1,82	1,87
	-300...-100	308	1,42	1,76	1,88	1,95
	-1000...-300	1708	1,36	1,73	1,91	2,05

Картина двойственная, и обе её стороны существенны.

Переходный слой существует. На горизонте +6 ч ошибка убывает монотонно по мере удаления от границы: 1,58 °C в полосе шириной 25 км против 1,40 °C в глубине области, то есть у стыка она выше на 13 %. Эффект прослеживается примерно на 100-200 км. Утверждать полную бесшовность неправомерно.

Однако в авторегрессии он не усиливается. С ростом горизонта относительное превышение убывает: 13 % на +6 ч, 9 % на +12 ч и лишь 2 % на +24 ч. Это принципиально: погрешность, вносимая стыком, не накапливается при последовательном применении модели к собственному выходу, тогда как именно неограниченный рост приграничной ошибки составляет основную трудность региональных моделей с внешними граничными условиями. Убывание объясняется тем, что на дальних сроках начинает преобладать другой источник ошибки — рельеф: в глубине области расположены горные районы, и там ошибка на +24 ч превышает значение в полосе 100–200 км, хотя на +6 ч соотношение обратное.

Глобальная часть не страдает. Непосредственно за границей вставки ошибка (1,87 °C на +24 ч) не превышает значений вдали от неё (1,95 и 2,05 °C): вставка более подробной сетки не ухудшает прогноз в окружающей области.

Итоговая формулировка: склейка порождает контролируемый переходный слой шириной порядка 100 км, заметный на ближних горизонтах и затухающий на дальних, и не требует отдельной процедуры сшивания полей.

Усвоение наблюдений в цикле прогноза

Постановка задачи и методы

Ошибка авторегрессионного прогноза нарастает с горизонтом, поэтому естественный способ ограничить рост — периодически корректировать состояние по измерениям. Специальная процедура необходима из-за несоответствия двух представлений информации: модели требуется значение каждой переменной во всех 133 279 узлах, тогда как наблюдения доступны в отдельных точках и распределены неравномерно. Задача усвоения — совместить полностью прогностического поля с точностью измерений, распространив информацию из точек наблюдений на окрестность физически осмысленным образом [1].

Исследуются два классических метода, применяемых пошагово внутри авторегрессионной развёртки: после каждого шага прогноза поле корректируется, и уже исправленное состояние подаётся на вход следующего шага.

Релаксационное усвоение (нуджинг). Простейшая схема — линейная релаксация к наблюдениям в узлах, где они доступны:

$$x_g^a = x_g^b + \alpha m_g (y_g - x_g^b), \quad (1)$$

где x_g^b — прогностическое (фоновое) значение в узле g ; y_g — наблюдение; $m_g \in \{0,1\}$ — индикатор наличия наблюдения; α — коэффициент релаксации; x_g^a — скорректированное значение. Схема вычислительно тривиальна, но коррекция применяется только в наблюдаемых узлах: при разрежённой сети это порождает локальные возмущения, не согласованные с окружающим полем.

Оптимальная интерполяция [1] учитывает пространственную структуру ошибок и распространяет поправку на окрестность каждого наблюдения:

$$\mathbf{x}^a = \mathbf{x}^b + \mathbf{K}(\mathbf{y} - \mathbf{H}\mathbf{x}^b), \quad \mathbf{K} = \mathbf{B}\mathbf{H}^T (\mathbf{H}\mathbf{B}\mathbf{H}^T + \mathbf{R})^{-1}, \quad (2)$$

где $\mathbf{H}$ — оператор наблюдений, сопоставляющий состоянию модели значения в точках измерений (реализован как выбор ближайшего узла сетки); $\mathbf{B}$ — ковариационная матрица ошибок фона; $\mathbf{R}$ — ковариационная матрица ошибок наблюдений; $\mathbf{K}$ — матрица усиления. Ковариации ошибок фона задаются гауссовой моделью, убывающей с расстоянием: $B_{ij} = \sigma_b^2 \exp(-d_{ij}^2/L^2)$, где d_{ij} — расстояние между узлами по формуле гаверсина, L — радиус корреляции, σ_b — среднеквадратическое отклонение ошибки фона. Ошибки наблюдений

полагаются некоррелированными: $\mathbf{R} = \sigma_o^2 \mathbf{I}$. Усвоение выполняется независимо для каждой переменной, матрица $\mathbf{B}$ строится однократно.

Существенно для настройки, что подстановка $\mathbf{B} = \sigma_b^2 \mathbf{C}$ и $\mathbf{R} = \sigma_o^2 \mathbf{I}$ в (2) даёт матрицу усиления, зависящую не от σ_b и σ_o по отдельности, а только от их отношения. Поэтому величина $\sigma_b = 0,8$ фиксирована, а подбирается σ_o ; этого достаточно для перебора всех различных конфигураций схемы.

Обоснование выбора методов

Современные оперативные системы усвоения используют преимущественно вариационные методы либо ансамблевые фильтры Калмана, превосходящие оптимальную интерполяцию по точности [1, 2]. Выбор более простых схем здесь продиктован постановкой задачи. Во-первых, целью является не построение оптимальной системы усвоения, а проверка принципиальной совместимости пошаговой коррекции с авторегрессионным нейросетевым прогнозом: прогностический оператор — обученная сеть, а не численное интегрирование уравнений, и поведение цикла «прогноз — коррекция» в таком сочетании заранее неочевидно. Во-вторых, вариационные методы требуют построения сопряжённой модели, ансамблевые — многократного прогона модели; и то, и другое составляет самостоятельную задачу. В-третьих, схемы (1) и (2) вычислительно пренебрежимы на фоне самого прогноза и не нарушают основного свойства подхода — выпуска прогноза за секунды на одном ускорителе.

Постановка эксперимента

Эксперименты выполнены по схеме «идентичных близнецов»: в качестве наблюдений используются значения реанализа в случайно выбранном подмножестве узлов региональной вставки. Рассмотрены две плотности — 10 % узлов (около 250 условных станций) и 1 % (около 25), причём вторая ближе к реальной плотности наземной сети в регионе.

Постановка идеализирована, и это следует оговорить прямо: наблюдения не содержат инструментальной погрешности и ошибки репрезентативности, размещены строго в узлах сетки и доступны для всех переменных одновременно. Полученные величины прироста качества характеризуют поэтому верхнюю границу возможного эффекта.

Радиус корреляции ошибок фона L и дисперсия ошибок наблюдений σ_o подбирались на проверочной выборке, результаты приводятся на тестовой; прогоны на тестовой выборке повторены с тремя различными расстановками условных станций. Результаты подбора приведены в табл. 2: оптимум достигается при $L = 100$ км и $\sigma_o = 0,5$, причём весь разброс по двенадцати сочетаниям укладывается в два процентных пункта, то есть схема мало чувствительна к выбору этих величин. Отметим, что тот же оптимум был получен и для 19-канальной конфигурации модели, — настройки усвоения переносятся между конфигурациями сети.

Табл. 2. Подбор гиперпараметров оптимальной интерполяции на проверочной выборке (200 сроков, регион): агрегатная успешность, %, и ошибка приземной температуры, °С, по горизонтам +6 / +12 / +18 / +24 ч.

L , км	σ_o	$\bar{S}$, %	RMSE t2m по горизонтам, °C
50	0,3	88,25	0,87 / 1,01 / 1,06 / 1,09
50	0,5	87,95	0,90 / 1,05 / 1,09 / 1,12
50	1,0	86,38	1,03 / 1,19 / 1,23 / 1,26
100	0,3	87,90	0,86 / 1,01 / 1,05 / 1,09
100	0,5	88,30	0,85 / 1,00 / 1,03 / 1,06
100	1,0	87,87	0,91 / 1,06 / 1,09 / 1,11
150	0,3	87,68	0,90 / 1,06 / 1,09 / 1,12
150	0,5	87,85	0,90 / 1,05 / 1,08 / 1,11
150	1,0	87,54	0,93 / 1,09 / 1,12 / 1,15
200	0,3	87,31	0,94 / 1,10 / 1,13 / 1,16
200	0,5	87,38	0,94 / 1,10 / 1,13 / 1,16
200	1,0	87,09	0,97 / 1,13 / 1,17 / 1,20

Зависимость качества от обоих параметров физически осмысленна. По радиусу корреляции наблюдается выраженный оптимум при $L = 100$ км: при меньшем радиусе поправка не успевает распространиться в промежутки между наблюдениями, при большем — избыточно сглаживается, теряя локальность. По отклонению ошибки наблюдений значения 0,3 и 0,5 близки, тогда как $\sigma_o = 1,0$ систематически хуже на всех радиусах: чрезмерное недоверие к наблюдениям ослабляет коррекцию. Наилучшая конфигурация — $L = 100$ км, $\sigma_o = 0,5$ — используется далее во всех расчётах на тестовой выборке.

Табл. 5.2. Усвоение наблюдений на тестовой выборке (1607 сроков, все сезоны, регион — 2501 узел). Ошибка приземной температуры RMSE, °C, по горизонтам и агрегатная успешность $\bar{S}$ относительно инерционного прогноза, вычисленная по (3). Оптимальная интерполяция при 10 % — среднее по трём независимым расстановкам условных станций.

Режим усвоения	+6 ч	+12 ч	+18 ч	+24 ч	$\bar{S}$, %
Без усвоения	1,32	1,53	1,59	1,66	73,41
Нуджинг, $\alpha = 0,5$	1,27	1,47	1,52	1,59	74,60
Нуджинг, $\alpha = 0,7$	1,26	1,46	1,51	1,57	74,86
Нуджинг, $\alpha = 0,9$	1,25	1,45	1,50	1,57	75,01
Оптимальная интерполяция, 1 % узлов	1,13	1,32	1,33	1,37	77,03
Оптимальная интерполяция, 10 % узлов	0,80	0,91	0,90	0,91	84,36

Из табл. 5.2 следуют три наблюдения. Во-первых, оптимальная интерполяция существенно превосходит релаксационное усвоение при одной и той же плотности наблюдений: 0,91 против 1,57 °C на суточном сроке. Причина в том, что нуджинг правит поле только в наблюдаемых узлах, тогда как оптимальная интерполяция распространяет поправку на окрестность согласно структуре ковариаций ошибок фона.

Во-вторых, среди испытанных значений коэффициента релаксации лучшим оказывается $\alpha = 0,9$, причём зависимость монотонна: чем сильнее коррекция к наблюдению, тем ниже ошибка. Это косвенно указывает на то, что в идеализированной постановке (наблюдения без приборной погрешности) оптимальным был бы предельный случай прямой подстановки; при реальных наблюдениях, содержащих шум, такой вывод не переносится.

В-третьих, разброс по трём расстановкам условных станций мал: агрегатная успешность составила 86,31, 86,46 и 86,66 %, то есть результат не зависит от конкретного размещения сети.

Усвоение на длинных горизонтах

Мотивировка усвоения опирается на деградацию прогноза при длительной развёртке, тогда как приведённые выше оценки ограничены сроком +24 ч. Для устранения этого несоответствия выполнена серия расчётов с развёрткой на 28 шагов (168 ч) в четырёх режимах: без усвоения; с оптимальной интерполяцией на каждом шаге при плотности 10 %; с усвоением только на первых четырёх шагах; с усвоением на каждом шаге при плотности 1 %. Оценка — на 200 сроках тестовой выборки, область — региональная вставка (табл. 3).

Табл. 3. Ошибка прогноза приземной температуры (°C) при развёртке до 336 ч (14 суток). Основная конфигурация, 200 сроков, регион (2501 узел).

Горизонт	Без усвоения	ОИ, 10 %	ОИ, 10 %, первые 4 шага	ОИ, 1 %
+24 ч	1,99	1,07	1,07	1,66
+48 ч	2,43	1,21	2,23	1,91
+72 ч	2,92	1,28	2,84	2,03
+96 ч	3,63	1,34	3,57	2,15
+120 ч	4,53	1,40	4,47	2,27
+168 ч	6,28	1,54	6,27	2,51
+240 ч	8,23	1,79	8,22	2,89
+336 ч	9,68	2,15	9,75	3,23
Успешность за все сроки, %	2,3	76,6	1,3	66,2

Из табл. 3 следуют три вывода.

Без усвоения ошибка растёт монотонно во всём диапазоне — от 1,99 °C на суточном сроке до 9,68 °C на четырнадцатисуточном, почти впятеро. Резкого обрыва не происходит, деградация постепенная, однако ошибка свыше 4 °C на сроках более пяти суток делает прогноз практически непригодным: суммарная успешность относительно инерционного прогноза за все 56 шагов составляет лишь 2,3 %.

Непрерывное усвоение принципиально меняет характер деградации. Ошибка возрастает лишь вдвое — с 1,07 до 2,15 °C, — а суммарная успешность держится на уровне 76,6 %. Показательно сопоставление: прогноз на четырнадцать суток с усвоением (2,15 °C) точнее, чем прогноз на двое суток без него (2,43 °C). Коррекция на каждом шаге снимает накопленную погрешность, и авторегрессия перестаёт быть источником неограниченного роста ошибки. Различие значимо на всех горизонтах: блочный бутстреп (блок 5 суток, 2000 реплик, парное сравнение на совпадающих сроках) даёт 95 %-й доверительный интервал выигрыша [0,84; 1,02] °C на +24 ч и [6,40; 8,47] °C на +336 ч.

Действие коррекции недолговечно. В режиме усвоения только на первых четырёх шагах ошибка совпадает с непрерывным до +24 ч, но уже через сутки преимущество почти утрачено (2,23 против 1,21 °C на +48 ч), а к четвёртым суткам кривая сливается с прогоном вообще без усвоения (3,57 против 3,63 °C); на дальних сроках совпадение полное. Суммарная успешность падает до 1,3 % — однократная коррекция начального состояния не даёт на масштабе двух недель ничего. Иными словами, «память» модели о коррекции составляет порядка суток, и улучшение качества требует регулярного поступления наблюдений, а не точной инициализации.

Снижение плотности наблюдений в десять раз (с 10 % до 1 % узлов, то есть примерно с 250 до 25 условных станций, что ближе к реальной сети) ослабляет эффект, но не устраняет: 1,66 против 1,99 °C на суточном сроке, 3,23 против 9,68 °C на четырнадцатисуточном, суммарная успешность 66,2 % против 2,3 %. Вывод устойчив к разрежённости сети.

Устойчивость и остаточная формулировка

Отдельного внимания заслуживает роль остаточной формулировки, то есть предсказания приращения поля вместо самого поля. В 19-канальной линии моделей (п. 4.2) конфигурация без неё до суточного срока практически не отличалась от основной, но на дальних сроках теряла устойчивость: ошибка достигала 15,6 °С на семисуточном сроке против 7,3 °С, а успешность обращалась в ноль около +126 ч и далее становилась отрицательной. Признаком раскочки служила немонотонность ошибки по горизонтам, отсутствующая у основной конфигурации.

Существенно, что усвоение этот дефект ослабляет, но не устраняет: при непрерывной коррекции переход успешности через ноль лишь отодвигается примерно на сутки. Остаточная формулировка и усвоение решают разные задачи и друг друга не заменяют.

Обсуждение, выводы и направления дальнейшей работы

Обсуждение

Лёгкая модель для региона. Прогноз над областью 50–60° с. ш., 83–98° в. д. получен на единой мультимасштабной сетке моделью объёмом 5,9 млн параметров, обучение и расчёт которой укладываются в одну видеокарту. Это на два-три порядка меньше, чем у известных региональных нейросетевых систем [3, 4], построенных на глобальных моделях с сотнями миллионов параметров [1]. Практическое следствие: воспроизведение схемы поси́льно региональному управлению по гидрометеорологии, располагающему одним вычислительным узлом. Стык глобальной и региональной частей выполнен жёсткой конкатенацией узлов; отдельная процедура согласования полей после прогноза, как в классическом граничном сшивании, не требуется, а прямая диагностика (п. 4.5) показывает переходный слой шириной около 100 км, не усиливающийся в авторегрессии.

Что определяет качество регионального дообучения. Три контролируемых эксперимента дают связную картину. Расписание заморозки процессора на итог не влияет: при равном бюджете обучения обе стратегии дают одинаковую ошибку приземной температуры. Сама адаптация процессора, напротив, необходима — при заморозке на всё обучение ошибка на проверочной выборке оказывается на 7,5 % выше, а обучение выходит на плато уже к восьмой эпохе, причём растёт и ошибка на обучающей выборке, то есть модели не хватает свободы подстроить динамику, а не данных. Наконец, отбор состояния по минимуму одношаговой ошибки ненадёжен: выигрывая на горизонте +6 ч, такое состояние проигрывает на +18 и +24 ч. Отсюда практическое правило: сравнивать стратегии при равном бюджете, а состояние отбирать по метрике на целевом горизонте при полной развёртке.

Агрегатный показатель скрывает поведение по полям. Конфигурации, различающиеся по сводной успешности на восемь процентных пунктов, могут совпадать по приземной температуре — полю, наиболее востребованному потребителем прогноза. Причина в том, что сводный показатель усредняет нормированные ошибки по всем каналам, и вклад каждого определяется отношением его ошибки к разбросу поля, а не значимостью для практики. Верификацию необходимо отчитывать покомпонентно и по горизонтам, а не единственным числом.

Совместимость классического усвоения с нейросетевым прогнозом. Обученная сеть используется как детерминированный оператор прогноза, а коррекция наблюдениями выполняется в пространстве состояний между авторегрессионными шагами: переобучения не требуется, стоимость шага усвоения пренебрежима. Тем самым релаксационное усвоение и оптимальная интерполяция [8] переносятся на нейросетевую модель без изменения формулировки. Существенно, что необходимо именно непрерывное поступление наблюдений: коррекция, прекращённая после первых шагов развёртки, теряет действие в течение примерно суток, а к четвёртым суткам прогноз становится неотличим от расчёта вообще без усвоения.

Ограничения

Все модели обучены при одном начальном значении генератора случайных чисел: изменчивость по выборке оценивается доверительными интервалами, межзапусковая — нет, поэтому различия порядка процентного пункта по сводному показателю содержательно не интерпретируются. Эксперименты по усвоению поставлены по схеме «идентичный двойник»: в роли наблюдений выступают значения реанализа [7] в случайно выбранных узлах, ошибка измерения и ошибка репрезентативности [9] не моделируются, реальная сеть станций разрежена неоднородно, — поэтому полученный вклад усвоения следует считать верхней оценкой. Гиперпараметры усвоения подбирались на той же территории, где оценивается качество; разделение выборок по времени соблюдено, но перенос значений радиуса корреляции и дисперсии ошибок наблюдений на другую территорию не проверялся.

Истиной служит реанализ, а не стационарные наблюдения; реанализ сглаживает подсеточные эффекты, включая городской остров тепла, поэтому оценки не переносятся напрямую на прогноз в точке станции без постобработки. Эталоном служат инерционный прогноз и прогноз глобальной модели, интерполированный в узлы вставки; сопоставление с оперативной численной моделью атмосферы не проводилось, и при таком сравнении необходимо будет учесть, что модель, обученная на реанализе, оценивается против реанализа и находится в благоприятном положении [6]. Наконец, результаты получены для одной территории и одного тестового окна, тем более что прямое сравнение мультимасштабного подхода с региональной моделью с граничным форсингом показывает конкурентоспособность обоих подходов [4].

Направления дальнейшей работы

Уплотнение мультимасштабного графа за счёт слияния всех уровней икосаэдрической мозаики, а не двух, — приём, дающий дальние связи без роста числа параметров; расширение состава прогностических полей и переход к прогнозу с оценкой неопределённости через ансамбль возмущённых начальных состояний либо порождающие вероятностные модели [5]; верификация по данным сети станций как условие принятия схемы оперативной практикой; наконец, включение циклического усвоения поступающих наблюдений в автоматический цикл выпуска прогноза.

Отдельно отметим направление, естественное именно для нейросетевой постановки. Обученная сеть дифференцируема по входу, поэтому сопряжённая модель, построение которой составляет основную трудность вариационного усвоения в традиционных численных моделях, здесь не нужна: градиент вычисляется обратным распространением через авторегрессионную развёртку. Это открывает путь к четырёхмерному вариационному усвоению, согласующему начальное состояние сразу по нескольким срокам наблюдений вместо пошаговой коррекции поля [10, 11].

Выводы

1. Построена и проверена мультимасштабная графовая нейронная сеть регионального прогноза погоды на едином графе, где глобальная и региональная части соединены без отдельной процедуры сшивания полей; прямая диагностика стыка показывает переходный слой шириной около 100 км, затухающий с ростом горизонта.
2. Модель лёгкая: обучение и расчёт прогноза выполняются на одной видеокarte, что делает воспроизведение схемы посильным для регионального гидрометеорологического подразделения.
3. Единый граф превосходит интерполяцию прогноза глобальной модели в узлы области по всем полям: выигрыш составляет от 11 % по приземной температуре до 37–40 % по ветру и геопотенциалу.

1. Установлено, что отбор обученного состояния по ошибке одношагового прогноза ненадёжен для многошагового; расписание заморозки процессора на итог не влияет, тогда как сама адаптация процессора необходима и даёт около 7,5 % по ошибке на проверочной выборке.
2. Показано, что единственный агрегатный показатель скрывает различное поведение модели по отдельным полям; верификацию необходимо отчитывать покомпонентно.
3. Продемонстрирована совместимость классических последовательных схем усвоения с обученной нейросетевой моделью: при непрерывной коррекции ошибка за четырнадцать суток возрастает лишь вдвое, тогда как без усвоения — впятеро; действие однократной коррекции сохраняется порядка суток.
4. Основные ограничения — единственный прогон обучения, синтетический характер усваиваемых наблюдений, оценка качества против реанализа и отсутствие сравнения с оперативной моделью — определяют содержание ближайших этапов исследования.

Список литературы

1. Гандин Л. С. Объективный анализ метеорологических полей. Л.: Гидрометеиздат, 1963. 286 с.
2. Толстых М. А., Фадеев Р. Ю., Шашкин В. В. и др. Система моделирования атмосферы для бесшовного прогноза. М.: Триада ЛТД, 2017. 166 с. [заполнить: сверить по бумажному экземпляру или РИНЦ](#)
3. Lam R., Sanchez-Gonzalez A., Willson M. et al. Learning skillful medium-range global weather forecasting // *Science*. 2023. Vol. 382, No. 6677. P. 1416–1421.
4. Bi K., Xie L., Zhang H. et al. Accurate medium-range global weather forecasting with 3D neural networks // *Nature*. 2023. Vol. 619. P. 533–538.
5. Pathak J., Subramanian S., Harrington P. et al. FourCastNet: A global data-driven high-resolution weather model using adaptive Fourier neural operators // *arXiv:2202.11214*. 2022.
6. Davies H. C. A lateral boundary formulation for multi-level prediction models // *Quarterly Journal of the Royal Meteorological Society*. 1976. Vol. 102, No. 432. P. 405–418.
7. Oskarsson J., Landelius T., Lindsten F. Graph-based neural weather prediction for limited area modeling // *arXiv:2309.17370*. 2023.
8. Nipen T. N., Haugen H. H., Ingstad M. S. et al. Regional data-driven weather modeling with a global stretched-grid // *Artificial Intelligence for the Earth Systems*. 2026. Vol. 5, No. 2. DOI: 10.1175/AIES-D-25-0001.1.
9. Gao Y., Wu H., Shu K. et al. OneForecast: A universal framework for global and regional weather forecasting // *Proceedings of the 42nd International Conference on Machine Learning (ICML)*. 2025. *arXiv:2502.00338*.
10. Wijnands J. S., Van Genderachter M., François B. et al. Data-driven regional weather forecasting: A comparison of stretched-grid and limited-area modelling // *Machine Learning with Applications*. 2026. Article 100526. DOI: 10.1016/j.mlwa.2026.100526.
11. Hersbach H., Bell B., Berrisford P. et al. The ERA5 global reanalysis // *Quarterly Journal of the Royal Meteorological Society*. 2020. Vol. 146, No. 730. P. 1999–2049.
12. Battaglia P. W., Hamrick J. B., Bapst V. et al. Relational inductive biases, deep learning, and graph networks // *arXiv:1806.01261*, 2018.
13. Rasp S., Hoyer S., Merose A. et al. WeatherBench 2: A benchmark for the next generation of data-driven global weather models // *Journal of Advances in Modeling Earth Systems*. 2024. Vol. 16, No. 6. Article e2023MS004019.
14. Wilks D. S. *Statistical Methods in the Atmospheric Sciences*. 4th ed. Amsterdam: Elsevier, 2019. 840 p.
15. Battaglia P. W., Pascanu R., Lai M. et al. Interaction networks for learning about objects, relations

- and physics // *Advances in Neural Information Processing Systems*. 2016. Vol. 29. P. 4502–4510.
5. Ben Bouallègue Z., Clare M. C. A., Magnusson L. et al. The rise of data-driven weather forecasting: A first statistical assessment of machine learning-based weather forecasts in an operational-like context // *Bulletin of the American Meteorological Society*. 2024. Vol. 105, No. 6. P. E864–E883.
 6. Kalnay E. *Atmospheric Modeling, Data Assimilation and Predictability*. Cambridge: Cambridge University Press, 2003. 341 p.
 7. Price I., Sanchez-Gonzalez A., Alet F. et al. Probabilistic weather forecasting with machine learning // *Nature*. 2025. Vol. 637. P. 84–90.
 8. Janjić T., Bormann N., Bocquet M. et al. On the representation error in data assimilation // *Quarterly Journal of the Royal Meteorological Society*. 2018. Vol. 144. No. 713. P. 1257–1278.
 9. Geer A. J. Learning earth system models from observations: machine learning or data assimilation? // *Philosophical Transactions of the Royal Society A*. 2021. Vol. 379. No. 2194. Article 20200089.
 10. Bocquet M., Brajard J., Carrassi A., Bertino L. Bayesian inference of chaotic dynamics by merging data assimilation, machine learning and expectation-maximization // *Foundations of Data Science*. 2020. Vol. 2. No. 1. P. 55–80.
 11. Smith A., Lott N., Vose R. The Integrated Surface Database: Recent developments and partnerships // *Bulletin of the American Meteorological Society*. 2011. Vol. 92. No. 6. P. 704–708.

References

1. Gandin L.S. *Ob"ektivnyi analiz meteorologicheskikh polei [Objective Analysis of Meteorological Fields]*. Leningrad, Gidrometeoizdat Publ., 1963, 286 p. [in Russ.]
2. Tolstykh M.A., Fadeev R.Yu., Shashkin V.V. et al. *Sistema modelirovaniya atmosfery dlya besshovnogo prognoza [Atmosphere Modelling System for Seamless Prediction]*. Moscow, Triada Ltd. Publ., 2017, 166 p. [in Russ.]
3. Lam R., Sanchez-Gonzalez A., Willson M. et al. Learning skillful medium-range global weather forecasting. *Science*, 2023, vol. 382, no. 6677, pp. 1416–1421.
4. Bi K., Xie L., Zhang H. et al. Accurate medium-range global weather forecasting with 3D neural networks. *Nature*, 2023, vol. 619, pp. 533–538.
5. Pathak J., Subramanian S., Harrington P. et al. FourCastNet: A global data-driven high-resolution weather model using adaptive Fourier neural operators. *arXiv:2202.11214*, 2022.
6. Davies H.C. A lateral boundary formulation for multi-level prediction models. *Quarterly Journal of the Royal Meteorological Society*, 1976, vol. 102, no. 432, pp. 405–418.
7. Oskarsson J., Landelius T., Lindsten F. Graph-based neural weather prediction for limited area modeling. *arXiv:2309.17370*, 2023.
8. Nipen T.N., Haugen H.H., Ingstad M.S. et al. Regional data-driven weather modeling with a global stretched-grid. *Artificial Intelligence for the Earth Systems*, 2026, vol. 5, no. 2, DOI: 10.1175/AIES-D-25-0001.1.
9. Gao Y., Wu H., Shu K. et al. OneForecast: A universal framework for global and regional weather forecasting. *Proceedings of the 42nd International Conference on Machine Learning (ICML)*, 2025, *arXiv:2502.00338*.
10. Wijnands J.S., Van Genderachter M., François B. et al. Data-driven regional weather forecasting: A comparison of stretched-grid and limited-area modelling. *Machine Learning with Applications*, 2026, article 100526, DOI: 10.1016/j.mlwa.2026.100526.
11. Hersbach H., Bell B., Berrisford P. et al. The ERA5 global reanalysis. *Quarterly Journal of the Royal Meteorological Society*, 2020, vol. 146, no. 730, pp. 1999–2049.
12. Battaglia P.W., Hamrick J.B., Bapst V. et al. Relational inductive biases, deep learning, and graph networks. *arXiv:1806.01261*, 2018.
13. Rasp S., Hoyer S., Merose A. et al. WeatherBench 2: A benchmark for the next generation of data-

driven global weather models. *Journal of Advances in Modeling Earth Systems*, 2024, vol. 16, no. 6, article e2023MS004019.

1. Wilks D.S. *Statistical Methods in the Atmospheric Sciences*. 4th ed. Amsterdam, Elsevier, 2019, 840 p.
2. Battaglia P.W., Pascanu R., Lai M. et al. Interaction networks for learning about objects, relations and physics. *Advances in Neural Information Processing Systems*, 2016, vol. 29, pp. 4502–4510.
3. Ben Bouallègue Z., Clare M.C.A., Magnusson L. et al. The rise of data-driven weather forecasting: A first statistical assessment of machine learning-based weather forecasts in an operational-like context. *Bulletin of the American Meteorological Society*, 2024, vol. 105, no. 6, pp. E864–E883.
4. Kalnay E. *Atmospheric Modeling, Data Assimilation and Predictability*. Cambridge, Cambridge University Press, 2003, 341 p.
5. Price I., Sanchez-Gonzalez A., Alet F. et al. Probabilistic weather forecasting with machine learning. *Nature*, 2025, vol. 637, pp. 84–90.
6. Janjić T., Bormann N., Bocquet M. et al. On the representation error in data assimilation. *Quarterly Journal of the Royal Meteorological Society*, 2018, vol. 144, no. 713, pp. 1257–1278.
7. Geer A.J. Learning earth system models from observations: machine learning or data assimilation? *Philosophical Transactions of the Royal Society A*, 2021, vol. 379, no. 2194, article 20200089.
8. Bocquet M., Brajard J., Carrassi A., Bertino L. Bayesian inference of chaotic dynamics by merging data assimilation, machine learning and expectation-maximization. *Foundations of Data Science*, 2020, vol. 2, no. 1, pp. 55–80.
9. Smith A., Lott N., Vose R. The Integrated Surface Database: Recent developments and partnerships. *Bulletin of the American Meteorological Society*, 2011, vol. 92, no. 6, pp. 704–708.