

Мультимасштабная графовая нейросетевая модель регионального прогноза погоды

А.С. Табаков^{1,2}, А.В. Пененко¹, А.Б. Колкер^{3,4}

¹Институт вычислительной математики и математической геофизики СО РАН, г. Новосибирск, Россия; ²Новосибирский государственный университет, г. Новосибирск, Россия; ³Сибирский региональный научно-исследовательский гидрометеорологический институт, г. Новосибирск, Россия; ⁴Новосибирский государственный технический университет, г. Новосибирск, Россия

artur.tabakov11@gmail.com

Статья описывает графовую нейросетевую модель регионального прогноза погоды над югом Красноярского края. Глобальная сетка с шагом $0,703^\circ$ и региональная вставка с шагом $0,25^\circ$ образуют одну расчётную сетку из 133 279 узлов. Внешние граничные условия модели не нужны: поля на стыке двух разрешений согласуют обмен сообщениями по графу, и этому модель учится вместе со всем остальным. У модели 6,0 млн обучаемых параметров, для обучения и прогноза хватает одного графического ускорителя. На независимой выборке из 1607 сроков, которая охватывает все сезоны, среднеквадратическая ошибка прогноза приземной температуры на сутки равна $1,47^\circ\text{C}$. Агрегатная успешность относительно инерционного прогноза составляет 74,4 %, аномальная корреляция относительно климатологии равна 0,973. На общих узлах и сроках ошибка по приземной температуре в 1,33 раза больше, чем у глобальной модели GraphCast, у которой в шесть раз больше параметров. При равномерном усреднении функции потерь целевые узлы и приземные каналы получают малую долю обучающего сигнала. Явные веса по узлам и каналам снижают ошибку приземной температуры на 10,2 % в среднем по горизонтам и на 12,0 % на суточном сроке, а архитектура и объём обучения остаются прежними. Опыт с равным бюджетом обучения показал, что ошибка одношагового прогноза на проверочной выборке плохо подходит для отбора модели, которая строит многошаговый прогноз.

Ключевые слова: численный прогноз погоды, графовая нейронная сеть, региональный прогноз, мультимасштабная сетка, авторегрессионный прогноз, функция потерь, машинное обучение

A multiscale graph neural network for regional weather forecasting

A.S. Tabakov^{1,2}, A.V. Penenko¹, A.B. Kolker^{3,4}

¹Institute of Computational Mathematics and Mathematical Geophysics SB RAS, Novosibirsk, Russia; ²Novosibirsk State University, Novosibirsk, Russia; ³Siberian Regional

Research Hydrometeorological Institute, Novosibirsk, Russia; ⁴Novosibirsk State Technical University, Novosibirsk, Russia

artur.tabakov11@gmail.com

A regional neural network weather forecasting model for the south of Krasnoyarsk Krai is presented, built on a graph representation of the atmospheric state. A global mesh of 0.703° and a regional insert of 0.25° form a single graph of 133,279 nodes, removing the need for external lateral boundary conditions: the resolutions are reconciled at the interface by message passing during training. The model has 6.0 million trainable parameters and runs on a single GPU. On 1607 independent initial times covering all seasons the 2-m temperature error is 1.47°C at the 24-h lead time, the aggregate skill score 74.4 % against persistence and the anomaly correlation 0.973 against climatology. On shared nodes and initial times it trails the global GraphCast by a factor of 1.33 with six times fewer parameters. The distribution of the training signal over nodes and channels arising from uniform averaging of the loss is far from the task: explicit weighting cuts the 2-m temperature error by 10.2 % at an equal budget and unchanged architecture. At an equal training budget the single-step validation error proves an unreliable criterion for selecting a model for multi-step forecasting.

Keywords: numerical weather prediction, graph neural network, regional forecasting, multiscale mesh, autoregressive forecast, loss function, machine learning

Введение

Численный прогноз погоды интегрирует уравнения гидротермодинамики атмосферы на сетке высокого разрешения. В России такой прогноз оперативно выпускают по полулагранжевой модели ПЛАВ [1]. Подход точен, но один глобальный прогноз на средние сроки занимает часы работы суперкомпьютера. Это ограничивает частоту обновления прогноза и размер ансамбля.

В 2022–2023 годах нейросетевые модели, обученные на архиве реанализа, догнали по точности оперативные системы ведущих метеоцентров, а вычислений на выпуск прогноза им нужно во много раз меньше. Модель GraphCast [8] работает на графовом представлении атмосферы. На сроках от трёх до десяти суток она превзошла оперативную систему Европейского центра по большинству переменных. Сопоставимые результаты получили модели Pangu-Weather [3] и FourCastNet [11]. В основе GraphCast лежит граф, узлы которого почти равномерно покрывают сферу (п. 3.1).

Большинство таких систем решает глобальную задачу, а на практике часто нужен более детальный прогноз над ограниченной территорией. Главная трудность такого перехода связана с граничными условиями: у краевых узлов вырезанной области нет корректного окружения. В классическом прогнозе поле в буферной зоне релаксируют к внешнему полю [4]. Для этого нужна отдельная процедура, и она вносит свои погрешности.

Для нейросетевых региональных моделей предложено несколько способов обойти проблему границ. Архитектура Neural-LAM [10] получает граничный форсинг от глобальной модели. В [9] разрешение плавно меняется на растянутой сетке. В [5] вложенные сетки обмениваются информацией между уровнями. Подходы с растянутой сеткой и с ограниченной областью сравнивали в [13].

Наша работа посвящена региональной модели прогноза над югом Красноярского края. Её вклад состоит в следующем.

1. Мы построили единую мультимасштабную сетку. Глобальная сетка с шагом $0,703^\circ$ и региональная вставка с шагом $0,25^\circ$ соединены в один граф без внешних границ. Разрешения согласует обмен сообщениями, отдельная процедура сшивания не нужна. Сама идея мультимасштабного представления известна [5, 9]. Наш вариант отличается способом построения: узлы глобальной решётки внутри области заменены узлами вставки, и связность для всех узлов строится одинаково. Такая конструкция точнее интерполяции прогноза глобальной модели в те же узлы.
2. Модель намеренно сделана лёгкой: у неё 6,0 млн параметров, у моделей [3, 8, 9] от десятков до сотен миллионов. Для обучения и выпуска прогноза хватает одного графического ускорителя, и схему можно воспроизвести в вычислительной среде регионального управления гидрометслужбы.
3. Мы исследовали стратегию дообучения глобальной модели под региональную сетку. Отдельный методический результат касается отбора модели. Ошибка одношагового прогноза на проверочной выборке ненадёжна как критерий отбора, если модель должна строить многошаговый прогноз.
4. При равномерном усреднении функции потерь обучающий сигнал распределяется не так, как требует задача: узлы целевой области получают 1,7 % сигнала, приземная температура 0,46 %. Явные веса по узлам и каналам снижают ошибку приземной температуры на 10,2 %, архитектура и объём обучения остаются прежними.

Данные, базовая модель и метрики качества

Исходные данные

Модель обучали и оценивали на реанализе ERA5 Европейского центра среднесрочных прогнозов погоды [6] за 2010–2020 гг. с шагом 6 ч. Это 16 072 последовательных срока.

Состояние атмосферы описывают 19 полей. Семь из них приземные: температура воздуха на высоте 2 м, зональная и меридиональная составляющие ветра на высоте 10 м, давление на уровне моря, приземное давление, суммарные осадки за 6 ч и общее содержание водяного пара в столбе атмосферы. Два поля статические: геопотенциал поверхности и маска

суши и моря. Модель получает их на вход, но не прогнозирует, и в оценках они не участвуют. На уровнях 850 и 500 гПа заданы по пять полей: температура, две составляющие ветра, геопотенциал и удельная влажность. Вертикальную структуру описывает набор признаков узла, отдельных узлов по высоте нет.

Поля хранятся в физических единицах. Геопотенциал ERA5 один раз поделили на $g = 9,80665 \text{ м/с}^2$. Перед подачей в сеть каждый канал стандартизуется. Среднее и стандартное отклонение считали по всему периоду 2010–2020 гг., включая проверочную и тестовую части. Эти два числа на канал влияют на результат пренебрежимо мало, но мы сообщаем об этом явно.

На вход модель получает два последовательных срока (12 ч). Прогноз строится авторегрессионно с шагом 6 ч, оценки приводятся для горизонтов +6, +12, +18 и +24 ч.

Целевая область (регион) ограничена координатами 50–60° с. ш., 83–98° в. д. Её покрывает решётка с шагом 0,25° размером $61 \times 41 = 2501$ узел. Внутри региона выделена зона 55,5–56,5° с. ш., 92–94° в. д. (45 узлов) с Красноярском и окрестностями. Метрики считаются относительно полей ERA5 с шагом 0,25° в этих узлах, без интерполяции с более грубой сетки.

Основная модель использует 33-канальную конфигурацию. К 19 полям в ней добавлены по пять полей на уровнях 250 и 1000 гПа (температура, обе составляющие ветра, геопотенциал, удельная влажность) и четыре канала временного форсинга: синусы и косинусы часа суток и дня года. При развёртке форсинг и статические поля заменяются известными значениями и в число прогностических каналов не входят.

Хронологическое разбиение выборки

Выборку разбили строго по времени, без перемешивания сроков. Обучающая выборка целиком предшествует проверочной, а проверочная предшествует тестовой, так что будущие состояния в обучение не попадают. Пример занимает окно из 2 входных срезов и 4 прогностических шагов, и из 16 072 сроков получается 16 067 примеров. Их разделили в отношении 80/10/10: 12 853 для обучения, 1607 в проверочную выборку и 1607 в тестовую. По проверочной выборке подбирали гиперпараметры и отбирали состояние модели. Все публикуемые числа получены на тестовой выборке. Она охватывает конец 2019 г. и весь 2020 г., то есть полный годовой цикл и все четыре сезона. Сроки начала прогноза в обучающей выборке идут с 01.01.2010 06 UTC по 19.10.2018 06 UTC, в проверочной с 19.10.2018 12 UTC по 25.11.2019 00 UTC, в тестовой с 25.11.2019 06 UTC по 30.12.2020 18 UTC.

Базовая глобальная модель

Региональное дообучение начинается с глобальной модели. Её обучили на тех же 19 полях на широтно-долготной сетке 512×256 узлов с шагом около 0,703°. Модель устроена по схеме «кодировщик–процессор–декодировщик» на графе. Кодировщик переносит признаки узлов

расчётной сетки на вершины икосаэдрической мозаики (уровни детализации 4 и 6). Процессор выполняет 12 раундов обмена сообщениями блоком Interaction Network [2]. Декодировщик возвращает результат в узлы сетки. У модели 6,0 млн обучаемых параметров, в шесть раз меньше, чем у GraphCast [8], и для обучения и оперативного выпуска прогноза хватает одного графического ускорителя.

Функция потерь равна среднеквадратической ошибке в стандартизованных переменных, осреднённой по узлам, каналам и горизонтам. Длина авторегрессионной развёртки при обучении растёт поэтапно. При подготовке работы мы нашли особенность реализации. При глобальном предобучении широтные веса узлов были почти равномерными, а при региональном дообучении (п. 3.4) применялись веса $\cos\phi$, где ϕ обозначает широту узла. Региональное дообучение стартовало с промежуточного состояния глобальной модели, лучшего по проверочной выборке (эпоха 30 из 36 пройденных). На собственной сетке базовая модель даёт агрегатную успешность 65,4 % и ошибку приземной температуры 1,07 °C в среднем по горизонтам +6...+24 ч (200 сроков). С региональными числами работы эти значения сравнивать нельзя. Их считали по всему шару на грубой сетке 0,703°, где истинное поле сглажено, и на другой подвыборке сроков.

Метрики качества

Для канала c и горизонта τ среднеквадратическая ошибка считается в физических единицах канала:

$$\text{RMSE}_c(\tau) = \left[\frac{1}{N|G|} \sum_{n=1}^N \sum_{g \in G} (\hat{x}_{c,g}^{(n)}(\tau) - x_{c,g}^{(n)}(\tau))^2 \right]^{1/2}, \quad (1)$$

где N — число сроков ($N = 1607$ для тестовой выборки); G — множество оцениваемых узлов (2501 для региона, 45 для внутренней зоны); $\hat{x}$ — прогноз, x — значение реанализа, которое принимается за истинное. Ошибка приводится в единицах переменной: °C, м/с, гПа, гпм. Узлы входят в сумму с весами $\cos\phi$, нормированными на единичное среднее, как принято в протоколе верификации нейросетевых моделей прогноза [12]. Ячейка широтно-долготной сетки на 60° с. ш. вдвое уже экваториальной, и при равных весах высокие широты получили бы завышенный вклад. Для полосы 50–60° с. ш. отношение крайних весов равно 1,29.

Прогноз сравнивается с двумя эталонами. Инерционный эталон переносит поля последнего входного среза t_0 на все горизонты без изменений, климатический описан ниже. Успешность относительно эталона вычисляется так:

$$S_c(\tau) = \left(1 - \frac{\text{RMSE}_c(\tau)}{\text{RMSE}^{\text{эт}}_c(\tau)} \right) \cdot 100 \%, \quad (2)$$

где $\text{RMSE}^{\text{эт}}$ — ошибка (1) для эталона на том же окне и той же маске узлов.

Инерционный эталон подходит не для всех полей. По приземной температуре его ошибка равна 4,99 / 6,88 / 5,88 / 4,42 °С на горизонтах +6...+24 ч. На суточном сроке он точнее, чем на шестичасовом, потому что поле возвращается к тому же часу местного времени. Успешность относительно него меняется немонотонно (76,4 / 80,2 / 76,2 / 67,0 %) и говорит об эталоне не меньше, чем о модели.

У климатического эталона такого недостатка нет. Его построили по обучающей части выборки разложением по гармоникам (три годовые и суточный ход), тестовые сроки в подгонку не входили. Его ошибка почти не зависит от горизонта: 6,25 °С по приземной температуре на всех сроках, 5,42 °С по температуре на 850 гПа, 9,19 гПа по давлению на уровне моря, 2,05 и 1,74 м/с по составляющим ветра. На суточном сроке успешность основной модели относительно климатологии равна 76,6 % по приземной температуре, 82,7 % по T850, 88,8 % по давлению, 65,9 и 60,9 % по ветру. Постоянная ошибка эталона показывает, до какого срока прогноз полезен. Ошибка модели по приземной температуре равна 4,33 °С на +120 ч и 6,19 °С на +168 ч, то есть сравнивается с климатологией после седьмых суток.

Для сводной оценки служит агрегатный показатель. Каналы имеют разные единицы, и агрегат считается в стандартизованных переменных:

$$\overline{\text{RMSE}} = \left[\frac{1}{N |G| C H} \sum_n \sum_{g \in G} \sum_{c=1}^C \sum_{\tau} \left(\frac{x_{c,g}^{(n)}(\tau) - x_{c,g}^{(n)}(\tau)}{\sigma_c} \right)^2 \right]^{1/2}, \quad \bar{S} = \left(1 - \frac{\overline{\text{RMSE}}}{\overline{\text{RMSE}}^{\text{ЭТ}}} \right) \cdot 100 \%, \quad (3)$$

где σ_c — стандартное отклонение канала при стандартизации; C — число прогностических каналов (17 для 19-канальной конфигурации, 27 для 33-канальной: исключены два статических поля и четыре канала форсинга); $H = 4$. В табл. 1 столбец $\bar{S}$ осредняет разные наборы каналов, и строки с 19 и 33 каналами по нему сравнивать нельзя. Сравнимы поканальные значения и строки внутри одного набора.

Кроме ошибки, мы приводим аномальную корреляцию. Она показывает, насколько прогноз воспроизводит отклонение от обычного состояния:

$$\text{ACC}_c(\tau) = \frac{\sum w_g (x_{c,g} - \bar{x}_{c,g})(x_{c,g} - \bar{x}_{c,g})}{\left[\sum w_g (x_{c,g} - \bar{x}_{c,g})^2 \sum w_g (x_{c,g} - \bar{x}_{c,g})^2 \right]^{1/2}}, \quad (4)$$

где $\bar{x}$ — климатология ERA5 за 1990–2019 гг. из архива WeatherBench 2 [12], w_g — тот же широтный вес. Суммирование идёт сразу по узлам и срокам, то есть ACC равна отношению сумм, а не среднему посрочных корреляций. Из прогноза и истины вычитается климатология, а не среднее поля, чтобы убрать из обоих общий сезонный ход.

Точность оценок характеризуют доверительные интервалы блочного бутстрепа. Сроки идут через 6 ч и коррелированы внутри одного синоптического процесса, и при ресэмплинге

берутся блоки подряд идущих сроков [7]. Интервалы строятся из посрочных вкладов в ошибку, и конфигурации сравниваются парно на общих сроках. Интервал учитывает изменчивость по срокам верификации, но не по повторным обучением. Изменчивость по обучением оценена в п. 5.1.

Мультимасштабная графовая модель и стратегия дообучения

Ограничения регулярной сетки на сфере

Значение переменной в узле через шесть часов определяется состоянием его окрестности. Чтобы модель могла выучить эту зависимость, окрестность узла должна везде иметь примерно один физический размер. На регулярной сетке в координатах широта–долгота это условие не выполняется. При шаге $0,703^\circ$ расстояние между соседними узлами вдоль параллели убывает пропорционально косинусу широты: около 78 км на экваторе, 50 км на 50° с. ш. и 14 км на 80° с. ш. Вблизи полюсов сетка вырождается. Модели приходится либо усреднять эту неоднородность, либо тратить ёмкость на её запоминание.

Узлы почти равномерно распределяет по сфере икосаэдрическая триангуляция. Икосаэдр из 20 равных граней рекурсивно измельчают: каждый треугольник делят на четыре, а новые вершины проецируют на сферу. На любом уровне измельчения у каждой вершины пять или шесть соседей, и длины рёбер различаются мало. Благодаря этому окрестность узла везде отвечает близкому физическому масштабу.

Архитектура

Модель построена по схеме «кодировщик–процессор–декодировщик» [2, 8]. Узлы обмениваются информацией на графе, а входные и выходные поля остаются на регулярной сетке.

Кодировщик переносит значения из узлов сетки в вершины графа. Каждая вершина собирает сообщение от узлов, которые попали в её окрестность (радиус связи 0,6 в единицах длины ребра графа). Многослойный персептрон переводит это сообщение в скрытое представление размерности 256.

Процессор выполняет $R = 12$ раундов обмена сообщениями по рёбрам графа. Каждый раунд реализован блоком Interaction Network [2] и состоит из двух шагов. Сначала для каждого ребра ($i \rightarrow j$) вычисляется сообщение

$$m_{ij}^{(r)} = \varphi_e(h_i^{(r-1)}, h_j^{(r-1)}, e_{ij}), \quad (5)$$

затем состояние вершины обновляется по среднему входящих сообщений:

$$h_j^{(r)} = \varphi_v(h_j^{(r-1)}, \frac{1}{|N(j)|} \sum_{i \in N(j)} m_{ij}^{(r)}), \quad (6)$$

где $h_j^{(r)}$ — скрытое представление вершины j после раунда r (размерность 256); e_{ij} — постоянные признаки ребра (длина и три компоненты единичного вектора направления в геоцентрических координатах); $N(j)$ — вершины, соединённые с j ; ϕ_e и ϕ_v — персептроны с активацией Swish и послойной нормировкой. Веса раундов не разделяются, как и в [8].

Декодировщик переносит скрытые представления вершин обратно в узлы регулярной сетки и выдаёт приращения полей.

Прогноз строится авторегрессионно с шагом 6 ч. Выход модели снова подаётся на её вход и даёт следующий срок:

$$\hat{x}(t_0 + 6(k+1)) = F(\hat{x}(t_0 + 6k), \hat{x}(t_0 + 6(k-1))), \quad k = 0, 1, \dots, K-1, \quad (7)$$

где F — обученное отображение; при $k = 0$ на вход идут два среза анализа. Конфигурации на 19 и 33 канала различаются только входным слоем кодировщика и выходным слоем декодировщика. Разница составляет около 9 тыс. параметров (0,15 %), и после округления число параметров у них одинаково.

Мультимасштабная расчётная сетка

Классическая региональная модель вырезает область из глобальной сетки и задаёт на её краю внешние граничные условия. У граничных узлов нет корректного окружения, у края накапливаются искажения, и для их подавления нужна отдельная процедура сшивания с внешним полем [4].

Мы используем другой приём: глобальная и региональная сетки объединены в один граф, и внешней границы у модели нет. Из глобальной сетки 512×256 (шаг $0,703^\circ$) удалены узлы внутри области интереса. На их место поставлена регулярная решётка с шагом $0,25^\circ$ ($61 \times 41 = 2501$ узел) в границах $50\text{--}60^\circ$ с. ш., $83\text{--}98^\circ$ в. д. Итоговая расчётная сетка содержит 130 778 глобальных узлов и 2501 узел вставки, всего 133 279.

Рёбра между узлами и вершинами графа строятся поиском ближайших соседей по геоцентрическим координатам. Для узлов обоих разрешений процедура одна и та же, и переходную зону при построении связности никак не выделяют.

Соединение жёсткое: множества узлов не пересекаются, и значения собираются в один вектор состояния без весовой функции и сглаживания на стыке. Разрешения согласуются в ходе обмена сообщениями. Узлы по обе стороны стыка связаны рёбрами и обмениваются признаками на каждом из 12 раундов, так что переходный слой модель формирует сама при обучении.

В методе Дэвиса [4] внутреннее решение в ходе интегрирования релаксируется к заданному извне полю, то есть внешняя граница и внешнее поле остаются необходимыми. В нашей схеме их нет. Прямая проверка бесшовности приведена на рис. 1: смена разрешения видна по размеру ячеек, а разрыва поля на склейке нет. Количественная диагностика по горизонтам дана в п. 4.6.

У подхода есть ограничение. Вставка задана прямоугольником в координатах широта–долгота и сохраняет ту же неоднородность шага по долготе, что обсуждалась в п. 3.1. Для полосы в 10° по широте отношение $\cos 50^\circ / \cos 60^\circ \approx 1,29$ невелико, но для области с большей протяжённостью по широте его придётся учитывать.

Стратегия дообучения

Региональную модель получают дообучением глобальной, которую обучили на той же выборке ERA5 в конфигурации 512×256 . После смены геометрии сетки веса кодировщика и декодировщика не согласованы с новой связностью, а процессор хранит динамику, выученную на глобальной задаче. Если сразу дообучать все параметры, большие градиенты от неадаптированных кодировщика и декодировщика могут разрушить эту динамику. Такой эффект называют катастрофическим забыванием.

Чтобы его избежать, дообучение идёт в две фазы.

1. Фаза 1 (первые E_f эпох): параметры процессора заморожены, обучаются только кодировщик и декодировщик. Они подстраиваются под новую геометрию и статистику региона.
2. Фаза 2 (оставшиеся эпохи): процессор размораживается и учится с темпом в 10 раз меньше базового.

В основной конфигурации $E_f = 10$, в конфигурациях для проверки самой стратегии (п. 4.5) $E_f = 6$. Базовый темп обучения равен 10^{-4} , оптимизатор Adam.

Длина авторегрессионной развёртки растёт по учебному плану. Обучение начинается с одношагового прогноза, затем число шагов K в (7) увеличивается до четырёх. Функция потерь считается по всем шагам развёртки.

Функция потерь равна среднеквадратической ошибке в стандартизованных переменных по всем узлам расчётной сетки. Мы пробовали считать потери только по области интереса. Поля за её пределами тогда деградировали и через авторегрессию ухудшали прогноз внутри области. Рельеф и маска суши и моря в функцию потерь не входят и переносятся между шагами развёртки без изменений.

Результаты: качество регионального прогноза

Условия оценки

Все оценки получены на одном окне верификации и с одним определением истинного поля (разд. 2): это реанализ ERA5 с шагом $0,25^\circ$ в узлах региональной вставки. Показатели: ошибка (1), успешность относительно эталона (2), агрегатная успешность (3) и аномальная корреляция (4). Табл. 1 посчитана с широтными весами, табл. 3–5 с равными. В табл. 3–5

конфигурации сравниваются между собой, а вес меняет ошибку не более чем на 0,02 °C и агрегат на 0,2 п.п., одинаково у всех строк.

Объём выборки в таблицах разный. Табл. 1, 3 и 4 посчитаны на полной тестовой выборке из 1607 сроков (25.11.2019–30.12.2020, все четыре сезона). Табл. 2 и 5 посчитаны на первых 100 сроках периода (по 19.12.2019). Эта подвыборка приходится на холодное полугодие и труднее полной: ошибка приземной температуры на суточном сроке равна 1,47 °C на 1607 сроках и 2,05 °C на 100. Числа из разных таблиц сравнивать нельзя. Внутри одной таблицы все конфигурации посчитаны на одних сроках.

Качество основной модели

На суточном сроке ошибка приземной температуры равна 1,47 °C по области [1,39; 1,53] и 1,31 °C во внутренней зоне [1,21; 1,40]. По остальным полям региона на том же сроке: ветер 0,70 и 0,68 м/с, давление на уровне моря 1,03 гПа, T850 0,94 °C, Z500 8,7 гпм. Аномальную корреляцию мы приводим в п. 4.7 вместе со сравнением с глобальной моделью, чтобы обе модели оценивались по одной климатологии.

Переход с 19 на 33 канала (уровни 250 и 1000 гПа, временной форсинг) уменьшает ошибку на всех горизонтах: на 0,076 / 0,121 / 0,149 / 0,174 °C с интервалами [0,063; 0,088], [0,104; 0,138], [0,125; 0,171] и [0,141; 0,210]. Весь выигрыш нельзя приписать новым уровням: 33-канальную конфигурацию дообучали от другой глобальной модели, которая сама точнее. Взвешенная конфигурация снижает ошибку приземной температуры относительно базовой 33-канальной ещё на 11,6 % (1,548 против 1,368 °C в среднем по горизонтам), а агрегатную успешность повышает на 1,17 п.п. с интервалом [+1,09; +1,24]. Часть этого выигрыша дают восемь эпох дополнительного обучения; при равном объёме обучения выигрыш равен 10,2 % (п. 4.4).

Что даёт единый граф

Чтобы оценить вклад самой мультимасштабной конструкции, мы билинейно интерполировали прогноз глобальной модели с шагом 0,703° в те же 2501 узел и оценили его по той же истине. Все строки табл. 2 посчитаны на одних и тех же 100 сроках тестовой выборки.

Единый граф точнее интерполяции по всем полям. По приземной температуре выигрыш умеренный (11 %), по ветру и геопотенциалу больше (37–40 %). Вероятная причина в том, что обмен сообщениями уточняет поле в целом. Приземную температуру в конкретном узле сильнее определяют подсеточные факторы, которых не разрешает ни одна из сравниваемых конфигураций.

Веса в функции потерь

При обучении функция потерь равна среднеквадратической ошибке по нормированным каналам, усреднённой по узлам графа и шагам развёртки. Такое усреднение неявно задаёт, какие

части задачи получают обучающий сигнал. В двух отношениях это распределение далеко от постановки задачи.

Первая диспропорция пространственная. Узлов региональной вставки 2501 из 133 279, то есть 1,9 %. Почти весь обучающий сигнал приходится на глобальную часть графа, хотя публикуемые показатели относятся к вставке.

Вторая диспропорция поканальная. Каждый канал нормирован на разброс самого поля, а модель предсказывает приращение за шаг, и разбросы приращений у каналов различаются на порядки. По обучающей выборке осадки дают 25,0 % функции потерь, приземная температура 0,46 %, геопотенциал на 500 гПа 0,15 %, приземное давление 0,02 %. Крайние доли различаются в 1218 раз. Вклад канала определяется масштабом его изменчивости, а не значимостью.

Обе диспропорции мы устранили весами. Узлы вставки получают вес W , остальные узлы единичный вес. Каналы получают веса, обратные квадрату разброса шестичасовой невязки по обучающей выборке. Все конфигурации табл. 3 получены одинаковым дожигом одной исходной модели: восемь эпох на полной развёртке с косинусным снижением темпа до нуля. Различаются они только весами. Первая строка табл. 3 (1,503 °C) не совпадает со строкой «33 канала, базовая» табл. 1 (1,525 °C без широтных весов), потому что в неё уже включён дожиг. При равном объёме обучения взвешивание даёт выигрыш 10,2 %, а разность с табл. 1 (11,5 %) включает ещё и восемь эпох дожига.

У веса вставки есть внутренний максимум по агрегату. Когда доля вставки растёт с 1,7 до 34,1 %, улучшаются и агрегат, и приземная температура. Дальнейший рост до 63,3 % агрегат ухудшает. Парный блочный бутстреп по общим срокам даёт для разности агрегатов при $W = 100$ и $W = 30$ величину $-0,05$ п.п. с интервалом $[-0,07; -0,03]$, который не покрывает ноль. Этот интервал учитывает изменчивость по срокам, но не по повторным обучениям. Изменчивость по обучениям оценена в 0,03 п.п. и сравнима с самой разностью. По приземной температуре максимума нет, ошибка убывает монотонно (1,503 $\rightarrow$ 1,445 $\rightarrow$ 1,415 $\rightarrow$ 1,407). Внутренний максимум по агрегату мы считаем свойством этой выборки, а не метода.

Механизм виден в последнем столбце. За выигрыш во вставке модель платит точностью на глобальной части графа. При $W = 100$ ошибка по сетке растёт втрое сильнее, чем при $W = 30$ (0,0021 против 0,0007). Суточный прогноз внутри вставки зависит от притока извне. Ухудшение окружающего поля возвращается в область через развёртку, и оптимум определяется балансом между областью и её окружением.

Веса каналов работают как регулятор, а не как исправление ошибки. С ними агрегат снижается на 0,30 п.п. (интервал $[-0,32; -0,28]$), а приземная температура улучшается на 4,6 %, и все четыре интервала не покрывают ноль. Агрегат (3) сам равен среднему по каналам с равными весами, так что для него равномерное взвешивание оптимально по построению. Выравнивание вкладов переносит точность с каналов с большой собственной изменчивостью на каналы с малой. Выигрыш канала описывается логарифмом его веса (корреляция 0,98 по

12 каналам), но за пределы измеренного диапазона эту зависимость переносить нельзя. Механизм тот же, что у веса вставки: усиленные каналы отбирают ресурс у полей, от которых сами зависят.

Основная конфигурация статьи использует $W = 30$ и выравнивающие веса каналов. Веса каналов вычислены по обучающей выборке и по тестовой не подбирались. Целевые каналы для усиления отдельно не выбирали.

Стратегия дообучения и выбор контрольной точки

Стратегию дообучения мы исследовали на отдельной линии 19-канальных моделей. Сравнивались два варианта: заморозка процессора на первые 6 эпох и обучение всех параметров с первой эпохи. Сборка данных, начальное значение генератора и расписание у вариантов одинаковые. Эта линия предсказывает само поле, а не приращение. Её агрегатная успешность (около 60 %) поэтому ниже, чем у 19-канальной строки табл. 1 (69,2 %), хотя ошибки приземной температуры близки. Числа табл. 1 и 4 относятся к разным моделям, и сравнивать их между собой нельзя.

Если сравнивать лучшие контрольные точки, заморозка выигрывает до 0,14 °C на +24 ч. Но лучшие точки достигнуты на разных эпохах, 16-й и 7-й, и сравниваются не только стратегии, но и объёмы обучения. При равном бюджете разность по приземной температуре исчезает: обе конфигурации дают 1,82 °C на сутки.

Контрольная точка эпохи 7, «лучшая» по одношаговой ошибке, в авторегрессионной развёртке проигрывает точке эпохи 16 той же конфигурации (1,96 против 1,82 °C). Тот же эффект есть у базовой 33-канальной конфигурации. Состояние с минимальной ошибкой на проверочной выборке точнее на +6 ч (1,30 против 1,32 °C), но проигрывает на +18 и +24 ч, и смена знака значима с обеих сторон.

Отсюда методический вывод. Минимум одношаговой ошибки на проверочной выборке выбирает модель, лучшую ровно на измеряемом горизонте, и для многошагового прогноза этот критерий ненадёжен. Отбирать модель следует по метрике на полной развёртке, а стратегии сравнивать при равном бюджете.

О роли самой заморозки можно сказать немного. По приземной температуре при равном бюджете расписание на итог не влияет: 1,82 против 1,82 °C, интервалы [1,72; 1,90] и [1,71; 1,90] совпадают. По агрегату заморозка выигрывает 1,30 п.п. с интервалом [+1,06; +1,59], который не накрывает ноль (60,8 против 59,5 %).

Это второй после п. 4.4 случай, когда агрегат и поканальные значения расходятся, и причина та же. Агрегат усредняет нормированные ошибки по всем каналам. Вклад каждого канала определяется отношением его ошибки к разбросу поля, а не значимостью канала для практики. Ранжирование конфигураций поэтому зависит от того, какое поле выбрано целевым. В отчёте нужно приводить и агрегат, и поканальные значения целевых полей на одной маске узлов.

Адаптировать процессор под регион всё же необходимо. Если заморозить его на всё обучение, ошибка на проверочной выборке выше на 7,5 %. Обучение выходит на плато к восьмой эпохе, и ошибка на обучающей выборке тоже выше. Значит, модели не хватает свободы подстроить динамику, а не данных. Эту величину измерили одношаговой метрикой, и мы используем её как признак недообучения, а не для отбора состояния.

Диагностика стыка

Мы утверждаем, что жёсткая склейка узлов не требует отдельной процедуры сшивания. Чтобы проверить это напрямую, ошибку приземной температуры посчитали по полосам расстояния до границы региональной вставки (табл. 5).

Переходный слой существует. На горизонте +6 ч ошибка монотонно убывает с удалением от границы: 1,58 °C в полосе шириной 25 км против 1,40 °C в глубине области, то есть у стыка она выше на 13 %. Эффект прослеживается примерно на 100–200 км. Значит, о полной бесшовности говорить нельзя.

В авторегрессии переходный слой не усиливается. Превышение у стыка над минимумом по полосам составляет 6,0 / 8,8 / 7,9 / 6,5 % по четырём горизонтам и держится в пределах 6–9 %. Относительно дальней полосы превышение со временем уменьшается, но причина в росте ошибки в глубине области, а не в рассасывании переходного слоя. В глубине области лежат горные районы, и на дальних сроках там преобладает ошибка из-за рельефа. Неограниченный рост ошибки у границы составляет главную трудность региональных моделей с внешними граничными условиями, и у нашей модели его нет.

Глобальная часть не страдает. Сразу за границей вставки ошибка (1,87 °C на +24 ч) не больше, чем вдали от неё (1,95 и 2,05 °C). Склейка создаёт переходный слой ограниченной величины и не требует отдельной процедуры сшивания полей.

Сравнение с глобальной моделью

Публикуемые метрики GraphCast [8] относятся ко всему земному шару, а наши к вставке над Красноярским краем. Напрямую их сравнивать нельзя: больше половины площади шара занимает океан, где прогноз точнее. Мы взяли прогнозы GraphCast, реанализ и климатологию из архива WeatherBench 2 [12] в разрешении 0,25°, вырезали те же 2501 узел и посчитали метрики тем же кодом и с теми же широтными весами.

В архиве GraphCast есть только инициализации 00 и 12 UTC, и сравнение идёт на 803 сроках тестового окна, общих для обеих моделей. Правильность сопоставления мы проверили на инерционном прогнозе. Посчитанный по архиву, он даёт по приземной температуре 6,71 / 6,90 / 4,02 / 4,45 °C, а посчитанный нашим кодом на тех же сроках 6,71 / 6,90 / 4,03 / 4,45 °C. Сравнение ограничено приземными полями. Уровни лежат в архиве одним блоком, и скачать один уровень стоит столько же, сколько все.

GraphCast точнее по всем полям, сильнее всего по давлению на уровне моря. Такое соотношение ожидаемо. У GraphCast 36,7 млн параметров против 6,0 млн, разрешение $0,25^\circ$ по всему шару против грубой глобальной сетки со вставкой, 37 уровней против четырёх и обучение на многих ускорителях против одного. Отставание показывает цену перехода к вычислительной среде регионального подразделения. Предел самого подхода это сравнение не определяет.

Аномальная корреляция нашей модели относительно той же климатологии равна 0,973 [0,968; 0,978] по области и 0,983 [0,977; 0,986] во внутренней зоне. По остальным полям области она равна 0,946 и 0,927 для составляющих ветра, 0,995 для давления, 0,988 для T850 и 0,998 для Z500.

Обсуждение, выводы и направления дальнейшей работы

Все улучшения, описанные в работе, получены без изменения архитектуры: менялось только распределение обучающего сигнала. Оба веса улучшают целевую часть задачи за счёт остальной. Большой вес вставки ухудшает прогноз на глобальной части графа, а от него через приток извне зависит и сама вставка. Веса каналов улучшают приземную температуру и снижают агрегат по всем каналам.

Ограничения

Изменчивость между запусками оценена одной парой прогонов с разными начальными значениями генератора. Агрегат у них расходится на 0,03 п.п. (73,41 против 73,40 %), и различия имеют смысл начиная с десятых долей пункта. Вес целевой области $W = 30$ и стратегию дообучения выбрали по табл. 3 и 4, которые посчитаны на тестовой выборке, а не на проверочной. Выбор одного гиперпараметра из четырёх значений слабо переиспользует тестовую выборку, но величины для $W = 30$ следует считать слегка оптимистичными. К весам каналов эта оговорка не относится: их вычислили по обучающей выборке.

Три приёма, от которых мы ждали пользы, не помогли. Шум в авторегрессии ухудшил прогноз на 5–15 %. Ансамбль дообученных состояний одной модели не дал выигрыша: ошибки состояний коррелируют с коэффициентом 0,993. Обучение на развёртке в двенадцать шагов вместо четырёх изменило агрегат на 0,11 п.п., и интервал накрывает ноль. Подробный разбор вынесен в отдельную методическую работу.

Истинным полем служит реанализ, а не станционные наблюдения. Реанализ сглаживает подсеточные эффекты, в том числе городской остров тепла, и наши оценки нельзя перенести на прогноз в точке станции без постобработки. С оперативной моделью мы не сравнивались. При таком сравнении нужно учесть, что модель, обученная на реанализе, оценивается против того же реанализа и находится в выгодном положении [12]. Результаты получены для одной территории и одного тестового окна. Прямого сравнения с региональной моделью с граничным форсингом [10] мы не проводили.

Направления дальнейшей работы

Граф можно уплотнить, если объединить все уровни икосаэдрической мозаики, а не два. Это даёт дальние связи без роста числа параметров. Следующие шаги: больше прогностических полей и прогноз с оценкой неопределённости через ансамбль возмущённых начальных состояний или порождающие вероятностные модели. Чтобы схему приняли в оперативную практику, её нужно проверить по данным сети станций. Отдельная задача состоит в том, чтобы включить циклическое усвоение наблюдений в автоматический цикл выпуска прогноза.

Выводы

1. Построена и проверена мультимасштабная графовая нейронная сеть для регионального прогноза погоды. Глобальная и региональная части в ней соединены без отдельной процедуры сшивания полей. Диагностика стыка показывает переходный слой шириной 100–200 км, где ошибка выше на 6–9 %, и с ростом горизонта этот слой не усиливается. Для обучения и расчёта хватает одного графического ускорителя.
2. Единый граф точнее интерполяции прогноза глобальной модели в узлы области по всем полям: выигрыш составляет 11 % по приземной температуре и 37–40 % по ветру и геопотенциалу.
3. Отбор состояния модели по ошибке одношагового прогноза ненадёжен для многошагового прогноза. Расписание заморозки процессора на итоговую ошибку приземной температуры не влияет, но адаптировать процессор необходимо: без неё ошибка на проверочной выборке выше на 7,5 %.
4. Один агрегатный показатель скрывает разное поведение модели по отдельным полям. Результаты верификации нужно приводить по каждому целевому полю отдельно.
5. При равномерном усреднении функции потерь узлы целевой области получают 1,7 % обучающего сигнала, приземная температура 0,46 %. Явные веса снижают ошибку приземной температуры на 10,2 % без изменения архитектуры и объёма обучения. При слишком большом весе целевой области ухудшается прогноз на глобальной части графа, а от него через приток извне зависит и сама область.

Список литературы

1. Толстых М.А., Шашкин В.В., Фадеев Р.Ю. и др. Система моделирования атмосферы для бесшовного прогноза. М.: Триада ЛТД, 2017. 166 с.
2. Battaglia P.W., Pascanu R., Lai M. et al. Interaction networks for learning about objects, relations and physics // Advances in Neural Information Processing Systems (NIPS). 2016. Vol. 29. P. 4502–4510.

3. Bi K., Xie L., Zhang H. et al. Accurate medium-range global weather forecasting with 3D neural networks // *Nature*. 2023. Vol. 619, No. 7970. P. 533–538. DOI: 10.1038/s41586-023-06185-3.
4. Davies H.C. A lateral boundary formulation for multi-level prediction models // *Quarterly Journal of the Royal Meteorological Society*. 1976. Vol. 102, No. 432. P. 405–418. DOI: 10.1002/qj.49710243210.
5. Gao Y., Wu H., Shu R. et al. OneForecast: A universal framework for global and regional weather forecasting // *Proceedings of the 42nd International Conference on Machine Learning (ICML)*. PMLR, 2025. Vol. 267. P. 18658–18697.
6. Hersbach H., Bell B., Berrisford P. et al. The ERA5 global reanalysis // *Quarterly Journal of the Royal Meteorological Society*. 2020. Vol. 146, No. 730. P. 1999–2049. DOI: 10.1002/qj.3803.
7. Künsch H.R. The jackknife and the bootstrap for general stationary observations // *The Annals of Statistics*. 1989. Vol. 17, No. 3. P. 1217–1241. DOI: 10.1214/aos/1176347265.
8. Lam R., Sanchez-Gonzalez A., Willson M. et al. Learning skillful medium-range global weather forecasting // *Science*. 2023. Vol. 382, No. 6677. P. 1416–1421. DOI: 10.1126/science.adi2336.
9. Nipen T.N., Haugen H.H., Ingstad M.S. et al. Regional data-driven weather modeling with a global stretched grid // *Artificial Intelligence for the Earth Systems*. 2026. Vol. 5, No. 2. Art. e250001. DOI: 10.1175/AIES-D-25-0001.1.
10. Oskarsson J., Landelius T., Lindsten F. Graph-based neural weather prediction for limited area modeling // *arXiv:2309.17370*. 2023.
11. Pathak J., Subramanian S., Harrington P. et al. FourCastNet: A global data-driven high-resolution weather model using adaptive Fourier neural operators // *arXiv:2202.11214*. 2022.
12. Rasp S., Hoyer S., Merose A. et al. WeatherBench 2: A benchmark for the next generation of data-driven global weather models // *Journal of Advances in Modeling Earth Systems*. 2024. Vol. 16, No. 6. Art. e2023MS004019. DOI: 10.1029/2023MS004019.
13. Wijnands J.S., Van Genderachter M., François B. et al. Data-driven regional weather forecasting: A comparison of stretched-grid and limited-area modelling // *Machine Learning with Applications*. 2026. Vol. 24. Art. 100887. DOI: 10.1016/j.mlwa.2026.100887.

References

1. Tolstykh M.A., Shashkin V.V., Fadeev R.Yu. et al. Sistema modelirovaniya atmosfery dlya besshovnogo prognoza [Atmosphere Modelling System for Seamless Prediction]. Moscow, Triada Ltd. Publ., 2017, 166 p. [in Russ.]
2. Battaglia P.W., Pascanu R., Lai M. et al. Interaction networks for learning about objects, relations and physics. *Advances in Neural Information Processing Systems (NIPS)*, 2016, vol. 29, pp. 4502–4510.

3. Bi K., Xie L., Zhang H. et al. Accurate medium-range global weather forecasting with 3D neural networks. *Nature*, 2023, vol. 619, no. 7970, pp. 533–538. DOI: 10.1038/s41586-023-06185-3.
4. Davies H.C. A lateral boundary formulation for multi-level prediction models. *Quarterly Journal of the Royal Meteorological Society*, 1976, vol. 102, no. 432, pp. 405–418. DOI: 10.1002/qj.49710243210.
5. Gao Y., Wu H., Shu R. et al. OneForecast: A universal framework for global and regional weather forecasting. *Proceedings of the 42nd International Conference on Machine Learning (ICML)*, PMLR, 2025, vol. 267, pp. 18658–18697.
6. Hersbach H., Bell B., Berrisford P. et al. The ERA5 global reanalysis. *Quarterly Journal of the Royal Meteorological Society*, 2020, vol. 146, no. 730, pp. 1999–2049. DOI: 10.1002/qj.3803.
7. Künsch H.R. The jackknife and the bootstrap for general stationary observations. *The Annals of Statistics*, 1989, vol. 17, no. 3, pp. 1217–1241. DOI: 10.1214/aos/1176347265.
8. Lam R., Sanchez-Gonzalez A., Willson M. et al. Learning skillful medium-range global weather forecasting. *Science*, 2023, vol. 382, no. 6677, pp. 1416–1421. DOI: 10.1126/science.adi2336.
9. Nipen T.N., Haugen H.H., Ingstad M.S. et al. Regional data-driven weather modeling with a global stretched grid. *Artificial Intelligence for the Earth Systems*, 2026, vol. 5, no. 2, art. e250001. DOI: 10.1175/AIES-D-25-0001.1.
10. Oskarsson J., Landelius T., Lindsten F. Graph-based neural weather prediction for limited area modeling. *arXiv:2309.17370*, 2023.
11. Pathak J., Subramanian S., Harrington P. et al. FourCastNet: A global data-driven high-resolution weather model using adaptive Fourier neural operators. *arXiv:2202.11214*, 2022.
12. Rasp S., Hoyer S., Merose A. et al. WeatherBench 2: A benchmark for the next generation of data-driven global weather models. *Journal of Advances in Modeling Earth Systems*, 2024, vol. 16, no. 6, art. e2023MS004019. DOI: 10.1029/2023MS004019.
13. Wijnands J.S., Van Ginderachter M., François B. et al. Data-driven regional weather forecasting: A comparison of stretched-grid and limited-area modelling. *Machine Learning with Applications*, 2026, vol. 24, art. 100887. DOI: 10.1016/j.mlwa.2026.100887.

Таблица 1. Ошибка приземной температуры (°C) по горизонтам и агрегатная успешность $\bar{S}$ (%) согласно (3). Тестовая выборка 1607 сроков. Регион содержит 2501 узел, внутренняя зона 45 узлов.

Зона	Конфигурация	+6 ч	+12 ч	+18 ч	+24 ч	$\bar{S}$, %
Регион	19 каналов	1,41	1,67	1,75	1,85	69,2
	33 канала, базовая	1,33	1,55	1,61	1,68	73,2
	33 канала, взвешенная (основная)	1,19	1,38	1,41	1,47	74,4
Внутренняя зона	33 канала, базовая	1,21	1,41	1,47	1,53	74,5
	33 канала, взвешенная (основная)	1,06	1,23	1,26	1,31	75,4

Table 1. RMSE of 2 m temperature (°C) by lead time and aggregate skill score $\bar{S}$ (%) per (3). 1607 initial times; region 2501 nodes, inner zone 45 nodes.

Таблица 2. Ошибка прогноза на горизонте +24 ч в узлах региональной вставки: инерционный прогноз, интерполяция прогноза глобальной модели и мультимасштабная модель.

Поле	Инерционный прогноз	Глобальная 0,703° + интерполяция	Мультимасштабная	Выигрыш
t2m, °C	4,20	2,30	2,05	11 %
10u, м/с	2,71	0,99	0,59	40 %
msl, гПа	9,36	2,23	1,66	26 %
t@850, °C	6,27	1,48	1,23	17 %
z@500, гПм	88,5	21,0	13,3	37 %

Table 2. Error at +24 h at the insert nodes: persistence, interpolated global forecast, multiscale model.

Таблица 3. Влияние весов в функции потерь. Регион, 1607 сроков. Ошибка t2m усреднена по четырём горизонтам. Последний столбец показывает ошибку по всей сетке графа.

Конфигурация	Доля вставки в потерях	$\bar{S}$, %	t2m, °C	RMSE по сетке
Исходная (без весов, после дожига)	1,7 %	73,8	1,503	0,1696
Вес вставки $W = 10$	14,7 %	74,7	1,445	0,1697
Вес вставки $W = 30$	34,1 %	74,9	1,415	0,1703
Вес вставки $W = 100$	63,3 %	74,8	1,407	0,1717
$W = 30$ и веса каналов	34,1 %	74,6	1,350	0,1708

Table 3. Effect of loss weighting. Region, 1607 initial times; t2m averaged over four lead times, last column — error over the whole graph.

Таблица 4. Ошибка приземной температуры (°C) по региону и агрегатная успешность при разных способах отбора контрольной точки.

Конфигурация	Состояние	+6 ч	+12 ч	+18 ч	+24 ч	$\bar{S}$, %
С заморозкой	лучшая по val (эпоха 16)	1,34	1,59	1,71	1,82	60,8
Без заморозки	лучшая по val (эпоха 7)	1,36	1,65	1,81	1,96	59,9
Без заморозки	равный бюджет (эпоха 16)	1,35	1,62	1,72	1,82	59,5

Table 4. RMSE of 2 m temperature (°C) and aggregate skill score for different ways of selecting the checkpoint.

Таблица 5. Ошибка приземной температуры (°C) по расстоянию до границы вставки. Положительное расстояние отсчитывается внутрь вставки (шаг 0,25°), отрицательное наружу, на глобальную часть графа (шаг 0,703°).

Зона	Расстояние до границы, км	Узлов	+6 ч	+12 ч	+18 ч	+24 ч
Вставка 0,25°	0–25	278	1,58	1,97	2,06	2,12
	25–50	240	1,54	1,92	2,00	2,08
	50–100	414	1,51	1,85	1,94	2,02
	100–200	698	1,49	1,81	1,91	1,99
	200–1000	871	1,40	1,80	1,97	2,07
Глобальная 0,703°	–100...0	143	1,37	1,74	1,82	1,87
	–300...–100	308	1,42	1,76	1,88	1,95
	–1000...–300	1708	1,36	1,73	1,91	2,05

Table 5. RMSE of 2 m temperature (°C) by distance to the insert boundary. Positive — inside (0.25°), negative — outside (0.703°).

Таблица 6. Сравнение с GraphCast на одних узлах и сроках: 803 инициализации, 2501 узел, широтные веса. Ошибка осреднена по горизонтам +6...+24 ч, аномальная корреляция вычислена относительно климатологии WeatherBench 2 за 1990–2019 гг.

Поле	GraphCast	Наша модель	Отношение
Приземная температура, °C	1,04	1,38	1,33
Зональная составляющая ветра, м/с	0,45	0,64	1,43
Меридиональная составляющая, м/с	0,44	0,63	1,44
Давление на уровне моря, гПа	0,47	0,84	1,79
Аномальная корреляция t2m	0,984	0,973	—

Table 6. Comparison with GraphCast on shared nodes and times: 803 initialisations, 2501 nodes, latitude weights. RMSE averaged over +6...+24 h; ACC against the WeatherBench 2 1990–2019 climatology.




Рис. 1. Прогноз приземной температуры на +24 ч в окрестности границы региональной вставки. Размер ячейки равен шагу сетки: 0,25° внутри вставки и 0,703° снаружи. Штриховой линией показана граница вставки.

Fig. 1. 2 m temperature forecast at +24 h near the insert boundary. Cell size follows the grid spacing, 0.25° inside and 0.703° outside; dashed line — the boundary.